



École normale supérieure de Rennes
Département Sciences du sport et éducation physique

Diplôme de l'ENS – 1^{ère} année
Année universitaire 2025-2026
Discipline : STAPS

Mémoire en Sciences de la Vie et de la Santé

Identification des marqueurs de motricité fine les plus caractéristiques des TSA chez l'enfant : Approche bayésienne par projection prédictive

Présenté par :
Romain MARTINIE

Encadrants :
Laetitia FRADET (Université de Bretagne-Sud)
&
Germain FAITY (ENS, département 2SEP)

Attestation sur l'honneur

Je soussigné, Romain MARTINIE, atteste sur l'honneur de ne pas avoir eu recours au plagiat et que ce mémoire de recherche est le résultat d'un travail personnel. La rédaction de ce travail a été effectuée avec l'aide d'intelligence artificielle générative (modèle Claude Sonnet 4.6 : assistance dans le code, les formulations et correction de la langue).

Table des matières

1	Introduction	1
2	Revue de littérature	2
2.1	Les troubles du spectre de l'autisme (TSA)	2
2.1.1	Définition	2
2.1.2	Prévalence et comorbidités	2
2.1.3	Apparition du phénotype et trajectoires développementales	2
2.2	Bases neuronales des TSA	3
2.2.1	Bases structurelles	3
2.2.2	Altérations fonctionnelles	3
2.3	Diagnostic des TSA : outils, validité, et limites méthodologiques	4
2.3.1	Outils comportementaux de référence	4
2.3.2	Validité et questionnement du statut de référence	5
2.3.3	Ancrage normatif des outils de diagnostic	5
2.4	TSA et contrôle moteur : caractérisation de la motricité fine	6
2.4.1	Pointage et saisie manuelle	6
2.4.2	Écriture	6
2.4.3	Apport des approches par apprentissage automatique	7
	Classification en fonction de variables motrices	7
	Caractérisation de la motricité fine	7
3	Problématique, objectifs et hypothèses	8
3.1	Problématique	8
3.2	Objectifs	8
3.3	Hypothèses	8
4	Matériel et méthodes	9
4.1	Protocole expérimental	9
4.1.1	Population	9
4.1.2	Dispositif et tâches motrices	9
	Anticipation pointage	9
	Anticipation écriture	10
	Isochronie	10
	Pointage simple	10
4.2	Description du jeu de données	11
4.3	Cadre de l'inférence bayésienne	11
4.4	Cadre interprétatif de la sélection	12

4.5	Prétraitement des données	12
4.6	Modèle de référence	12
4.6.1	Régression logistique bayésienne	12
4.6.2	Spécification des priors	13
4.6.3	Critères de validité du modèle	14
4.6.4	Diagnostics MCMC	14
4.6.5	Vérifications prédictives (<i>Predictive Checks</i>)	14
4.7	Sélection par projection prédictive	15
4.7.1	Principe de cv varsel	15
4.7.2	Critère de sélection	15
4.8	Screening par comparaison de modèles et sélection sur la tâche PA	15
4.9	Analyse de sensibilité	16
4.10	Environnement logiciel	16
5	Résultats	17
5.1	Sélection sur le modèle global : limites de l'approche	17
5.1.1	Courbe elpd et sélection des variables	17
5.1.2	Diagnostics MCMC et approximation PSIS-LOO	19
5.1.3	Sensibilité au prior (p_0)	19
5.2	Screening par tâche motrice	20
5.3	Sélection sur la tâche PA	20
5.3.1	Courbe elpd et sélection des variables	20
5.3.2	Diagnostics MCMC et approximation PSIS-LOO	22
5.3.3	Sensibilité au prior (p_0)	23
5.3.4	Représentation dans l'espace des variables sélectionnées	23
6	Discussion	25
6.1	Interprétation des variables sélectionnées	25
6.2	Apport de l'approche bayésienne	26
6.3	Limites	26
7	Conclusion	27

Table des figures

4.1	Configuration expérimentale pour la réalisation de la tâche d'Anticipation Pointage . .	9
4.2	Représentation des visuels utilisés pour la réalisation de la tâche d'Anticipation Ecriture	10
4.3	Représentation des visuels utilisés pour la réalisation de la tâche d'isochronie	10
5.1	Courbes elpd et accuracy issue du modèle de référence global	17
5.2	Distributions <i>a posteriori</i> du sous-modèle réduit à partir du modèle de référence global	18
5.3	Diagnostics MCMC pour le paramètre L2_large , modèle global	19
5.4	Comparaison des modèles par tâche	21
5.5	Courbes elpd et d'accuracy issue du modèle de référence PA	22
5.6	Distributions <i>a posteriori</i> du sous-modèle réduit à partir du modèle de référence PA .	22
5.7	Diagnostics MCMC pour le paramètre L2_large , modèle PA	23
5.8	Représentation des observations dans l'espace des variables sélectionnées	24
7.1		34
7.2		35
7.3		36

Liste des tableaux

4.1	Paramètres utilisés lors de la tâche de Fitts	10
5.1	Estimations <i>a posteriori</i> du sous-modèle réduit à partir du modèle de référence global	18
5.2	Analyse de sensibilité au prior p_0 pour le modèle complet	20
5.3	Estimations <i>a posteriori</i> du sous-modèle réduit à partir du modèle de référence PA . .	21
5.4	Analyse de sensibilité au prior p_0 , modèle PA	24

1 Introduction

En France, en 2003, les registres régionaux estimaient la prévalence des troubles du spectre de l'autisme (TSA) chez les enfants de moins de sept ans à 4,1 pour 1 000 (HAS, 2018, p.10). Cette valeur est probablement sous-évaluée, car les formes plus modérées échappent souvent aux dispositifs d'identification (HAS, 2018, p.10). Par ailleurs, le nombre de diagnostics tend à augmenter (ZEIDAN et al., 2022) et la reconnaissance institutionnelle des TSA s'accroît¹. Les retards dans le diagnostic peuvent dépasser un an entre la première prise de contact et la restitution du diagnostic en France dans le cadre d'un Centre de Ressources Autisme (CRA)², illustrant la difficulté à diagnostiquer les individus autistes.

Le diagnostic, posé par un psychiatre, repose principalement sur les altérations de la communication et des interactions sociales, ainsi que sur les comportements stéréotypés et les intérêts restreints (APA, 2022, p. 56–58). Cette approche présente des limites en pratique clinique, pouvant conduire à des biais (par exemple liés au genre, voir Section 2.3.3) ou expliquer en partie les retards dans la prise en charge par les CRA.

Pour autant, la littérature montre que les TSA s'accompagnent de caractéristiques motrices qui ne sont pas exploitées pour le diagnostic. Ces particularités apparaissent pourtant précocement, parfois dès les premiers mois de vie, voire avant les signes sociaux atypiques (AL SAGHEER et al., 2018; ZWAIGENBAUM et al., 2015). Parallèlement, des corrélats neuronaux pourraient expliquer ces manifestations motrices et le phénotype autistique dans son ensemble (voir Section 2.2). Ces observations suggèrent que les caractéristiques motrices pourraient ainsi constituer des marqueurs précoces du développement autistique.

Ce mémoire s'inscrit dans la continuité des travaux réalisés dans le cadre du projet "*Identifier et caractériser les déficits moteurs associés aux troubles du spectre autistique*", dont une partie des données a déjà été exploitée dans la thèse de BENCHEKRI (2024). En mobilisant une approche bayésienne, ce mémoire vise à identifier les variables de motricité fine les plus caractéristiques des enfants autistes, afin de proposer des pistes d'amélioration dans la compréhension et le diagnostic des TSA.

1. Comme en témoigne en France la *Stratégie nationale pour les troubles du neurodéveloppement 2023-2027*, <https://handicap.gouv.fr/nouvelle-strategie-nationale-pour-les-troubles-du-neurodeveloppement-autisme-dys-tdah-tdi>

2. IGAS. (2015). *Évaluation des Centres de ressources autisme (CRA) en appui de leur évolution* (p. 37). <https://igas.gouv.fr/sites/igas/files/files-spip/pdf/2015-124R-2.pdf>

2 Revue de littérature

2.1 Les troubles du spectre de l'autisme (TSA)

2.1.1 Définition

Les troubles du spectre de l'autisme (TSA) sont des troubles neurodéveloppementaux caractérisés par des difficultés persistantes dans la communication et les interactions sociales, ainsi que par des comportements et intérêts restreints ou répétitifs (APA, 2022, p. 56–58). Ce trouble apparaît pendant la période du développement, en général à la petite enfance. L'appellation "spectre" reflète une forte hétérogénéité individuelle au-delà des critères centraux de la communication et des comportements répétitifs (OMS, 2018). Ainsi, les TSA peuvent également se manifester à travers une déficience intellectuelle, des troubles du langage ou des troubles moteurs (APA, 2022, p. 62), et sont souvent accompagnés de comorbidités (APA, 2022, p. 67–68 ; LORD et al., 2018).

2.1.2 Prévalence et comorbidités

La prévalence des TSA est estimée à environ 1 % dans le monde, bien que les chiffres varient selon les études et aient tendance à augmenter avec le temps en raison d'une hausse des demandes de diagnostic (BRUGHA et al., 2011 ; ELSABBAGH et al., 2012 ; ZEIDAN et al., 2022). Les garçons sont généralement plus nombreux que les filles, avec un ratio masculin/féminin variant autour de 4 (ZEIDAN et al., 2022), malgré des biais genrés compliquant l'évaluation (voir Section 2.3.3). Les TSA seraient associés à une probabilité accrue de déficience intellectuelle (DI), mais la proportion n'est pas connue (ZEIDAN et al., 2022).

Par ailleurs, les TSA s'accompagnent fréquemment de comorbidités psychiatriques. Chez l'enfant, environ 45 % présentent par exemple au cours de leur vie un trouble déficitaire de l'attention avec hyperactivité (TDAH), 42 % un trouble anxieux et 14 % une dépression (MICAÏ et al., 2023). Chez l'adulte, ces proportions sont respectivement de l'ordre de 22 %, 28 à 42 % et 34 % (HOLLOCKS et al., 2019 ; MICAÏ et al., 2023) et sont donc supérieures à celles de la population générale. On y retrouve en effet autour de 4 % pour le TDAH (POPIT et al., 2024 ; SONG et al., 2021), 9 % pour le trouble anxieux (KESSLER et al., 2012) et 29 % pour la dépression (HU et al., 2022 ; KESSLER et al., 2012).

La prévalence et la diversité des comorbidités psychiatriques observées invitent donc à un diagnostic le plus précoce possible. En ce sens, quand est-ce que les premières caractéristiques autistiques émergent-elles ? Demeurent-elles stables tout au long du développement ?

2.1.3 Apparition du phénotype et trajectoires développementales

Dès les premiers mois de vie, des signes précoces du phénotype autistique apparaissent. Alors, dès l'âge d'un an, peuvent être observées des difficultés dans les premières interactions sociales, ainsi que des comportements répétitifs ou stéréotypés (TANNER & DOUNAVI, 2021 ; WEBB & JONES, 2009 ; ZWAIGENBAUM et al., 2015). Un contrôle moteur atypique, que ce soit au niveau de la motricité globale ou motricité fine, est également décrit dès 6 à 12 mois (ESTES et al., 2015 ; ZWAIGENBAUM et al., 2015).

Pour autant, les trajectoires développementales sont hétérogènes. En effet, si le diagnostic de l'autisme est stable dans le temps, on observe une grande hétérogénéité entre les études (BIELENINIK et al., 2017). De plus, bien que l'expression du phénotype autistique tende, en moyenne, à diminuer de l'enfance à l'adolescence (WAIZBARD-BARTOV & MILLER, 2022), entre 20 % et 49 % des enfants avec un TSA présentent néanmoins une régression dans les domaines du langage ou de la communication sociale (WEBB & JONES, 2009). Cette évolution dépend alors de variables comme l'environnement ou la présence ou non de déficience intellectuelle (WAIZBARD-BARTOV & MILLER, 2022).

Ainsi, l'apparition précoce du phénotype autistique et son évolution avec l'âge invitent à s'intéresser à la population pédiatrique. Par ailleurs, la présence d'un éventail de caractéristiques aussi diversifiées dès les premiers stades soulève la question de leurs bases neurobiologiques. Quelles altérations cérébrales pourraient expliquer la diversité des manifestations observées chez les enfants avec TSA ?

2.2 Bases neuronales des TSA

Les bases neuronales des TSA peuvent être comprises non pas comme l'altération d'une région cérébrale unique, mais comme un ensemble d'anomalies fonctionnelles et morphologiques affectant le cerveau à une échelle globale. Sans prétendre à l'exhaustivité, nous présenterons ici un aperçu des connaissances actuelles afin de situer les altérations cérébrales susceptibles de sous-tendre les caractéristiques observées chez les enfants avec TSA.

2.2.1 Bases structurelles

Sur le plan structurel, les analyses de morphométrie voxel-à-voxel (VBM) mettent en évidence un ensemble d'altérations de la matière grise chez les personnes présentant un TSA. Il a notamment été rapporté des réductions de volume dans le cortex cingulaire antérieur et médio-préfrontal, dans l'insula ainsi que dans le cervelet postérieur (GUO et al., 2024). Ces anomalies sont souvent convergentes entre mesures fonctionnelles et morphologiques (PATRIQUIN et al., 2016). De plus, il a été mis en évidence des volumes plus faibles du putamen, de l'amygdale, du noyau accumbens et du pallidum. Ces différences sous-corticales semblent relativement stables au cours du développement, tandis que les altérations corticales tendent à s'atténuer à l'âge adulte (van ROOIJ et al., 2017).

2.2.2 Altérations fonctionnelles

En imagerie fonctionnelle, les études au repos montrent, chez les sujets autistes, notamment une tendance à une hypoactivation dans l'insula gauche, du cortex cingulaire antérieur et médial préfrontal (ACC/mPFC), ainsi que dans l'aire temporale inférieure droite, accompagnée d'une hyperactivation du précuneus et de l'aire motrice supplémentaire (GUO et al., 2024). Des altérations concernent également le *default mode network* (DMN), où la connectivité entre le cortex préfrontal et le cortex cingulaire postérieur/precuneus apparaît réduite chez les individus avec TSA, ce qui pourrait expliquer certains troubles dans la cognition sociale (SATO & UONO, 2019). Des anomalies comparables touchent aussi les régions du "cerveau social" hors DMN, notamment l'amygdale (SATO & UONO, 2019), dont la connectivité affaiblie avec le cortex préfrontal ventromédian est corrélée à la sévérité des symptômes socio-affectifs (KLEINHANS et al., 2015). On observe également une dépendance du profil d'activation en fonction du type de tâche mobilisée : les tâches non sociales montrent un recrutement anormal de l'ACC dorsal et de l'aire motrice supplémentaire, tandis que les tâches sociales révèlent par exemple une hypoactivation du cortex cingulaire postérieur (DI MARTINO et al., 2008).

Le chevauchement des différences neuronales avec des régions impliquées dans le contrôle moteur, telles que le cervelet, les ganglions de la base et le cortex préfrontal, pourrait expliquer les difficultés motrices fréquemment observées chez les sujets avec TSA. En effet, des lésions du cervelet pourraient perturber le contrôle proactif ou la coordination sensori-motrice (MANTO et al., 2012). De même, les ganglions de la base pourraient être liés à l'apparition de mouvements stéréotypés (GROENEWEGEN, 2003).

Ainsi, les données de neuroimagerie révèlent des caractéristiques neuronales distribuées plutôt que localisées, affectant des régions impliquées dans la cognition sociale, la régulation émotionnelle et le contrôle moteur. Le chevauchement de ces anomalies avec celles observées dans d'autres troubles du neurodéveloppement ou pathologies complexifie leur interprétation (GUO et al., 2024; LUKITO et al., 2020). Parmi les régions altérées, on retrouve de façon récurrente des structures en lien avec la motricité notamment le cervelet ou les ganglions de la base. Cette implication dans un trouble défini par des critères socio-cognitifs interroge la place des troubles moteurs dans le phénotype autistique. Alors, comment les connaissances issues des modèles cérébraux actuels s'intègrent-elles, ou non, dans les outils de diagnostic existants, et quelles en sont les limites ?

2.3 Diagnostic des TSA : outils, validité, et limites méthodologiques

Malgré la mise en évidence progressive de différences neuronales suggérant l'existence de marqueurs non seulement sociaux mais aussi moteurs chez les personnes présentant un TSA, la recherche et la pratique clinique se sont historiquement centrées sur les dimensions psycho-socio-cognitives du trouble (COOK, 2016). Pour autant, le diagnostic des TSA reste complexe en raison d'un chevauchement symptomatique (voir Section 2.1.2) et neuronal (voir Section 2.2.1) avec d'autres troubles du neurodéveloppement ou d'autres pathologies.

Actuellement, le diagnostic repose sur une évaluation clinique intégrant l'observation comportementale, l'histoire développementale et les informations parentales, selon un consensus pluridisciplinaire considéré comme le "gold standard" (HAS, 2018, p. 52; FALKMER et al., 2013; HIROTA & KING, 2023; RANDALL et al., 2018; WOOLFENDEN et al., 2012). Un nombre important d'outils standardisés pour assister le diagnostic ont été proposés (HAS, 2018, p. 51; FALKMER et al., 2013; RANDALL et al., 2018). Ainsi, aujourd'hui, les outils standardisés considérés comme la référence et les plus utilisés sont l'*Autism Diagnostic Interview, Revised* (ADI-R) et l'*Autism Diagnostic Observation Schedule, 2e édition* (ADOS-2) (FRIGAUX et al., 2019; HIROTA & KING, 2023).

2.3.1 Outils comportementaux de référence

L'ADOS-2 est un outil standardisé et semi-structuré d'observation directe, basé sur l'évaluation de la communication, l'interaction sociale, le jeu et les comportements répétitifs chez les personnes suspectées de TSA (LORD et al., 2012). Il se compose de 4 modules adaptés à l'âge et au niveau de langage de l'individu (LORD et al., 2012). L'ADI-R, quant à lui, prend la forme d'un entretien semi-structuré mené auprès des parents ou aidants d'enfants et d'adultes, portant sur la trajectoire développementale de l'individu (LORD et al., 1994).

Il convient alors de s'interroger sur la validité de ces outils diagnostiques : le statut de référence qui leur est attribué est-il justifié par leur validité ?

2.3.2 Validité et questionnement du statut de référence

Chez les enfants, l'ADI-R possède une sensibilité de l'ordre de 60 à 70 % et une spécificité d'environ 80 % (dos SANTOS et al., 2024 ; FULCERI et al., 2025 ; LEBERSFELD et al., 2021 ; RANDALL et al., 2018). Cependant, ces résultats cachent une incertitude très élevée, avec des plages de sensibilité s'étendant de 19 à 100 % et une spécificité comprise entre 50 % et 100 % (FULCERI et al., 2025 ; LEBERSFELD et al., 2021). L'ADOS-2 montre dans la même population une sensibilité légèrement plus importante, de l'ordre de 90 %, et une spécificité autour de 70-80 % avec incertitude notable mais plus faible que pour l'ADI-R (sensibilité : 77–100 % ; spécificité : 44–100 %) (FULCERI et al., 2025 ; LEBERSFELD et al., 2021).

En termes de fiabilité inter-juges, des accords élevés sont rapportés pour l'ADI-R, avec des taux compris entre 80 et 90 % (LORD et al., 1994 ; ZANDER et al., 2017). Il en va de même pour l'ADOS-2, bien que la fiabilité dépende fortement de l'expérience de l'évaluateur, avec des taux d'accord variant de 50 à 86 % selon les modules et l'expérience de l'évaluateur (KAMP-BECKER et al., 2018).

Un biais circulaire doit également être pris en compte : les études de validation de ces outils s'appuient généralement sur un diagnostic de référence posé par une équipe pluridisciplinaire, laquelle intègre déjà les résultats de l'ADOS/ADOS-2 et de l'ADI-R dans son évaluation.

Enfin, les performances varient aussi selon les profils cliniques : la spécificité de l'ADI-R peut, par exemple, tomber à 57 % chez les adultes sans déficience intellectuelle (ADAMOU et al., 2021). Ainsi, bien qu'efficaces, les outils standardisés sont sujets à une validité incertaine et hétérogène en fonction des populations. Cette hétérogénéité questionne la dépendance de ces outils à des normes développementales, mais aussi sociales, qu'il convient d'interroger.

2.3.3 Ancrage normatif des outils de diagnostic

Les outils de diagnostic possèdent un biais de genre marqué : les filles sont régulièrement sous-diagnostiquées (GUPTA et al., 2025 ; LAI et al., 2023 ; REA et al., 2023). Ce phénomène s'explique en partie par des facteurs socioculturels et par la construction genrée des outils et des critères diagnostiques. En effet, la plupart des tests ont été élaborés à partir de cohortes majoritairement masculines, et certains comportements typiques des TSA peuvent être socialement tolérés, voire valorisés, chez les filles (LAI et al., 2023). De plus, la difficulté d'application des outils standardisés auprès de populations présentant des particularités sensorielles, telles qu'une déficience visuelle ou auditive (HIROTA & KING, 2023), ou encore la nécessité de traduire ces outils et d'en valider ces traductions constituent des limites supplémentaires.

En outre, les outils actuellement utilisés pour le diagnostic des TSA présentent des biais qui conduisent à une sous-identification récurrente de certaines populations, notamment féminines, et une validité incertaine. Dans cette perspective, une approche fondée sur le contrôle moteur, en complément des outils actuellement utilisés, pourrait contribuer à réduire certains de ces biais. En effet, la motricité et notamment la motricité fine est moins susceptible d'être influencée par les différences de genre, de handicap, ou de contexte culturel que les interactions sociales. De plus, les altérations motrices observées chez les personnes autistes sont corrélées avec les caractéristiques centrales des TSA comme les difficultés sociales ou de communication (HOCKING & CAEYENBERGHS, 2017).

2.4 TSA et contrôle moteur : caractérisation de la motricité fine

Dès les premières étapes du développement, les enfants présentant un TSA montrent majoritairement des déficiences dans les évaluations standardisées du développement moteur, qu'il s'agisse de la motricité globale ou de la motricité fine (HOCKING & CAEYENBERGHS, 2017). Toutefois, tous les enfants avec TSA ne présentent pas nécessairement de déficiences motrices (HOCKING & CAEYENBERGHS, 2017). Ainsi, plutôt que de ne prendre en compte uniquement ces difficultés motrices, il apparaît pertinent d'examiner les particularités de la motricité globale comme fine chez les enfants avec TSA. Dans cette optique, nous faisons ici le choix de nous intéresser à la motricité fine, à travers l'étude des modèles de pointage, de saisie manuelle et d'écriture.

2.4.1 Pointage et saisie manuelle

La littérature met en évidence, chez les enfants présentant un TSA, une tendance à une augmentation du temps de mouvement lors des tâches de pointage et de saisie manuelle (BENCHEKRI, 2024; FORTI et al., 2011; GLAZEBROOK et al., 2006), bien que ce résultat ne soit pas systématiquement observé (PAPADOPOULOS et al., 2012; RINEHART et al., 2006), ainsi qu'une diminution de la fluidité du mouvement (BENCHEKRI, 2024). Alors, cette diminution de la vitesse pourrait être interprétée soit comme la cause d'une réduction de la fluidité du mouvement, soit, au contraire, comme sa conséquence, à l'image de ce qui a été observé chez des adultes atteints du syndrome parkinsonien (BENCHEKRI, 2024). De plus, il a été rapporté une augmentation du temps d'élaboration de la commande motrice (GLAZEBROOK et al., 2006; RINEHART et al., 2006), pouvant refléter un dysfonctionnement des ganglions de la base similaire à celui observé chez les patients parkinsoniens (RINEHART et al., 2006).

Il est important de noter que ces différences sont modulées par des variables de confusion, notamment le quotient intellectuel (QI) ou la complexité de la tâche (MARI et al., 2003). Ainsi, les enfants présentant un TSA associé à un QI plus faible que la moyenne tendent à exécuter les mouvements plus lentement que ceux ayant un QI plus élevé (MARI et al., 2003).

2.4.2 Écriture

Chez les enfants présentant un TSA, on peut retrouver des difficultés marquées dans l'écriture. On retrouve notamment une diminution de la lisibilité globale et une détérioration de la formation des lettres (HANDLE et al., 2022; KUSHKI et al., 2011). Au niveau moteur, l'écriture se caractérise par une vitesse d'exécution ralentie et une fluidité de mouvement plus faible (BENCHEKRI, 2024; HANDLE et al., 2022; KANGARANI-FARAHANI et al., 2024). Il peut être considéré que ces caractéristiques résulteraient notamment d'une altération de la coordination visuomotrice, les enfants présentant un TSA s'appuieraient en effet préférentiellement sur le feedback proprioceptif (BENCHEKRI, 2024; KANGARANI-FARAHANI et al., 2024; SHAFER et al., 2021).

Nous avons pu voir que des caractéristiques spécifiques de la motricité fine chez les enfants autistes sont mises en évidence au sein de tâches de pointage ou d'écriture, et ne se limitent pas aux déficits fonctionnels observés par les tests standardisés. Une approche consistant d'abord en une classification, puis en la détermination des profils moteurs, pourrait permettre une caractérisation plus fine de ces différences. Cette démarche contribuerait à la compréhension du phénotype moteur des TSA ainsi que des mécanismes neurofonctionnels sous-jacents. En effet, ces caractéristiques motrices, cohérentes avec les altérations des structures impliquées dans le contrôle moteur (voir Section 2.2), apparaissent

comme des manifestations potentiellement informatives du fonctionnement cérébral des TSA. Une description précise de ces profils moteurs pourrait ainsi favoriser l'identification de marqueurs pertinents, utiles tant pour améliorer le diagnostic précoce des TSA que pour approfondir la compréhension de ce trouble, en offrant la possibilité de repérer des profils neurofonctionnels équivalents. Dans cette perspective, la littérature récente mobilise des approches fondées sur l'apprentissage automatique pour, d'une part, caractériser la motricité fine des individus avec un TSA, et, d'autre part, classifier les profils neurotypiques de ceux des enfants présentant un TSA.

2.4.3 Apport des approches par apprentissage automatique

Classification en fonction de variables motrices

Tout d'abord, la littérature montre de manière convergente la faisabilité d'une classification des TSA par des approches d'apprentissage automatique appliquées à des tâches de motricité fine. Les précisions sont généralement comprises entre 70 et 90 % selon la tâche et le modèle utilisés, qu'il s'agisse de tâches d'imitation gestuelle au niveau de la main (LI et al., 2017 ; LIU et al., 2024 ; VABALAS et al., 2020), de saisie manuelle (CAVALLO et al., 2021 ; CRIPPA et al., 2015 ; FREUD et al., 2025 ; MILANO et al., 2023 ; SIMEOLI et al., 2021 ; SU et al., 2024), de dessin (EMANUELE et al., 2021), ou de pointage (ANZULEWICZ et al., 2016 ; DOCTOR et al., 2025 ; LUONGO et al., 2024).

Caractérisation de la motricité fine

Par ailleurs, les modèles issus de ces études mettent en évidence des différences dans les vitesses, accélérations et dans la variabilité des trajectoires et amplitudes, traduisant des mouvements moins fluides chez les enfants avec TSA (DOCTOR et al., 2025 ; LI et al., 2017 ; MILANO et al., 2023 ; SIMEOLI et al., 2021). Il a été proposé que les enfants avec TSA auraient une moindre dépendance au feedback sensoriel, en particulier visuel, et des stratégies de contrôle davantage en boucle ouverte (ANZULEWICZ et al., 2016 ; CRIPPA et al., 2015 ; EMANUELE et al., 2021), ce qui est cohérent avec les conclusions des études plus observationnelles (voir Sections 2.4.1, 2.4.2).

Pour autant, les approches par apprentissage statistique demeurent à un stade de preuve de concept (DOCTOR et al., 2025). Bien qu'il soit possible d'extraire de l'information pertinente pour la classification à partir de tâches de motricité fine, les variables de confusion, telles que l'âge ou la présence ou non de déficience intellectuelle, peuvent biaiser l'apprentissage des modèles et ne sont pas toujours prises en compte (CAVALLO et al., 2021). De plus, les échantillons étudiés sont souvent relativement faibles comparés au nombre de *features*, ce qui entraîne un risque de sur-apprentissage. Enfin et surtout, la validation d'une approche automatique reste limitée par une forte hétérogénéité méthodologique, tant au niveau des tâches que des *features* extraites, ce qui empêche la constitution d'un modèle entraîné sur un grand volume de données et donc pleinement généralisable.

Face à cette hétérogénéité, l'identification des variables motrices les plus caractéristiques permettrait d'orienter la collecte de données pour le développement d'outils diagnostics basés sur la motricité. De plus, dans une perspective de modélisation "utile", cela permettrait d'inférer les systèmes neuronaux sous-jacents impliqués, puis de formuler des hypothèses sur les TSA en s'appuyant sur les connaissances associées à ces systèmes. Par exemple, si les variables les plus discriminantes reflètent principalement des processus de planification, cela suggérerait une implication prédominante des ganglions de la base et permettrait de mobiliser les connaissances issues de la maladie de Parkinson pour mieux comprendre les mécanismes autistiques (RINEHART et al., 2006).

3 Problématique, objectifs et hypothèses

3.1 Problématique

La revue de la littérature met en évidence le besoin de mieux comprendre les TSA et de pouvoir les diagnostiquer précocement. Bien que l'on possède des connaissances sur les bases neuronales, la compréhension des TSA et les outils de diagnostic actuels restent largement imparfaits. En ce sens, une caractérisation de la motricité fine des TSA, notamment par des approches computationnelles, pourrait être une stratégie pertinente pour combler ces limites. Toutefois, ces approches ne sont pas cliniquement exploitées. Une limite majeure que l'on peut noter est l'hétérogénéité des variables mesurées et des tâches utilisées. Ainsi, déterminer les marqueurs moteurs les plus caractéristiques des TSA constituerait une avancée pour la compréhension et le diagnostic de ce trouble.

Nous nous proposons d'identifier, parmi un ensemble de tâches de motricité fine, les marqueurs moteurs les plus caractéristiques chez l'enfant avec TSA, dans l'objectif de mieux comprendre les altérations motrices associées et de contribuer, à titre exploratoire, au développement d'outils diagnostiques complémentaires à ceux utilisés aujourd'hui.

3.2 Objectifs

À l'aide d'analyses adaptées à un contexte de forte dimensionnalité, ce travail vise, d'une part, à améliorer la compréhension des TSA en reliant les marqueurs moteurs identifiés aux corrélats neuronaux décrits dans la littérature. D'autre part, il cherche à identifier une tâche ou un ensemble de variables de motricité fine présentant un fort pouvoir discriminant, afin d'évaluer l'existence de différents profils moteurs au sein de la population TSA. Cette approche pourrait constituer une base pour de futures études à plus large échelle, visant le développement d'outils de classification automatique en complément du diagnostic actuel.

3.3 Hypothèses

Sur la base de la littérature et des questionnements précédents, nous faisons l'hypothèse qu'il sera possible de classer les enfants présentant un TSA par rapport aux enfants neurotypiques (NT) avec une précision de l'ordre de 70 à 90 %, à partir de l'ensemble des variables motrices issues des différentes tâches, et ce, sans surapprentissage. Nous supposons par ailleurs qu'un sous-ensemble restreint, correspondant aux variables les plus discriminantes, sera suffisant pour classer les deux groupes avec des performances comparables à celles obtenues avec l'ensemble complet des marqueurs. Enfin, nous faisons l'hypothèse que les variables motrices les plus discriminantes présenteront des liens cohérents avec les corrélats neurophysiologiques décrits dans la littérature, principalement le cervelet et les ganglions de la base, et qu'elles seront donc majoritairement associées à la fluidité et à l'accélération du mouvement.

4 Matériel et méthodes

Les données analysées dans ce mémoire sont issues des travaux de la thèse de BENCHEKRI (2024), dont nous rappelons ici les éléments de protocole nécessaires à la compréhension de la démarche statistique.

4.1 Protocole expérimental

4.1.1 Population

L'étude a inclus des enfants âgés de 6 à 12 ans, répartis en deux groupes : des enfants avec un trouble du spectre de l'autisme (TSA) et des enfants à développement "typique" (TD). Pour les enfants TSA, le diagnostic a été validé cliniquement par les équipes médicales des structures partenaires où ils étaient suivis, et objectivé par un score seuil à l'ADI-R et/ou à l'ADOS.

4.1.2 Dispositif et tâches motrices

Le protocole comprenait des tâches organisées de la façon suivante : motricité fine, motricité globale, puis oculométrie. Parmi l'ensemble des tâches proposées, quatre étaient en lien avec la motricité fine et ont donc donné lieu aux variables analysées dans ce mémoire. Les données motrices ont été recueillies à l'aide d'une tablette graphique et d'un stylet (voir Annexe pour + de détails), sur quatre sites : Bordeaux, La Rochelle, Limoges, Poitiers.

Anticipation pointage

La tâche d'anticipation pointage (PA) consistait à pointer successivement deux cibles avec le stylet, en partant d'un carré de 0,5 cm de côté. La première cible, d'un diamètre de 2 cm, était présentée horizontalement à 10 cm de la zone de départ, à gauche ou à droite. La seconde cible était placée au-dessus de la première, à 14 cm de celle-ci, et pouvait présenter deux diamètres : 2 cm ou 0,5 cm, correspondant respectivement aux conditions facile et difficile (voir figure 4.1).




FIGURE 4.1 – Configuration expérimentale pour la réalisation de la tâche d'Anticipation Pointage. La première cible pouvait apparaître à droite ou à gauche. La seconde cible est ici représentée en condition difficile (cible petite). N'est pas à l'échelle.

Anticipation écriture

La tâche d'anticipation écriture (*ll_ln*) consistait à recopier avec le stylet et par-dessus un modèle, deux digrammes (*ll* et *ln*) présentés en écriture cursive, sans espace entre les deux lettres (voir figure 4.2).



FIGURE 4.2 – Représentation des visuels utilisés pour la réalisation de la tâche d'Anticipation Ecriture

Isochronie

Pour la tâche d'isochronie (*Epow*), le participant devait recopier, avec le stylet et par-dessus un modèle, la lettre *e* selon cinq tailles différentes. Pour chaque taille, cinq essais consécutifs étaient réalisés avant de passer à la taille suivante (voir figure 4.3).




FIGURE 4.3 – Représentation des visuels utilisés pour la réalisation de la tâche d'isochronie. Pour chaque taille, 5 essais étaient réalisés. N'est pas à l'échelle.

Pointage simple

La tâche de Pointage simple (*PS_lin*) correspondait à une tâche de Fitts. Le participant devait pointer une cible avec le stylet dès son apparition, le plus rapidement possible et sans lever le stylet, en partant d'un carré de 0,5 cm de côté. Quatre niveaux de difficulté ont été définis par l'indice de difficulté ID, calculé selon la formule suivante :

$$ID = \log_2 \left(\frac{2A}{w} \right)$$

où *A* désigne la distance à parcourir et *w* la largeur de la cible. Les paramètres associés à chaque niveau de difficulté sont présentés dans le tableau 4.1.

ID	Distance <i>A</i> (cm)	Taille <i>w</i> (cm)
3	8	2
4	16	2
5	8	0,5
6	16	0,5

TABLE 4.1 – Paramètres utilisés lors de la tâche de Fitts

4.2 Description du jeu de données

Les données ont été collectées sur quatre sites cliniques à l'aide d'un système de capture de mouvement Vicon (+ ref). Au total, 66 enfants TSA et 62 enfants TD ont été rencontrés. Après traitement des données, le jeu de données final retenu pour les analyses comprend 45 enfants TSA et 49 enfants TD.

À partir des enregistrements issus des quatre tâches, 142 variables motrices ont été extraites, auxquelles s'ajoutent l'âge et le sexe de chaque enfant, soit 144 variables prédictives (*features*) au total. Ces variables se répartissent en trois catégories : des variables directes ? (distances, vitesses...), des variables dérivées (SPARC, curve index...) et des variables spécifiques aux tâches (indice d'isochronie, pente de la loi de Fitts...). Une description complète de l'ensemble des variables est disponible en annexe ANNEXE.

Le ratio variables/observations ($D/n = 144/94 \approx 1.5$) est supérieur à 1. L'analyse statistique est donc dans un cas de grande dimension + citation fléau de la dimensionnalité ?. Ce constat motive le recours à un cadre régularisant pour déterminer les variables les plus caractéristiques.

4.3 Cadre de l'inférence bayésienne

L'inférence bayésienne repose sur le théorème de Bayes, qui exprime la distribution *a posteriori* des paramètres θ du modèle conditionnellement aux données observées y :

$$p(\theta | y) \propto p(y | \theta) p(\theta)$$

où $p(y | \theta)$ désigne la vraisemblance des données et $p(\theta)$ la distribution *a priori* sur les paramètres. Contrairement à l'approche fréquentiste (cadre "classique"), les paramètres ne sont pas estimés ponctuellement mais caractérisés par une distribution de probabilité, qui quantifie explicitement l'incertitude sur leurs valeurs. L'inférence porte ainsi sur $p(\theta | y)$ et non sur la probabilité des données sous l'hypothèse nulle. Il est important de noter que les probabilités sont ici considérées de façon *épistémique* : elles modélisent l'incertitude des paramètres et non leur fréquence.

Les approches fondées sur les tests d'hypothèse nulle (NHST) et le seuil de significativité $p < 0.05$ font l'objet de critiques méthodologiques majeures (AMRHEIN et al., 2019 ; IOANNIDIS, 2005). Elles encouragent notamment le raisonnement binaire, entraînent une inflation des erreurs de type I et ne permettent pas de quantifier l'incertitude sur les paramètres d'intérêt. Dans le contexte de ce mémoire où $p > n$, on s'attend à une grande incertitude sur les paramètres et à un risque important d'erreurs de type I dans un cadre fréquentiste.

Ainsi, une méthodologie bayésienne lève ces limitations en fournissant une distribution de probabilité complète par paramètre, en s'affranchissant du problème des comparaisons multiples (GELMAN et al., 2009) et en intégrant la régularisation via les distributions *a priori* (voir section 4.6.2).

En pratique, la distribution *a posteriori* n'est pas calculable analytiquement dans le cas général. Elle est approchée par simulation via des méthodes de Monte Carlo par chaînes de Markov (MCMC), qui permettent d'approximer la distribution de $p(\theta | y)$ en obtenant des échantillons de celle-ci. Une limite importante de la méthodologie appliquée est donc le coût computationnel qui est supérieur aux approches fréquentistes classiques, bien que les implémentations actuelles rendent ce coût élevé mais acceptable pour les dimensions considérées ici.

4.4 Cadre interprétatif de la sélection

La sélection de variables est réalisée selon un critère prédictif (voir section 4.7.2) : une variable est considérée comme informative si sa présence dans le modèle améliore la capacité à prédire l'appartenance au groupe TSA ou TD sur de nouvelles observations. Nous considérerons que si une variable est prédictive, alors elle reflète une caractéristique motrice différenciant les deux groupes sans que cela constitue une preuve de causalité. Ainsi, si un sous-ensemble de variables prédit aussi bien que le modèle complet, les variables exclues sont soit du bruit, soit redondantes, c'est-à-dire qu'elles partagent une information mutuelle élevée¹ avec les variables déjà sélectionnées sans pour autant être du bruit. La redondance n'est pas limitée aux relations linéaires d'ordre 1 (corrélation) : des dépendances non-linéaires entre variables peuvent également conduire à l'exclusion d'une variable par ailleurs pertinente.

Ces considérations impliquent que la liste des variables sélectionnées constitue un point de départ pour l'exploration clinique et expérimentale et non un ensemble exhaustif ou définitif de marqueurs du TSA.

4.5 Prétraitement des données

Trois sujets présentant des valeurs manquantes ont été exclus de l'analyse. Un sujet supplémentaire a été exclu sur la base d'un critère de valeur aberrante : toute observation présentant un score $|z| > 5$ sur au moins une variable était candidate à l'exclusion. L'exclusion a été confirmée après vérification en unités naturelles et examen du contexte de la tâche. Au total, 90 sujets ont donc été retenus pour l'analyse.

L'ensemble des variables a ensuite été centré et réduit (moyenne et écart-type estimés sur l'échantillon), de façon à les ramener à une échelle commune. Cette normalisation repose sur des estimateurs fréquentistes, ce qui constitue une légère entorse à la cohérence bayésienne stricte mais était néanmoins nécessaire pour l'application de distributions a priori régularisantes comparables entre coefficients (voir section 4.6.2).

4.6 Modèle de référence

4.6.1 Régression logistique bayésienne

Le modèle de référence est une régression logistique bayésienne. La variable à prédire $y_i \in \{0, 1\}$ indique l'appartenance de l'individu i au groupe TSA ($y_i = 1$) ou TD ($y_i = 0$). Le modèle est défini tel que :

1. Au sens de la théorie de l'information, l'information mutuelle entre deux variables aléatoires X et Y est définie par :

$$I(X; Y) = H(X) + H(Y) - H(X, Y)$$

où H désigne l'entropie de Shannon. Elle mesure la quantité d'information partagée entre X et Y , et vaut zéro si et seulement si X et Y sont indépendantes.

$$y_i \sim \text{Bernoulli}(\pi_i), \quad i = 1, \dots, n$$

$$\text{logit}(\pi_i) = \alpha + \sum_{j=1}^D \beta_j x_{ij}, \quad j = 1, \dots, D$$

où $\pi_i = P(y_i = 1 \mid x_i)$ est la probabilité d'appartenir au groupe TSA, α l'ordonnée à l'origine, β_j le coefficient associé à la variable x_{ij} , et D le nombre total de variables. La fonction logit, définie par $\text{logit}(\pi) = \log(\pi/(1 - \pi))$, assure que $\pi_i \in]0, 1[$. Géométriquement, le modèle définit un hyperplan qui sépare les groupes TD et TSA dans l'espace des *features* dont la distance signée détermine la probabilité d'appartenance à chaque groupe.

4.6.2 Spécification des priors

Dans le cadre bayésien, les distributions a priori peuvent jouer un rôle analogue à la régularisation en statistique fréquentiste : elles contraignent les coefficients vers zéro en l'absence de signal suffisant dans les données. Un prior gaussien centré correspond à une pénalité ridge (L_2) tandis qu'un prior laplacien correspond à une pénalité lasso (L_1). Ces deux approches présentent cependant des limitations dans le régime $p > n$: le prior gaussien écrase uniformément tous les coefficients sans produire de sparsité (coefficient à 0), tandis que le prior laplacien tend à trop contraindre les effets importants.

Le prior *Regularized Horseshoe* (RHS) (PIIRONEN & VEHTARI, 2017) est proposé pour dépasser ces limites dans un cadre bayésien, pour les problèmes de sélection de variables en grande dimension. Il repose sur une décomposition en deux niveaux de régularisation :

$$\begin{aligned} \beta_j &\sim \mathcal{N}(0, \tau^2 \tilde{\lambda}_j^2) \\ \tilde{\lambda}_j^2 &= \frac{c^2 \lambda_j^2}{c^2 + \tau^2 \lambda_j^2} \\ \lambda_j &\sim \text{C}^+(0, 1), \quad \tau \sim \text{C}^+(0, \tau_0) \\ c^2 &\sim \text{Inv-Gamma}\left(\frac{\nu}{2}, \frac{\nu s^2}{2}\right) \end{aligned}$$

où C^+ désigne la distribution demi-Cauchy. Le paramètre τ joue le rôle de *shrinkage global* : il pousse l'ensemble des coefficients vers zéro. Le paramètre λ_j joue le rôle de *shrinkage local* : il permet aux coefficients présentant un signal suffisant d'échapper à cet écrasement. Le terme c^2 , issu d'une distribution Inverse-Gamma de paramètres $(\nu/2, \nu s^2/2)$ avec $\nu = 4$ et $s = 2$ (valeurs recommandées par PIIRONEN et VEHTARI, 2017), régularise les coefficients importants en bornant leur variance *a priori*.

L'hyperparamètre τ_0 , qui calibre le shrinkage global en fonction de la sparsité attendue, est défini par :

$$\tau_0 = \frac{p_0}{D - p_0} \frac{\sigma}{\sqrt{n}}$$

où p_0 est le nombre de variables a priori supposées prédictives, D le nombre total de variables, n la taille d'échantillon, et σ une facteur d'échelle dans le cadre de la régression logistique. Conformément aux recommandations de PIIRONEN et VEHTARI (2017) pour la régression logistique, σ est fixé à 2. Nous posons $p_0 = 10$, reflétant l'hypothèse que seul un petit nombre de variables parmi les $D = 144$

est suffisant pour discriminer les deux groupes. Ce choix est exploratoire et sa sensibilité est évaluée dans la section 4.9.

L’intercept α reçoit un prior Student-t peu informatif, centré en zéro :

$$\alpha \sim \text{Student-t}(\nu = 7, \mu = 0, \sigma = 2.5)$$

4.6.3 Critères de validité du modèle

La performance prédictive du modèle est évaluée par validation croisée *leave-one-out* (LOO-CV), approchée par l’estimateur PSIS-LOO (VEHTARI et al., 2015). Il estime l’*expected log pointwise predictive density* (elpd), définie telle que :

$$\text{elpd}_{\text{loo}} = \sum_{i=1}^n \log p(y_i | y_{-i})$$

où $p(y_i | y_{-i})$ désigne la probabilité assignée par le modèle ajusté sur les $n - 1$ observations restantes à la vraie classe de l’observation i . L’elpd est donc la somme des log-probabilités prédites pour chaque observation mise de côté tour à tour : plus elle est élevée, meilleure est la capacité du modèle à généraliser à de nouvelles données. L’elpd constitue le critère principal de comparaison entre modèles.

La fiabilité de l’approximation PSIS-LOO est contrôlée par les diagnostics $\hat{k}$ de Pareto : pour chaque observation i , un $\hat{k} > 0.7$ signale que l’approximation est peu fiable pour cette observation et que l’estimation de l’elpd doit être interprétée avec précaution (VEHTARI et al., 2015).

La précision de classification (*accuracy*, `pctcorr` dans `projpred`) est rapportée comme critère complémentaire pour faciliter l’interprétation clinique des résultats. Elle est définie comme la proportion d’observations correctement classées, la classe prédite étant celle de probabilité maximale selon le modèle (PIIRONEN et al., 2025).

4.6.4 Diagnostics MCMC

Il est nécessaire de vérifier la convergence des chaînes avant toute inférence. Quatre chaînes de chacune 4000 itérations ont été simulées, dont 2000 de préchauffage (*warmup*), soit 8000 échantillons post-warmup au total. La convergence est évaluée par le critère $\hat{R}$ de Gelman-Rubin. Une valeur $\hat{R} < 1.01$ et une taille d’échantillon effective > 400 pour l’ensemble des paramètres sont retenues comme seuil de convergence (VEHTARI et al., 2019). Ces diagnostics sont complétés par un examen visuel des traceplots, des graphiques d’autocorrélation et des distributions marginales *a posteriori* (histogrammes et densités).

4.6.5 Vérifications prédictives (*Predictive Checks*)

Enfin, la validité du modèle a été évaluée par des vérifications prédictives (*Predictive Checks*). Un *Prior Predictive Check* a d’abord permis de s’assurer que les distributions *a priori* ne contraignaient pas le modèle vers des prédictions extrêmes avant l’observation des données. Après ajustement, un *Posterior Predictive Check* a été réalisé en comparant la distribution des données observées aux données simulées par le modèle. Le *Posterior Predictive Check* montre que le modèle reproduit la proportion des classes (TSA/TD) sans pour autant présenter une certitude extrême et évite ainsi le surapprentissage. Les graphiques sont présentés en Annexe XXX.

4.7 Sélection par projection prédictive

4.7.1 Principe de cv varsel

La sélection par projection prédictive (PIIRONEN et al., 2018) est une méthode de sélection de variables en fonction d'un modèle de référence, ici le modèle logistique bayésien complet ajusté sur l'ensemble des variables. Ce modèle constitue un plafond de performance prédictive : l'objectif est d'identifier le sous-modèle le plus parcimonieux dont la performance prédictive n'est pas inférieure à celle du modèle de référence (voir section 4.7.2 pour le critère de sélection).

Le modèle de référence est d'abord ajusté sur l'ensemble des données et sa distribution *a posteriori* est obtenue par MCMC. Une recherche forward est ensuite conduite : les variables sont ajoutées une à une au sous-modèle, en sélectionnant à chaque étape la variable qui minimise la divergence de Kullback-Leibler² entre les prédictions du sous-modèle projeté et celles du modèle de référence. La projection consiste à trouver, pour chaque taille de sous-modèle, les paramètres qui reproduisent au mieux le comportement prédictif du modèle de référence. Une fois le sous-modèle sélectionné, une inférence finale est conduite sur ce sous-modèle restreint.

La performance prédictive de chaque sous-modèle est évaluée par `cv_varsel` avec `validate_search = TRUE` (PIIRONEN et al., 2025). Une LOO-CV est réalisée dans laquelle, à chaque fold, la recherche forward est réappliquée sur les $n - 1$ observations d'entraînement. La performance à chaque étape (chaque *fold* de LOO-CV pour chaque taille de sous-modèle k testée) est définie par l'elpd approximé par PSIS-LOO. La performance finale du sous-modèle sélectionné est évaluée sur l'observation exclue. La fréquence à laquelle une variable est incluse dans le sous-modèle de taille k à travers les folds permet de constituer une mesure de stabilité de la sélection.

4.7.2 Critère de sélection

Le critère principal de sélection est l'elpd estimé par PSIS-LOO (voir section 4.6.3). Pour chaque taille de sous-modèle k , l'écart à la performance du modèle de référence est quantifié par la différence $\Delta\text{elpd}_k = \text{elpd}_k - \text{elpd}_{ref}$ négative ou nulle par construction. La taille du sous-modèle retenu est déterminée principalement par la règle des $1\widehat{SE}$ (erreur standard) (PIIRONEN et al., 2018) : le sous-modèle le plus parcimonieux tel que $|\Delta\text{elpd}_k| \leq \widehat{SE}(\Delta\text{elpd}_k)$, c'est-à-dire dont l'écart au modèle de référence reste inférieur à son erreur standard estimée. Ce critère est confirmé visuellement par le critère du coude sur la courbe Δelpd_k et par la stabilité de sélection des variables. La précision est également rapportée mais la sélection de modèle est décidée par l'application des critères sur l'elpd.

4.8 Screening par comparaison de modèles et sélection sur la tâche PA

L'application de la sélection par projection prédictive sur le modèle global (144 variables) se heurte à une incertitude élevée sur l'estimation de l'elpd liée au ratio D/n important. En l'absence de coude

2. La divergence de Kullback-Leibler, notée D_{KL} , est souvent décrite comme une mesure de la distance entre deux distributions de probabilité. Formellement, avec P et Q des densités de probabilité :

$$D_{KL}(P||Q) = \int p(x) \log \frac{p(x)}{q(x)} dx$$

net dans la courbe Δelpd_k , il n'est pas possible d'identifier un sous-ensemble de variables de manière fiable à partir du modèle complet (voir section 5.1).

Pour contourner cette limite, le modèle global est décomposé en quatre sous-modèles de référence, un par tâche motrice (PA, ll_ln, Epow, PS_lin). Chaque sous-modèle est ajusté indépendamment avec le même prior RHS et la même procédure MCMC que le modèle global, à l'exception de $p_0 = 5$, ce qui reflète le moindre nombre de variables (τ_0 recalculé en fonction, voir section 4.6.2). La performance prédictive de chaque sous-modèle est estimée par PSIS-LOO et les $\hat{k}$ de Pareto sont rapportés pour chaque modèle. La comparaison des elpd entre sous-modèles et avec le modèle global est conduite par `loo_compare` (VEHTARI et al., 2025); ces modèles n'étant pas nichés, cette comparaison est indicative et non un test formel.

La tâche PA présente un elpd dont l'écart au modèle global reste inférieur à $1\widehat{SE}$ (voir section 5.3.1), ce qui satisfait le critère de sélection défini en section 4.7.2. Elle est donc retenue comme tâche candidate pour la sélection par projection prédictive, son sous-modèle constituant le nouveau modèle de référence ($D_{\text{PA}} = 24$).

4.9 Analyse de sensibilité

La sensibilité des résultats au choix de p_0 a été évaluée en réajustant le modèle de référence complet ($D = 144$) avec trois valeurs : $p_0 \in \{5, 10, 20\}$, et le modèle de référence PA ($D = 24$) avec $p_0 \in \{3, 5, 10\}$. Pour chaque valeur, τ_0 est recalculé en conséquence (voir section 4.6.2) et la procédure `cv_varsel` est réappliquée. La stabilité des variables sélectionnées, de la taille du sous-modèle retenu et des coefficients des variables sont examinées pour chacun des scénarios.

4.10 Environnement logiciel

Les analyses ont été conduites sous R version 4.5.3 (R CORE TEAM, 2026). Le modèle bayésien a été ajusté par l'algorithme de Monte Carlo hamiltonien implémenté dans `rstanarm` (version 2.32.1) (GOODRICH et al., 2025). La sélection par projection prédictive a été conduite avec le package `projpred` (version 2.10.0.9000) (PIIRONEN et al., 2025). La validation croisée LOO et les diagnostics $\hat{k}$ de Pareto ont été calculés avec le package `loo` (version 2.9.0.9000) (VEHTARI et al., 2025). La reproductibilité des résultats est assurée par une graine aléatoire (123). La robustesse du modèle de référence a été confirmée en vérifiant la stabilité des résultats avec une graine alternative (1234).

5 Résultats

5.1 Sélection sur le modèle global : limites de l'approche

5.1.1 Courbe elpd et sélection des variables

La procédure `cv_varsel` a été appliquée sur le jeu de données complet, avec un nombre maximum de variables fixé à $n = 15$. Ce plafond a été validé en répétant la procédure avec $n = 25$, qui ne produit pas d'amélioration supplémentaire ni de l'elpd ni de l'accuracy.

La courbe elpd (figure 5.1) présente une première difficulté d'interprétation. En effet, selon le critère strict de l'erreur standard, le modèle à une seule variable est statistiquement équivalent au modèle complet, en raison d'une incertitude élevée sur les différences d'elpd. L'examen visuel de la courbe et les taux de sélection par *fold* suggèrent néanmoins de retenir quatre variables, sélectionnées avec une stabilité respective de 0.99, 0.91, 0.97 et 0.93 (voir annexe XXX pour le détail par variable).




FIGURE 5.1 – Courbes de l'elpd et de l'accuracy issues du modèle de référence global, en fonction du nombre de variables incluses dans le sous-modèle, obtenue par projection prédictive avec validation croisée. Chaque point représente la différence d'elpd/d'accuracy entre le sous-modèle et le modèle de référence. Les barres d'erreur indiquent l'incertitude à ± 1 erreur standard. Une différence proche de zéro indique des performances prédictives équivalentes au modèle de référence global.

Le sous-modèle à quatre variables retenu est `L2_large`, `Sparc_small`, `Sparc2` et `pT2Pv6`. `L2_large` correspond à la distance parcourue de la première à la seconde cible lors de la tâche PA en condition "facile" (cible large). `Sparc_small` et `Sparc2` sont des mesures de SPARC (*Spectral Arc Length*, mesure

de fluidité) mesurée lors de la tâche PA et Epow, respectivement. Enfin, pT2Pv6 correspond au temps pour atteindre le pic de vitesse (*time to peak*) mesuré lors de la tâche PS avec ID = 6.

Les estimations *a posteriori* sont présentées dans le table 5.1 pour les valeurs quantitatives et la figure 5.2 pour la distribution qualitatives des courbes de densité. Si la taille d'effet reste toujours très incertaine, la probabilité de direction est très forte pour chacune des 4 variables sélectionnées ce qui indique une faible incertitude quant au signe des effets.

Les performances prédictives du sous-modèle sont comparables à celles du modèle de référence (sous-modèle vs référence ; elpd : -54.61 vs -57.52 , accuracy : 0.678 vs 0.656). La matrice de confusion montre une classification modérée, avec 13 faux négatifs et 12 faux positifs sur 90 observations. L'accuracy globale restant inférieure au seuil de 0.70 , la capacité prédictive du modèle de référence est elle-même limitée, ce qui invite à la prudence dans l'interprétation des variables sélectionnées. Par ailleurs, le modèle ne montre pas de signe de surapprentissage.




FIGURE 5.2 – Distributions *a posteriori* des coefficients de régression du sous-modèle à quatre variables à partir du modèle de référence global. Pour chaque paramètre, la barre verticale bleue indique la médiane *a posteriori* et la zone bleue représente l'intervalle de crédibilité à 95 % ($IC_{95\%}$). Conditionnellement au modèle et aux données, la valeur du paramètre a 95 % de chance de se situer dans cet intervalle.

	Médiane	$IC_{95\%}$	$P(\beta_j < 0)$	$P(\beta_j > 0)$
Intercept	0.035	$[-0.468 ; 0.541]$	0.443	0.558
L2_large	-0.738	$[-1.442 ; -0.018]$	0.978	0.023
Sparc_small	-0.400	$[-1.137 ; 0.020]$	0.970	0.030
Sparc2	-0.392	$[-1.201 ; 0.059]$	0.955	0.045
pT2Pv6	0.216	$[-0.095 ; 0.898]$	0.130	0.870

TABLE 5.1 – Estimations *a posteriori* des coefficients du sous-modèle à quatre variables à partir du modèle de référence global. La médiane et l'intervalle de crédibilité à 95 % ($IC_{95\%}$) résument la distribution *a posteriori* de chaque coefficient ; $P(\beta_j < 0)$ et $P(\beta_j > 0)$ indiquent la probabilité *a posteriori* que le coefficient soit négatif ou positif, respectivement (probabilité de direction).

5.1.2 Diagnostics MCMC et approximation PSIS-LOO

Les diagnostics MCMC à travers les *traceplots*, les fonctions d'autocorrélation, les histogrammes et les distributions marginales (figure 5.3) ne révèlent pas de problème majeur de convergence. Néanmoins, les *traceplots* montrent des pics ponctuels vers des valeurs extrêmes. Ce comportement peut être attendu avec un prior horeshoe en situation d'incertitude, ses queues lourdes autorisant l'exploration de grandes valeurs de coefficients. L'ensemble des paramètres affiche un $\hat{R}$ inférieur à 1.01 et une taille effective d'échantillon > 400 .




FIGURE 5.3 – Exemple de diagnostics MCMC illustrés pour le paramètre `L2_large`, sélectionné à partir du modèle global. De gauche à droite et de haut en bas : (1) *traceplot* des chaînes, un bon mélange est souhaité et se traduit par des chaînes entrelacées, similaires à un bruit blanc ; (2) fonction d'autocorrélation, une décroissance rapide vers zéro est souhaitée, ce indique une faible dépendance entre échantillons successifs ; (3) histogramme de la distribution *a posteriori*, il doit contenir assez d'informations pour approximer la densité ; (4) courbe de densité estimée *a posteriori*, l'axe x de l'histogramme et de la courbe de densité est exprimé en taille d'effet standardisée.

Concernant l'approximation PSIS-LOO, 9 observations présentent un $\hat{k}$ de Pareto supérieur à 0.7 (environ 10 % des observations), seuil au-delà duquel l'estimation PSIS est considérée peu fiable pour l'observation concernée (VEHTARI et al., 2015). Ce résultat invite à interpréter les valeurs d'elpd avec prudence.

5.1.3 Sensibilité au prior (p_0)

Afin d'évaluer l'influence du prior sur les résultats, deux valeurs alternatives du paramètre p_0 ont été testées et comparées à la valeur de référence.

Les trois configurations conduisent à la sélection des mêmes quatre variables, dans le même ordre, avec des stabilités par *fold* comparables. Les estimations *a posteriori* des coefficients sont stables. Exprimés en fraction de la largeur de l'intervalle de crédibilité à 95 % du modèle de référence, les écarts normalisés δ_{norm} restent inférieurs à 10 % pour l'ensemble des paramètres et des deux valeurs

alternatives testées (tableau 5.2). Les signes et ordres de grandeur des effets sont identiques dans toutes les configurations.

	$\hat{\beta}_{\text{ref}}$	$\hat{\beta}_{p_0=5}$	$\delta_{\text{norm}}(\%)$	$\hat{\beta}_{p_0=20}$	$\delta_{\text{norm}}(\%)$
Intercept	0.035	0.016	1.9	0.041	0.6
L2_large	-0.738	-0.732	0.4	-0.754	1.1
Sparc_small	-0.400	-0.343	4.9	-0.493	8.0
Sparc2	-0.392	-0.272	9.5	-0.469	6.1
pT2Pv6	0.216	0.143	7.3	0.325	10.9

TABLE 5.2 – Analyse de sensibilité des estimations *a posteriori* au choix du paramètre p_0 du prior horseshoe. $\hat{\beta}_{\text{ref}}$ désigne la médiane *a posteriori* du modèle de référence ($p_0 = 10$); δ_{norm} est l'écart normalisé en fonction de l'intervalle de crédibilité, tel que $\delta_{\text{norm}} = |\hat{\beta}_{p_0} - \hat{\beta}_{\text{ref}}| / (\text{largeur IC}_{95\%}^{\text{ref}}) \times 100$

Sur le plan prédictif, les performances sont stables. Les valeurs d'elpd et d'accuracy du modèle de référence et du sous-modèle restent du même ordre quelque soit la valeur de p_0 . On note toutefois qu'avec $p_0 = 20$, l'accuracy du sous-modèle (0.689) est supérieure à celle du modèle de référence (0.667), tandis que les valeurs d'elpd demeurent proches. À l'inverse, avec $p_0 = 5$, les deux métriques convergent et les estimations des coefficients sont légèrement plus faibles. Cela indique une régularisation plus forte. La configuration $p_0 = 10$ semble donc être un compromis satisfaisant.

5.2 Screening par tâche motrice

La comparaison des modèles par tâche motrice via LOO-CV (voir figure 5.4) indique que le modèle restreint à la tâche PA est statistiquement équivalent au modèle complet ($\Delta\text{elpd} = -2.21$, $\widehat{SE} = 3.21$) selon le critère de l'erreur standard sur la différence d'elpd, tout en reposant sur un espace de variables nettement plus faible. En effet, le modèle PA présente un p_{loo} (nombre de paramètres effectifs) plus faible que le modèle complet (8.08 vs 23.84), ce qui indique un modèle plus parcimonieux.

Les modèles fondés sur les tâches Epow, ll_ln et PS_lin affichent des performances inférieures, avec des différences d'elpd qui excèdent leur erreur standard respective (voir figure 5.4).

Ces résultats sont cohérents avec ceux de la section précédente, où les deux premières variables sélectionnées (L2_large, Sparc_small) sur le modèle complet appartenaient déjà à la tâche PA. La projection prédictive est donc conduite dans un second temps en restreignant l'espace des variables à cette seule tâche.

5.3 Sélection sur la tâche PA

5.3.1 Courbe elpd et sélection des variables

La projection prédictive appliquée aux variables de la tâche PA conduit à la sélection de deux variables, L2_large et Sparc_small, retenues avec une stabilité de 0.99 chacune sur l'ensemble des *folds* (voir annexe XXX). Le critère de l'erreur standard, la stabilité de sélection et le coude de la courbe elpd (figure 5.5) convergent vers $k_{\text{opt}} = 2$. Il est important de noter que ces deux variables correspondent aux deux premières retenues lors de la sélection sur le modèle global (section 5.1).

Les performances prédictives du sous-modèle sont comparables à celles du modèle de référence PA (sous-modèle vs référence; elpd : -52.82 vs -55.28 , accuracy : 0.700 vs 0.700). La matrice de confusion indique 15 faux négatifs et 11 faux positifs sur 90 observations. Ces performances sont légèrement




FIGURE 5.4 – Comparaison des modèles par tâche selon l’elpd estimé par LOO-CV. Chaque point représente la différence d’elpd entre le modèle considéré et le meilleur modèle (PA, fixé à 0) ; les barres d’erreur indiquent ± 1 erreur standard sur cette différence. Une différence dont l’intervalle d’erreur standard chevauche zéro indique des performances prédictives statistiquement équivalentes au modèle issu de la tâche PA. Le modèle global (Full) est donc statistiquement équivalent à celui de la tâche PA.

supérieures à celles obtenues sur le modèle global (section 5.1), ce qui suggère que la restriction de l’espace des variables à la tâche PA réduit le bruit introduit par des variables peu informatives. On notera que l’elpd du sous-modèle est légèrement supérieur à celui du modèle de référence (figure 5.5), ce qui peut refléter la régularisation induite par la réduction du modèle.

Les estimations des coefficients *a posteriori*, conditionnellement au modèle et aux données, sont présentées dans le tableau 5.3 et la figure 5.6. Les deux coefficients sont négatifs, avec des médianes respectivement de -0.883 et -0.502 , et une incertitude réduite sur le signe des effets malgré une incertitude importante sur leur taille. Ces estimations sont proches de celles obtenues lors de la sélection sur le modèle complet, avec des écarts relatifs sur les médianes de 16 % pour `L2_large` et 20 % pour `Sparc_small`.

	Médiane	IC _{95%}	$P(\beta_j < 0)$	$P(\beta_j > 0)$
Intercept	-0.011	$[-0.463; 0.463]$	0.52	0.48
L2_large	-0.883	$[-1.524; -0.076]$	0.99	0.01
Sparc_small	-0.502	$[-1.169; -0.028]$	0.97	0.03

TABLE 5.3 – Estimations *a posteriori* des coefficients du sous-modèle à deux variables à partir du modèle de référence PA. La médiane et l’intervalle de crédibilité à 95 % (IC_{95%}) résument la distribution *a posteriori* de chaque coefficient ; $P(\beta_j < 0)$ et $P(\beta_j > 0)$ indiquent la probabilité *a posteriori* que le coefficient soit négatif ou positif, respectivement (probabilité de direction).




FIGURE 5.5 – Courbes de l’elpd et de l’accuracy issues du modèle de référence PA, en fonction du nombre de variables incluses dans le sous-modèle, obtenue par projection prédictive avec validation croisée. Chaque point représente la différence d’elpd/d’accuracy entre le sous-modèle et le modèle de référence. Les barres d’erreur indiquent l’incertitude à ± 1 erreur standard. Une différence proche de zéro indique des performances prédictives équivalentes au modèle de référence.




FIGURE 5.6 – Distributions *a posteriori* des coefficients de régression du sous-modèle à deux variables à partir du modèle de référence PA. Pour chaque paramètre, la barre verticale bleue indique la médiane *a posteriori* et la zone bleue représente l’intervalle de crédibilité à 95 % ($IC_{95\%}$). Conditionnellement au modèle et aux données, la valeur du paramètre a 95 % de chance de se situer dans cet intervalle.

5.3.2 Diagnostics MCMC et approximation PSIS-LOO

Les diagnostics MCMC (figure 5.7) ne révèlent pas de problème de convergence et l’ensemble des paramètres affiche un $\hat{R} < 1.01$ ainsi qu’une taille effective d’échantillon > 400 .

L’approximation PSIS-LOO est fiable pour l’ensemble des observations. Aucun $\hat{k}$ de Pareto ne

dépasse le seuil de 0.7, ce qui contraste avec les résultats obtenus sur le modèle global et renforce la confiance dans les estimations d'elpd utilisées pour la sélection avec le modèle de référence PA.




FIGURE 5.7 – Exemple de diagnostics MCMC illustrés pour le paramètre `L2_large`, sélectionné à partir du modèle PA. De gauche à droite et de haut en bas : (1) *traceplot* des chaînes, un bon mélange est souhaité et se traduit par des chaînes entrelacées, similaires à un bruit blanc ; (2) fonction d'autocorrélation, une décroissance rapide vers zéro est souhaitée, ce indique une faible dépendance entre échantillons successifs ; (3) histogramme de la distribution *a posteriori*, il doit contenir assez d'informations pour approximer la densité ; (4) courbe de densité estimée *a posteriori*, l'axe x de l'histogramme et de la courbe de densité est exprimé en taille d'effet standardisée.

5.3.3 Sensibilité au prior (p_0)

Deux valeurs alternatives du paramètre p_0 ont été testées et comparées à la valeur de référence ($p_0 = 5$). Les trois configurations conduisent à la sélection des mêmes deux variables, dans le même ordre, avec des stabilités par *fold* identiques (0.99 et 0.99 dans toutes les configurations). Les estimations *a posteriori* sont stables : les écarts normalisés δ_{norm} sont inférieurs à 4 % pour l'ensemble des paramètres (tableau 5.4).

Sur le plan prédictif, les performances restent globalement stables. Avec $p_0 = 10$, on observe néanmoins que l'accuracy du modèle de référence augmente (0.711) alors que celle du sous-modèle ne suit pas (0.700), tandis que les valeurs d'elpd évoluent peu. Cela suggère un léger surapprentissage du modèle de référence.

5.3.4 Représentation dans l'espace des variables sélectionnées

La figure 5.8 représente les observations dans l'espace des deux variables sélectionnées, `L2_large` et `Sparc_small`. Les deux groupes forment des nuages distincts mais se chevauchent partiellement. Ce chevauchement est cohérent avec les performances prédictives observées (accuracy de 0.700).

En conclusion, l'ensemble de ces analyses semble donc converger. Le modèle global produit une

	$\hat{\beta}_{\text{ref}}$	$\hat{\beta}_{p_0=3}$	$\delta_{\text{norm}}(\%)$	$\hat{\beta}_{p_0=10}$	$\delta_{\text{norm}}(\%)$
Intercept	-0.011	-0.033	2.4	0.008	2.0
L2_large	-0.883	-0.898	1.0	-0.939	3.9
Sparc_small	-0.502	-0.483	1.7	-0.508	0.5

TABLE 5.4 – Analyse de sensibilité des estimations *a posteriori* au choix du paramètre p_0 du prior horeshoe du modèle PA. $\hat{\beta}_{\text{ref}}$ désigne la médiane *a posteriori* du modèle de référence ($p_0 = 5$) ; δ_{norm} est l'écart normalisé en fonction de l'intervalle de crédibilité, tel que $\delta_{\text{norm}} = |\hat{\beta}_{p_0} - \hat{\beta}_{\text{ref}}| / (\text{largeur IC}_{95\%}^{\text{ref}}) \times 100$




FIGURE 5.8 – Représentation des observations dans l'espace des deux variables sélectionnées par projection prédictive sur la tâche PA (L2_large et Sparc_small). Les unités des axes sont en taille d'effet standardisée.

sélection stable malgré une incertitude élevée sur les différences d'elpd. Le screening par tâche motrice montre que le modèle restreint à la tâche PA est équivalent au modèle complet tout en reposant sur un espace de variables plus faible. La projection prédictive conduite sur ce sous-espace aboutit à un sous-modèle à deux variables, L2_large et Sparc_small, dont la sélection est très stable (0.99 sur l'ensemble des *folds*) et cohérente avec les deux premières variables retenues sur le modèle global. Ces résultats sont peu sensibles au choix du prior p_0 . De plus, les deux coefficients sont négatifs : des valeurs plus élevées de L2_large et de Sparc_small sont associées à une probabilité réduite d'appartenir au groupe TSA, bien que l'incertitude sur la taille de ces effets demeure importante.

6 Discussion

la convergence des résultats entre le modèle PA et le modèle global malgré l'incertitude de ce dernier constitue un élément de validation indirecte de l'approche par décomposition

Modèle complet (145 vars) → ELPD trop incertain pour conclure, mais tendance à 2-7 variables stable en sensibilité → justifie de décomposer par tâche → T1 domine les autres tâches au sens $|elpd_diff| > se_diff$ → cv_varsel sur T1 → 2 variables (L2_large, Sparc_small) capturent l'essentiel avec $elpd.diff = 2.45$, $se = 0.83$ pour la taille 2 vs taille 3, ce qui est le seuil optimal. Dans cet échantillon, L2_large et Sparc_small constituent le sous-ensemble le plus parcimonieux identifié par la sélection projective sur la tâche T1, avec une performance prédictive non distinguable du modèle de référence complet. La stabilité de leur sélection ($cv_proportions = 0.99$) renforce leur statut de variables candidates pour des études futures, sans pour autant permettre une inférence causale ou $n < 94$ à la population TSA. + anticipation pointage Si Sparc_small bien, Sparc_large presque aussi bien, mais redondant donc non sélectionné. Pour autant, L2_large largement supérieur à L2_small qui ne capture pas d'information.

intention au départ : visiblement on tend à dire que PA suffirait + accent sur 2 variables, une liée à cible petite et une cible large spectre + tout les domaines enfants pas forcément différents enfants peut être en difficulté sur certaines tâches pour les uns, d'autres pour d'autres kmeans? → si clusterisation similaire imposée PCA/kmeans?

Sparc_small/L2large : qu'est-ce qu'elles traduisent de différent Fluidité : à quoi associé en terme de contrôles smoothness motor control... Idem pour longueur de tâche bioméca + intégrations sensorielles visuo/motrice

L2_large distance plus courte, lien parkinson etc

on a identifié des biomarqueurs moteurs de façon certaine, en éliminant bruit et redondance, mais modéré dans leur capacité à prédire quoi

Age et sexe pas informatives : c'est normal!! puisque jeu de données équilibré, contrairement à la population général

6.1 Interprétation des variables sélectionnées

Résultat principal L2 large + sparac small → augmentation de la variable diminue proba de prédire TSA. Rapporter en odd ratio pour interprétation.

Tâche PA

Résultat secondaire On peut regarder les variables sparac2 et pT2Pv6 du modèle réduit à partir du modèle de référence global, car stabilité ++ même si incertitude sur l'information que ça apporte. Rapporter en odd ratio pour interprétation.

Si accuracy modérée, c'est parce que bcp de sujet sont entre 2 → correspond avec l'idée de spectre. Il y a des cas extrêmes qu'on classe très bien, uniquement sur les marqueurs moteurs.

(lien avec la littérature sur la motricité fine et le TSA)

6.2 Apport de l'approche bayésienne

(par rapport à une régression classique)

6.3 Limites

(taille d'échantillon, na.omit, généralisabilité, k pareto sur modèle réduit à partir ref globale, incertitude)

7 Conclusion

Bibliographie

- ADAMOU, M., JONES, S. L., & WETHERHILL, S. (2021). Predicting diagnostic outcome in adult autism spectrum disorder using the autism diagnostic observation schedule, second edition. *BMC Psychiatry*, 21, 24. <https://doi.org/10.1186/s12888-020-03028-7>
- AL SAGHEER, T., HAIDA, O., BALBOUS, A., FRANCHETEAU, M., MATAS, E., FERNAGUT, P.-O., & JABER, M. (2018). Motor Impairments Correlate with Social Deficits and Restricted Neuronal Loss in an Environmental Model of Autism. *Int. J. Neuropsychopharmacol.*, 21(9), 871-882. <https://doi.org/10.1093/ijnp/pyy043>
- AMRHEIN, V., GREENLAND, S., & MCSHANE, B. (2019). Scientists rise up against statistical significance. *Nature*, 567, 305-307. <https://doi.org/10.1038/d41586-019-00857-9>
- ANZULEWICZ, A., SOBOTA, K., & DELAFIELD-BUTT, J. T. (2016). Toward the Autism Motor Signature: Gesture patterns during smart tablet gameplay identify children with autism. *Sci. Rep.*, 6:31107. <https://doi.org/10.1038/srep31107>
- APA. (2022). *Diagnostic and Statistical Manual of Mental Disorders, Fifth Edition, Text Revision (DSM-5-TR)*. American Psychiatric Publishing.
- BENCHEKRI, A. (2024). *Mieux comprendre les déficits moteurs associés au trouble du spectre de l'autisme : approches biomécanique et cognitive* [Thèse de Doctorat, Spécialité : Sciences et techniques des activités physiques et sportives]. Université de Poitiers.
- BIELENINIK, Ł., POSSERUD, M.-B., GERETSEGGER, M., THOMPSON, G., ELEFANT, C., & GOLD, C. (2017). Tracing the temporal stability of autism spectrum diagnosis and severity as measured by the Autism Diagnostic Observation Schedule: A systematic review and meta-analysis. *PLoS One*, 12(9), e0183160. <https://doi.org/10.1371/journal.pone.0183160>
- BRUGHA, T. S., MCMANUS, S., BANKART, J., SCOTT, F., PURDON, S., SMITH, J., BEBBINGTON, P., JENKINS, R., & MELTZER, H. (2011). Epidemiology of Autism Spectrum Disorders in Adults in the Community in England. *Archives of General Psychiatry*, 68(5), 459-465. <https://doi.org/10.1001/archgenpsychiatry.2011.38>
- CAVALLO, A., ROMEO, L., ANSUINI, C., BATTAGLIA, F., NOBILI, L., PONTIL, M., PANZERI, S., & BECCHIO, C. (2021). Identifying the signature of prospective motor control in children with autism. *Scientific Reports*, 11, 3165. <https://doi.org/10.1038/s41598-021-82374-2>
- COOK, J. (2016). From movement kinematics to social cognition: the case of autism [Publisher: Royal Society]. *Philosophical Transactions of the Royal Society B: Biological Sciences*, 371(1693), 20150372. <https://doi.org/10.1098/rstb.2015.0372>
- CRIPPA, A., SALVATORE, C., PEREGO, P., FORTI, S., NOBILE, M., MOLTENI, M., & CASTIGLIONI, I. (2015). Use of Machine Learning to Identify Children with Autism and Their Motor Abnormalities. *Journal of Autism and Developmental Disorders*, 45(7), 2146-2156. <https://doi.org/10.1007/s10803-015-2379-8>
- DEPAOLI, S., & van de SCHOOT, R. (2017). Improving transparency and replication in Bayesian statistics: The WAMBS-Checklist. *Psychol. Methods*, 22(2), 240-261. <https://doi.org/10.1037/met0000065>
- DI MARTINO, A., ROSS, K., UDDIN, L. Q., SKLAR, A. B., CASTELLANOS, F. X., & MILHAM, M. P. (2008). Functional Brain Correlates of Social and Non-Social Processes in Autism Spectrum Disorders: an ALE Meta-Analysis. *Biol. Psychiatry*, 65(1), 63. <https://doi.org/10.1016/j.biopsych.2008.09.022>
- DOCTOR, K. P., MCKEEVER, C., WU, D., PHADNIS, A., PLAWECKI, M. H., NURNBERGER, J. I., Jr., & JOSÉ, J. V. (2025). Deep learning diagnosis plus kinematic severity assessments of neurodivergent disorders. *Sci. Rep.*, 15(1), 20269. <https://doi.org/10.1038/s41598-025-04294-9>
- dos SANTOS, C. L., BARRETO, I. I., FLORIANO, I., TRISTÃO, L. S., SILVINATO, A., & BERNARDO, W. M. (2024). Screening and diagnostic tools for autism spectrum disorder: Systematic review and meta-analysis. *Clinics*, 79, 100323. <https://doi.org/10.1016/j.clinsp.2023.100323>

- ELSABBAGH, M., DIVAN, G., KOH, Y.-J., KIM, Y. S., KAUCHALI, S., MARCÍN, C., MONTIEL-NAVA, C., PATEL, V., PAULA, C. S., WANG, C., YASAMY, M. T., & FOMBONNE, E. (2012). Global Prevalence of Autism and Other Pervasive Developmental Disorders. *Autism Research*, 5(3), 160. <https://doi.org/10.1002/aur.239>
- EMANUELE, M., NAZZARO, G., MARINI, M., VERONESI, C., BONI, S., POLLETTA, G., D'AUSILIO, A., & FADIGA, L. (2021). Motor synergies: Evidence for a novel motor signature in autism spectrum disorder. *Cognition*, 213:104652. <https://doi.org/10.1016/j.cognition.2021.104652>
- ESTES, A., ZWAIGENBAUM, L., GU, H., JOHN, T. S., PATERSON, S., ELISON, J. T., HAZLETT, H., BOTTERON, K., DAGER, S. R., SCHULTZ, R. T., KOSTOPOULOS, P., EVANS, A., DAWSON, G., ELIASON, J., ALVAREZ, S., PIVEN, J., & NETWORK, I. (2015). Behavioral, cognitive, and adaptive development in infants with autism spectrum disorder in the first 2 years of life. *Journal of Neurodevelopmental Disorders*, 7(1), 24. <https://doi.org/10.1186/s11689-015-9117-6>
- FALKMER, T., ANDERSON, K., FALKMER, M., & HORLIN, C. (2013). Diagnostic procedures in autism spectrum disorders: a systematic literature review. *European Child & Adolescent Psychiatry*, 22(6), 329-340. <https://doi.org/10.1007/s00787-013-0375-0>
- FORTI, S., VALLI, A., PEREGO, P., NOBILE, M., CRIPPA, A., & MOLteni, M. (2011). Motor planning and control in autism. A kinematic analysis of preschool children. *Research in Autism Spectrum Disorders*, 5(2), 834-842. <https://doi.org/10.1016/j.rasd.2010.09.013>
- FREUD, E., AHMAD, Z., SHELEF, E., & HADAD, B. S. (2025). Effective Autism Classification Through Grasping Kinematics. *Autism Research*, 18(6), 1170-1181. <https://doi.org/10.1002/aur.70049>
- FRIGAUX, A., EVRARD, R., & LIGHEZZOLO-ALNOT, J. (2019). L'ADI-R et l'ADOS face au diagnostic différentiel des troubles du spectre autistique : intérêts, limites et ouvertures. *L'Encéphale*, 45(5), 441-448. <https://doi.org/10.1016/j.enceph.2019.07.002>
- FULCERI, F., CARUSO, A., MICAI, M., GILA, L., TANCREDI, R., FATTA, L. M., GALATI, G., D'AMICO, R., SCHÜNEMANN, H. J., BALDUZZI, S., CINQUINI, M., & SCATTONI, M. L. (2025). Autism diagnosis in children and adolescents: A systematic review and meta-analysis of test accuracy. *Neurosci. Biobehav. Rev.*, 173, 106164. <https://doi.org/10.1016/j.neubiorev.2025.106164>
- GELMAN, A., HILL, J., & YAJIMA, M. (2009). Why we (usually) don't have to worry about multiple comparisons. *arXiv*. <https://doi.org/10.48550/arXiv.0907.2478>
- GLAZEBROOK, C. M., ELLIOTT, D., & LYONS, J. (2006). A Kinematic Analysis of How Young Adults with and Without Autism Plan and Control Goal-Directed Movements. *Motor Control*, 10(3), 244-264. <https://doi.org/10.1123/mcj.10.3.244>
- GOODRICH, B., GABRY, J., ALI, I., & BRILLEMANN, S. (2025). rstanarm: Bayesian applied regression modeling via Stan. [R package version 2.32.2]. <https://mc-stan.org/rstanarm/>
- GROENEWEGER, H. J. (2003). The Basal Ganglia and Motor Control. *Neural Plast.*, 10(1-2), 107. <https://doi.org/10.1155/NP.2003.107>
- GUO, Z., TANG, X., XIAO, S., YAN, H., SUN, S., YANG, Z., HUANG, L., CHEN, Z., & WANG, Y. (2024). Systematic review and meta-analysis: multimodal functional and anatomical neural alterations in autism spectrum disorder. *Molecular Autism*, 15, 16. <https://doi.org/10.1186/s13229-024-00593-6>
- GUPTA, N., SRINIVASAN, S., & GUPTA, M. (2025). Rethinking psychometric testing in autism: overcoming the challenges of comorbidity and diagnostic overshadowing. *CNS Spectr.*, 30(1), e19. <https://doi.org/10.1017/S1092852925000021>
- HANDLE, H. C., FELDIN, M., & PILACINSKI, A. (2022). Handwriting in Autism Spectrum Disorder: A Literature Review. *NeuroSci*, 3(4), 558. <https://doi.org/10.3390/neurosci3040040>
- HAS. (2018, février). *Trouble du spectre de l'autisme : Signes d'alerte, repérage, diagnostic et évaluation chez l'enfant et l'adolescent* (rapp. tech.) (https://www.has-sante.fr/upload/docs/application/pdf/2018-02/trouble_du_spectre_de_lautisme_de_lenfant_et_ladolescent_-_argumentaire.pdf). Haute Autorité de Santé (HAS).
- HIROTA, T., & KING, B. H. (2023). Autism Spectrum Disorder: A Review. *JAMA*, 329(2), 157-168. <https://doi.org/10.1001/jama.2022.23661>

- HOCKING, D. R., & CAEYENBERGHS, K. (2017). What is the Nature of Motor Impairments in Autism, Are They Diagnostically Useful, and What Are the Implications for Intervention? [Publisher: Springer Science and Business Media LLC]. *Current Developmental Disorders Reports*, 4(2), 19-27. <https://doi.org/10.1007/s40474-017-0109-y>
- HOLLOCKS, M. J., LERH, J. W., MAGIATI, I., MEISER-STEDMAN, R., & BRUGHA, T. S. (2019). Anxiety and depression in adults with autism spectrum disorder: a systematic review and meta-analysis. *Psychological Medicine*, 49(4), 559-572. <https://doi.org/10.1017/S0033291718002283>
- HU, T., ZHAO, X., WU, M., LI, Z., LUO, L., YANG, C., & YANG, F. (2022). Prevalence of depression in older adults: A systematic review and meta-analysis. *Psychiatry Res.*, 311:114511. <https://doi.org/10.1016/j.psychres.2022.114511>
- IOANNIDIS, J. P. A. (2005). Why Most Published Research Findings Are False. *PLoS Med.*, 2(8), e124. <https://doi.org/10.1371/journal.pmed.0020124>
- KAMP-BECKER, I., ALBERTOWSKI, K., BECKER, J., GHAHREMAN, M., LANGMANN, A., MINGEBACH, T., POUSTKA, L., WEBER, L., SCHMIDT, H., SMIDT, J., STEHR, T., ROESSNER, V., KUCHARCZYK, K., WOLFF, N., & STROTH, S. (2018). Diagnostic accuracy of the ADOS and ADOS-2 in clinical practice. *Eur. Child Adolesc. Psychiatry*, 27(9), 1193-1207. <https://doi.org/10.1007/s00787-018-1143-y>
- KANGARANI-FARAHANI, M., MALIK, M. A., & ZWICKER, J. G. (2024). Motor Impairments in Children with Autism Spectrum Disorder: A Systematic Review and Meta-analysis. *Journal of Autism and Developmental Disorders*, 54(5), 1977-1997. <https://doi.org/10.1007/s10803-023-05948-1>
- KESSLER, R. C., PETUKHOVA, M., SAMPSON, N. A., ZASLAVSKY, A. M., & WITTCHEN, H.-U. (2012). Twelve-month and lifetime prevalence and lifetime morbid risk of anxiety and mood disorders in the United States. *International Journal of Methods in Psychiatric Research*, 21(3), 169. <https://doi.org/10.1002/mpr.1359>
- KLEINHANS, N. M., REITER, M. A., NEUHAUS, E., PAULEY, G., MARTIN, N., DAGER, S., & ESTES, A. (2015). Subregional differences in intrinsic amygdala hyper and hypo connectivity in autism spectrum disorder. *Autism research : official journal of the International Society for Autism Research*, 9(7), 760. <https://doi.org/10.1002/aur.1589>
- KUSHKI, A., CHAU, T., & ANAGNOSTOU, E. (2011). Handwriting Difficulties in Children with Autism Spectrum Disorders: A Scoping Review. *J. Autism Dev. Disord.*, 41(12), 1706-1716. <https://doi.org/10.1007/s10803-011-1206-0>
- LAI, M.-C., AMESTOY, A., BISHOP, S., BROWN, H. M., ONAIWU, M. G., HALLADAY, A., HARROP, C., HOTEZ, E., HUERTA, M., KELLY, A., MILLER, D., NORDAHL, C. W., RATTO, A. B., SAULNIER, C., SIPER, P. M., SOHL, K., ZWAIGENBAUM, L., & GOLDMAN, S. (2023). Improving autism identification and support for individuals assigned female at birth: clinical suggestions and research priorities. *Lancet. Child Adolesc. Health*, 7(12), 897-908. [https://doi.org/10.1016/S2352-4642\(23\)00221-3](https://doi.org/10.1016/S2352-4642(23)00221-3)
- LEBERSFELD, J. B., SWANSON, M., CLESI, C. D., & O'KELLEY, S. E. (2021). Systematic Review and Meta-Analysis of the Clinical Utility of the ADOS-2 and the ADI-R in Diagnosing Autism Spectrum Disorders in Children. *J. Autism Dev. Disord.*, 51(11), 4101-4114. <https://doi.org/10.1007/s10803-020-04839-z>
- LI, B., SHARMA, A., MENG, J., PURUSHWALKAM, S., & GOWEN, E. (2017). Applying machine learning to identify autistic adults using imitation: An exploratory study. *PLoS One*, 12(8), e0182652. <https://doi.org/10.1371/journal.pone.0182652>
- LIU, F., QIU, K., WANG, H., DONG, Y., & YU, D. (2024). Decreased wrist rotation imitation abilities in children with autism spectrum disorder. *Front. Psychiatry*, 15:1349879. <https://doi.org/10.3389/fpsyt.2024.1349879>
- LORD, C., ELSABBAGH, M., BAIRD, G., & VEENSTRA-VANDERWEELE, J. (2018). Autism spectrum disorder. *Lancet (London, England)*, 392(10146), 508-520. [https://doi.org/10.1016/S0140-6736\(18\)31129-2](https://doi.org/10.1016/S0140-6736(18)31129-2)
- LORD, C., RUTTER, M., DI LAVORE, P. C., RISI, S., GOTHAM, K., & BISHOP, S. (2012). *Autism Diagnostic Observation Schedule, Second Edition (ADOS-2) Manual (Part I): Modules 1-4*. Western Psychological Services.

- LORD, C., RUTTER, M., & LE COUTEUR, A. (1994). Autism Diagnostic Interview-Revised: A revised version of a diagnostic interview for caregivers of individuals with possible pervasive developmental disorders. *J. Autism Dev. Disord.*, 24(5), 659-685. <https://doi.org/10.1007/BF02172145>
- LUKITO, S., NORMAN, L., CARLISI, C., RADUA, J., HART, H., SIMONOFF, E., & RUBIA, K. (2020). Comparative Meta-analyses of Brain Structural and Functional Abnormalities during Cognitive Control in Attention-Deficit/Hyperactivity Disorder and Autism Spectrum Disorder. *Psychol. Med.*, 50(6), 894. <https://doi.org/10.1017/S0033291720000574>
- LUONGO, M., SIMEOLI, R., MAROCCO, D., MILANO, N., & PONTICORVO, M. (2024). Enhancing early autism diagnosis through machine learning: Exploring raw motion data for classification. *PLoS One*, 19(4), e0302238. <https://doi.org/10.1371/journal.pone.0302238>
- MANTO, M., BOWER, J. M., CONFORTO, A. B., DELGADO-GARCÍA, J. M., da GUARDA, S. N. F., GERWIG, M., HABAS, C., HAGURA, N., IVRY, R. B., MARIËN, P., MOLINARI, M., NAITO, E., NOWAK, D. A., TAIB, N. O. B., PELISSON, D., TESCHE, C. D., TILIKETE, C., & TIMMANN, D. (2012). Consensus Paper: Roles of the Cerebellum in Motor Control—The Diversity of Ideas on Cerebellar Involvement in Movement. *Cerebellum (London, England)*, 11(2), 457. <https://doi.org/10.1007/s12311-011-0331-9>
- MARI, M., CASTIELLO, U., MARKS, D., MARRAFFA, C., & PRIOR, M. (2003). The reach-to-grasp movement in children with autism spectrum disorder. *Philos. Trans. R. Soc. London, Ser. B*, 358(1430), 393-403. <https://doi.org/10.1098/rstb.2002.1205>
- MICAI, M., FATTA, L. M., GILA, L., CARUSO, A., SALVITTI, T., FULCERI, F., CIARAMELLA, A., D'AMICO, R., DEL GIOVANE, C., BERTELLI, M., ROMANO, G., SCHÜNEMANN, H. J., & SCATTONI, M. L. (2023). Prevalence of co-occurring conditions in children and adults with autism spectrum disorder: A systematic review and meta-analysis. *Neurosci. Biobehav. Rev.*, 155:105436. <https://doi.org/10.1016/j.neubiorev.2023.105436>
- MILANO, N., SIMEOLI, R., REGA, A., & MAROCCO, D. (2023). A deep learning latent variable model to identify children with autism through motor abnormalities. *Front. Psychol.*, 14:1194760. <https://doi.org/10.3389/fpsyg.2023.1194760>
- OMS. (2018). Classification internationale des maladies, 11e révision (CIM-11) : chapitre 6A02 – Troubles du spectre de l'autisme. <https://icd.who.int/fr/>
- PAPADOPOULOS, N., MCGINLEY, J., TONGE, B. J., BRADSHAW, J. L., SAUNDERS, K., & RINEHART, N. J. (2012). An investigation of upper limb motor function in high functioning autism and Asperger's disorder using a repetitive Fitts' aiming task. *Research in Autism Spectrum Disorders*, 6(1), 286-292. <https://doi.org/10.1016/j.rasd.2011.05.010>
- PATRIQUIN, M. A., DERAMUS, T., LIBERO, L. E., LAIRD, A., & KANA, R. K. (2016). Neuroanatomical and neurofunctional markers of social cognition in autism spectrum disorder. *Hum. Brain Mapp.*, 37(11), 3957. <https://doi.org/10.1002/hbm.23288>
- PIIRONEN, J., PAASINIEMI, M., CATALINA, A., WEBER, F., MARTIN, O., & VEHTARI, A. (2025). projpred: Projection Predictive Feature Selection [R package version 2.10.0]. <https://mc-stan.org/projpred/>
- PIIRONEN, J., PAASINIEMI, M., & VEHTARI, A. (2018). Projective Inference in High-dimensional Problems: Prediction and Feature Selection. *arXiv*. <https://doi.org/10.1214/20-EJS1711>
- PIIRONEN, J., & VEHTARI, A. (2017). Sparsity information and regularization in the horseshoe and other shrinkage priors. *arXiv*. <https://doi.org/10.1214/17-EJS1337SI>
- POPIT, S., SEROD, K., LOCATELLI, I., & STUHEC, M. (2024). Prevalence of attention-deficit hyperactivity disorder (ADHD): systematic review and meta-analysis. *Eur. Psychiatry*, 67(1), e68. <https://doi.org/10.1192/j.eurpsy.2024.1786>
- R CORE TEAM. (2026). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. Vienna, Austria. <https://www.R-project.org/>
- RANDALL, M., EGBERTS, K. J., SAMTANI, A., SCHOLTEN, R. J., HOOFT, L., LIVINGSTONE, N., STERLING-LEVIS, K., WOOLFENDEN, S., & WILLIAMS, K. (2018). Diagnostic tests for autism spectrum disorder (ASD) in preschool children. *Cochrane Database of Systematic Reviews*, 2018(7), CD009044. <https://doi.org/10.1002/14651858.CD009044.pub2>

- REA, H. M., ØIEN, R. A., SHIC, F., WEBB, S. J., & RATTO, A. B. (2023). Sex Differences on the ADOS-2. *J. Autism Dev. Disord.*, 53(7), 2878-2890. <https://doi.org/10.1007/s10803-022-05566-3>
- RINEHART, N. J., BELLGROVE, M. A., TONGE, B. J., BRERETON, A. V., HOWELLS-RANKIN, D., & BRADSHAW, J. L. (2006). An Examination of Movement Kinematics in Young People with High-functioning Autism and Asperger's Disorder: Further Evidence for a Motor Planning Deficit. *J. Autism Dev. Disord.*, 36(6), 757-767. <https://doi.org/10.1007/s10803-006-0118-x>
- SATO, W., & UONO, S. (2019). The atypical social brain network in autism: advances in structural and functional MRI studies. *Curr. Opin. Neurol.*, 32(4), 617-621. <https://doi.org/10.1097/WCO.0000000000000713>
- SHAFFER, R. L., WANG, Z., BARTOLOTTI, J., & MOSCONI, M. W. (2021). Visual and somatosensory feedback mechanisms of precision manual motor control in autism spectrum disorder. *Journal of Neurodevelopmental Disorders*, 13, 32. <https://doi.org/10.1186/s11689-021-09381-2>
- SIMEOLI, R., MILANO, N., REGA, A., & MAROCCO, D. (2021). Using Technology to Identify Children With Autism Through Motor Abnormalities. *Front. Psychol.*, 12:635696. <https://doi.org/10.3389/fpsyg.2021.635696>
- SONG, P., ZHA, M., YANG, Q., ZHANG, Y., LI, X., & RUDAN, I. (2021). The prevalence of adult attention-deficit hyperactivity disorder: A global systematic review and meta-analysis. *Journal of Global Health*, 11, 04009. <https://doi.org/10.7189/jogh.11.04009>
- SU, W.-C., MUTERSBAUGH, J., HUANG, W.-L., BHAT, A., & GANDJBAKHCHÉ, A. (2024). Using deep learning to classify developmental differences in reaching and placing movements in children with and without autism spectrum disorder. *Sci. Rep.*, 14(1), 30283. <https://doi.org/10.1038/s41598-024-81652-z>
- TANNER, A., & DOUNAVI, K. (2021). The Emergence of Autism Symptoms Prior to 18 Months of Age: A Systematic Literature Review. *J. Autism Dev. Disord.*, 51(3), 973-993. <https://doi.org/10.1007/s10803-020-04618-w>
- VABALAS, A., GOWEN, E., POLIAKOFF, E., & CASSON, A. J. (2020). Applying Machine Learning to Kinematic and Eye Movement Features of a Movement Imitation Task to Predict Autism Diagnosis. *Scientific Reports*, 10, 8346. <https://doi.org/10.1038/s41598-020-65384-4>
- van ROOIJ, D., ANAGNOSTOU, E., ARANGO, C., AUZIAS, G., BEHRMANN, M., BUSATTO, G. F., CALDERONI, S., DALY, E., DERUELLE, C., DI MARTINO, A., DINSTEIN, I., DURAN, F. L. S., DURSTON, S., ECKER, C., FAIR, D., FEDOR, J., FITZGERALD, J., FREITAG, C. M., GALLAGHER, L., ... BUITELAAR, J. K. (2017). Cortical and Subcortical Brain Morphometry Differences Between Patients With Autism Spectrum Disorder and Healthy Individuals Across the Lifespan: Results From the ENIGMA ASD Working Group. *Am. J. Psychiatry*, 175(4), 359. <https://doi.org/10.1176/appi.ajp.2017.17010100>
- VEHTARI, A., GABRY, J., MAGNUSSON, M., YAO, Y., BÜRKNER, P.-C., PAANANEN, T., & GELMAN, A. (2025). loo: Efficient leave-one-out cross-validation and WAIC for Bayesian models [R package version 2.9.0]. <https://mc-stan.org/loo/>
- VEHTARI, A., GELMAN, A., & GABRY, J. (2015). Practical Bayesian model evaluation using leave-one-out cross-validation and WAIC. *arXiv*. <https://doi.org/10.1007/s11222-016-9696-4>
- VEHTARI, A., GELMAN, A., SIMPSON, D., CARPENTER, B., & BÜRKNER, P.-C. (2019). Rank-normalization, folding, and localization: An improved $\hat{R}$ for assessing convergence of MCMC. *arXiv*. <https://doi.org/10.1214/20-BA1221>
- WAIZBARD-BARTOV, E., & MILLER, M. (2022). Does the Severity of Autism Symptoms Change Over Time? A Review of the Evidence, Impacts, and Gaps in Current Knowledge. *Clin. Psychol. Rev.*, 99, 102230. <https://doi.org/10.1016/j.cpr.2022.102230>
- WEBB, S. J., & JONES, E. J. H. (2009). Early Identification of Autism: Early Characteristics, Onset of Symptoms, and Diagnostic Stability. *Infants and young children*, 22(2), 100. <https://doi.org/10.1097/ICY.0b013e3181a02f7f>
- WOOLFENDEN, S., SARKOZY, V., RIDLEY, G., & WILLIAMS, K. (2012). A systematic review of the diagnostic stability of Autism Spectrum Disorder. *Research in Autism Spectrum Disorders*, 6(1), 345-354. <https://doi.org/10.1016/j.rasd.2011.06.008>

- ZANDER, E., WILLFORS, C., BERGGREN, S., COCO, C., HOLM, A., JIFÄLT, I., KOSIERADZKI, R., LINDER, J., NORDIN, V., OLAFSDOTTIR, K., & BÖLTE, S. (2017). The Interrater Reliability of the Autism Diagnostic Interview-Revised (ADI-R) in Clinical Settings. *Psychopathology*, 50(3), 219-227. <https://doi.org/10.1159/000474949>
- ZEIDAN, J., FOMBONNE, E., SCORAH, J., IBRAHIM, A., DURKIN, M. S., SAXENA, S., YUSUF, A., SHIH, A., & ELSABBAGH, M. (2022). Global prevalence of autism: A systematic review update. *Autism Research*, 15(5), 778-790. <https://doi.org/10.1002/aur.2696>
- ZWAIGENBAUM, L., BAUMAN, M. L., STONE, W. L., YIRMIYA, N., ESTES, A., HANSEN, R. L., MCPARTLAND, J. C., NATOWICZ, M. R., CHOUERI, R., FEIN, D., KASARI, C., PIERCE, K., BUIE, T., CARTER, A., DAVIS, P. A., GRANPEESHEH, D., MAILLOUX, Z., NEWSCHAFER, C., ROBINS, D., ... WETHERBY, A. (2015). Early Identification of Autism Spectrum Disorder: Recommendations for Practice and Research. *Pediatrics*, 136(Supplement_1), S10-S40. <https://doi.org/10.1542/peds.2014-3667C>

Annexe A. PPC




FIGURE 7.1 –

Annexe B. Stabilité ref




FIGURE 7.2 –

Annexe C. Stabilité PA




FIGURE 7.3 –