



École normale supérieure de Rennes
Département Sciences du sport et éducation physique

Diplôme de l'ENS – 1^{ère} année
Année universitaire 2025-2026
Discipline : STAPS

Mémoire en Sciences de la Vie et de la Santé

Identification des marqueurs de motricité fine les plus caractéristiques des TSA chez l'enfant : Approche bayésienne par projection prédictive

Présenté par :
Romain MARTINIE

Encadrants :
Laetitia FRADET (Université de Bretagne-Sud)
&
Germain FAITY (ENS, département 2SEP)

Remerciements

Attestation sur l'honneur

Je soussigné, Romain MARTINIE, atteste sur l'honneur de ne pas avoir eu recours au plagiat et que ce mémoire de recherche est le résultat d'un travail personnel. La rédaction de ce travail a été effectuée avec l'aide d'intelligence artificielle générative (modèle Claude Sonnet 4.6 : assistance dans le code, les formulations et correction de la langue).

Table des matières

1	Introduction	1
2	Revue de littérature	2
2.1	Les troubles du spectre de l'autisme (TSA)	2
2.1.1	Définition	2
2.1.2	Prévalence et comorbidités	2
2.1.3	Apparition du phénotype et trajectoires développementales	2
2.2	Bases neuronales des TSA	3
2.2.1	Bases structurelles	3
2.2.2	Altérations fonctionnelles	3
2.3	Diagnostic des TSA : outils, validité, et limites méthodologiques	4
2.3.1	Outils comportementaux de référence	4
2.3.2	Validité et questionnement du statut de référence	5
2.3.3	Ancrage normatif des outils de diagnostic	5
2.4	TSA et contrôle moteur : caractérisation de la motricité fine	6
2.4.1	Pointage et saisie manuelle	6
2.4.2	Écriture	6
2.4.3	Apport des approches par apprentissage automatique	7
	Classification en fonction de variables motrices	7
	Caractérisation de la motricité fine	7
3	Problématique, objectifs et hypothèses	8
3.1	Problématique	8
3.2	Objectifs	8
3.3	Hypothèses	8
4	Matériel et méthodes	9
4.1	Protocole expérimental	9
4.1.1	Population	9
4.1.2	Dispositif et tâches motrices	9
	Anticipation pointage	9
	Anticipation écriture	10
	Isochronie	10
	Pointage simple	10
4.2	Description du jeu de données	10
4.3	Cadre de l'inférence bayésienne	11
4.4	Cadre interprétatif de la sélection	12

4.5	Prétraitement des données	12
4.6	Modèle de référence	12
4.6.1	Régression logistique bayésienne	12
4.6.2	Spécification des priors	13
4.6.3	Critères de validité du modèle	14
4.6.4	Diagnostics MCMC	14
4.6.5	Vérifications prédictives (<i>Predictive Checks</i>)	14
4.7	Sélection par projection prédictive	15
4.7.1	Principe de cv varsel	15
4.7.2	Critère de sélection	15
4.8	Screening par comparaison de modèles et sélection sur la tâche PA	15
4.9	Analyse de sensibilité	16
4.10	Environnement logiciel	16
5	Résultats	17
5.1	Sélection sur le modèle global : limites de l'approche	17
5.1.1	Courbe elpd et sélection des variables	17
5.1.2	Diagnostics MCMC et approximation PSIS-LOO	19
5.1.3	Sensibilité au prior (p_0)	20
5.2	Screening par tâche motrice	20
5.3	Sélection sur la tâche PA	21
5.3.1	Courbe elpd et sélection des variables	21
5.3.2	Diagnostics MCMC et approximation PSIS-LOO	23
5.3.3	Sensibilité au prior (p_0)	23
5.3.4	Représentation dans l'espace des variables sélectionnées	24
6	Discussion	26
6.1	Convergence des résultats, PA comme tâche la plus discriminante	26
6.2	Interprétation des variables sélectionnées	27
6.2.1	Hypokinésie du mouvement et planification en <i>feedforward</i>	27
6.2.2	Déficit de fluidité sous contrainte de précision et rôle du cervelet	27
6.2.3	Variables secondaires (Sparc et <i>Time to Peak</i>)	28
6.3	Performance prédictive et hétérogénéité du spectre	28
6.4	Limites	29
7	Conclusion	30

Liste des abréviations

ACC	Cortex Cingulaire Antérieur
ACP	Analyse par Composantes Principales
ADI-R	<i>Autism Diagnostic Interview, Revised</i>
ADOS	<i>Autism Diagnostic Observation Schedule</i>
CRA	Centre de Ressources Autisme
DI	Déficience Intellectuelle
DMN	<i>Default Mode Network</i>
elpd	<i>Expected Log pointwise Predictive Density</i>
Epow	tâche d'isochronie
ID	Indice de Difficulté
ll_in	tâche d'anticipation écriture
LOO-CV	<i>Leave-One-Out Cross-Validation</i>
MCMC	<i>Markov Chain Monte Carlo</i> (chaîne de Markov par Monte Carlo)
mPFC	Cortex Préfrontal Médial
PA	tâche de Pointage Anticipation
PS	tâche de Pointage Simple
PSIS-LOO	<i>Pareto Smoothed Importance Sampling</i>
QI	Quotient Intellectuel
RHS	<i>Regularized HorseShoe</i>
SPARC	<i>SPectral ARC length</i>
TD	Développement Typique
TDH	Trouble de Déficit de l'Attention avec ou sans Hyperactivité
TSA	Trouble du Spectre Autistique
VBM	<i>Voxel-Based Morphometry</i> (Morphométrie Voxel-à-Voxel)
$\widehat{SE}$	Erreur Standard estimée

Table des figures

4.1	Configuration expérimentale pour la réalisation de la tâche d'Anticipation Pointage . .	9
4.2	Représentation des visuels utilisés pour la réalisation de la tâche d'Anticipation Écriture	10
4.3	Représentation des visuels utilisés pour la réalisation de la tâche d'isochronie	10
5.1	Courbes elpd et <i>accuracy</i> issues du modèle de référence global	17
5.2	Distributions <i>a posteriori</i> du sous-modèle réduit à partir du modèle de référence global	18
5.3	Diagnostics MCMC pour le paramètre L2_large , modèle global	19
5.4	Comparaison des modèles par tâche	21
5.5	Courbes elpd et d' <i>accuracy</i> issues du modèle de référence PA	22
5.6	Distributions <i>a posteriori</i> du sous-modèle réduit à partir du modèle de référence PA .	22
5.7	Diagnostics MCMC pour le paramètre L2_large , modèle PA	23
5.8	Représentation des observations dans l'espace des variables sélectionnées	24

Liste des tableaux

4.1	Paramètres utilisés lors de la tâche de Fitts	11
5.1	Estimations <i>a posteriori</i> du sous-modèle réduit à partir du modèle de référence global	19
5.2	Analyse de sensibilité au prior p_0 pour le modèle complet	20
5.3	Estimations <i>a posteriori</i> du sous-modèle réduit à partir du modèle de référence PA . .	23
5.4	Analyse de sensibilité au prior p_0 , modèle PA	24

Table des annexes

Annexe A : Description de l'ensemble des variables

Annexe B : *Prior* et *Posterior Predictive checks*

Annexe C. Stabilité de sélection des variables par *fold* à partir du modèle de référence global

Annexe D. Stabilité de sélection des variables par *fold* à partir du modèle de référence PA

Annexe E. Représentation des deux composantes principales issues de l'ACP réalisée sur les 4 variables sélectionnées pour les sujets TSA

1 Introduction

En France, en 2003, les registres régionaux estimaient la prévalence des troubles du spectre de l'autisme (TSA) chez les enfants de moins de sept ans à 4,1 pour 1 000 (HAS, 2018, p.10). Cette valeur est probablement sous-évaluée, car les formes plus modérées échappent souvent aux dispositifs d'identification (HAS, 2018, p.10). Par ailleurs, le nombre de diagnostics tend à augmenter (ZEIDAN et al., 2022) et la reconnaissance institutionnelle des TSA s'accroît¹. Les retards dans le diagnostic peuvent dépasser un an entre la première prise de contact et la restitution du diagnostic en France dans le cadre d'un Centre de Ressources Autisme (CRA)², illustrant la difficulté à diagnostiquer les individus autistes.

Le diagnostic, posé par un psychiatre, repose principalement sur les altérations de la communication et des interactions sociales, ainsi que sur les comportements stéréotypés et les intérêts restreints (APA, 2022, p. 56–58). Cette approche présente des limites en pratique clinique, pouvant conduire à des biais (par exemple liés au genre, voir Section 2.3.3) ou expliquer en partie les retards dans la prise en charge par les CRA.

Pour autant, la littérature montre que les TSA s'accompagnent de caractéristiques motrices qui ne sont pas exploitées pour le diagnostic. Ces particularités apparaissent pourtant précocement, parfois dès les premiers mois de vie, voire avant les signes sociaux atypiques (AL SAGHEER et al., 2018; ZWAIGENBAUM et al., 2015). Parallèlement, des corrélats neuronaux pourraient expliquer ces manifestations motrices et le phénotype autistique dans son ensemble (voir section 2.2). Ces observations suggèrent que les caractéristiques motrices pourraient ainsi constituer des marqueurs précoces du développement autistique.

Ce mémoire s'inscrit dans la continuité des travaux réalisés dans le cadre du projet "*Identifier et caractériser les déficits moteurs associés aux troubles du spectre autistique*", dont une partie des données a déjà été exploitée dans la thèse de BENCHEKRI (2024). En mobilisant une approche bayésienne, ce mémoire vise à identifier les variables de motricité fine les plus caractéristiques des enfants autistes, afin de proposer des pistes d'amélioration dans la compréhension et le diagnostic des TSA.

1. Comme en témoigne en France la *Stratégie nationale pour les troubles du neurodéveloppement 2023-2027*, <https://handicap.gouv.fr/nouvelle-strategie-nationale-pour-les-troubles-du-neurodeveloppement-autisme-dys-tdah-tdi>

2. IGAS. (2015). *Évaluation des Centres de ressources autisme (CRA) en appui de leur évolution* (p. 37). <https://igas.gouv.fr/sites/igas/files/files-spip/pdf/2015-124R-2.pdf>

2 Revue de littérature

2.1 Les troubles du spectre de l'autisme (TSA)

2.1.1 Définition

Les troubles du spectre de l'autisme (TSA) sont des troubles neurodéveloppementaux caractérisés par des difficultés persistantes dans la communication et les interactions sociales, ainsi que par des comportements et intérêts restreints ou répétitifs (APA, 2022, p. 56–58). Ce trouble apparaît pendant la période du développement, en général à la petite enfance. L'appellation "spectre" reflète une forte hétérogénéité individuelle au-delà des critères centraux de la communication et des comportements répétitifs (OMS, 2018). Ainsi, les TSA peuvent également se manifester à travers une déficience intellectuelle, des troubles du langage ou des troubles moteurs (APA, 2022, p. 62), et sont souvent accompagnés de comorbidités (APA, 2022, p. 67–68 ; LORD et al., 2018).

2.1.2 Prévalence et comorbidités

La prévalence des TSA est estimée à environ 1 % dans le monde, bien que les chiffres varient selon les études et aient tendance à augmenter avec le temps en raison d'une hausse des demandes de diagnostic (BRUGHA et al., 2011 ; ELSABBAGH et al., 2012 ; ZEIDAN et al., 2022). Les garçons sont généralement plus nombreux que les filles, avec un ratio masculin/féminin variant autour de 4 (ZEIDAN et al., 2022), malgré des biais genrés compliquant l'évaluation (voir Section 2.3.3). Les TSA seraient associés à une probabilité accrue de déficience intellectuelle (DI), mais la proportion n'est pas connue (ZEIDAN et al., 2022).

Par ailleurs, les TSA s'accompagnent fréquemment de comorbidités psychiatriques. Chez l'enfant, environ 45 % présentent par exemple au cours de leur vie un trouble déficitaire de l'attention avec hyperactivité (TDAH), 42 % un trouble anxieux et 14 % une dépression (MICAI et al., 2023). Chez l'adulte, ces proportions sont respectivement de l'ordre de 22 %, 28 à 42 % et 34 % (HOLLOCKS et al., 2019 ; MICAI et al., 2023) et sont donc supérieures à celles de la population générale. On y retrouve en effet autour de 4 % pour le TDAH (POPIT et al., 2024 ; SONG et al., 2021), 9 % pour le trouble anxieux (KESSLER et al., 2012) et 29 % pour la dépression (HU et al., 2022 ; KESSLER et al., 2012).

La prévalence et la diversité des comorbidités psychiatriques observées invitent donc à un diagnostic le plus précoce possible. En ce sens, quand est-ce que les premières caractéristiques autistiques émergent-elles ? Demeurent-elles stables tout au long du développement ?

2.1.3 Apparition du phénotype et trajectoires développementales

Dès les premiers mois de vie, des signes précoces du phénotype autistique apparaissent. Alors, dès l'âge d'un an, peuvent être observées des difficultés dans les premières interactions sociales, ainsi que des comportements répétitifs ou stéréotypés (TANNER & DOUNAVI, 2021 ; WEBB & JONES, 2009 ; ZWAIGENBAUM et al., 2015). Un contrôle moteur atypique, que ce soit au niveau de la motricité globale ou de la motricité fine, est également décrit dès 6 à 12 mois (ESTES et al., 2015 ; ZWAIGENBAUM et al., 2015).

Pour autant, les trajectoires développementales sont hétérogènes. En effet, si le diagnostic de l'autisme est stable dans le temps, on observe une grande hétérogénéité entre les études (BIELENINIK et al., 2017). De plus, bien que l'expression du phénotype autistique tende, en moyenne, à diminuer de l'enfance à l'adolescence (WAIZBARD-BARTOV & MILLER, 2022), entre 20 % et 49 % des enfants avec un TSA présentent néanmoins une régression dans les domaines du langage ou de la communication sociale (WEBB & JONES, 2009). Cette évolution dépend alors de variables comme l'environnement ou la présence ou non de déficience intellectuelle (WAIZBARD-BARTOV & MILLER, 2022).

Ainsi, l'apparition précoce du phénotype autistique et son évolution avec l'âge invitent à s'intéresser à la population pédiatrique. Par ailleurs, la présence d'un éventail de caractéristiques aussi diversifiées dès les premiers stades soulève la question de leurs bases neurobiologiques. Quelles altérations cérébrales pourraient expliquer la diversité des manifestations observées chez les enfants avec TSA ?

2.2 Bases neuronales des TSA

Les bases neuronales des TSA peuvent être comprises non pas comme l'altération d'une région cérébrale unique, mais comme un ensemble d'anomalies fonctionnelles et morphologiques affectant le cerveau à une échelle globale. Sans prétendre à l'exhaustivité, nous présenterons ici un aperçu des connaissances actuelles afin de situer les altérations cérébrales susceptibles de sous-tendre les caractéristiques observées chez les enfants avec TSA.

2.2.1 Bases structurelles

Sur le plan structurel, les analyses de morphométrie voxel-à-voxel (VBM) mettent en évidence un ensemble d'altérations de la matière grise chez les personnes présentant un TSA. Il a notamment été rapporté des réductions de volume dans le cortex cingulaire antérieur et médio-préfrontal, dans l'insula ainsi que dans le cervelet postérieur (GUO et al., 2024). Ces anomalies sont souvent convergentes entre mesures fonctionnelles et morphologiques (PATRIQUIN et al., 2016). De plus, il a été mis en évidence des volumes plus faibles du putamen, de l'amygdale, du noyau accumbens et du pallidum. Ces différences sous-corticales semblent relativement stables au cours du développement, tandis que les altérations corticales tendent à s'atténuer à l'âge adulte (van ROOIJ et al., 2017).

2.2.2 Altérations fonctionnelles

En imagerie fonctionnelle, les études au repos montrent, chez les sujets autistes, notamment une tendance à une hypoactivation dans l'insula gauche, du cortex cingulaire antérieur et médial préfrontal (ACC/mPFC), ainsi que dans l'aire temporale inférieure droite, accompagnée d'une hyperactivation du précuneus et de l'aire motrice supplémentaire (GUO et al., 2024). Des altérations concernent également le *default mode network* (DMN), où la connectivité entre le cortex préfrontal et le cortex cingulaire postérieur/precuneus apparaît réduite chez les individus avec TSA, ce qui pourrait expliquer certains troubles dans la cognition sociale (SATO & UONO, 2019). Des anomalies comparables touchent aussi les régions du "cerveau social" hors DMN, notamment l'amygdale (SATO & UONO, 2019), dont la connectivité affaiblie avec le cortex préfrontal ventromédian est corrélée à la sévérité des symptômes socio-affectifs (KLEINHANS et al., 2015). On observe également une dépendance du profil d'activation en fonction du type de tâche mobilisée : les tâches non sociales montrent un recrutement anormal de l'ACC dorsal et de l'aire motrice supplémentaire, tandis que les tâches sociales révèlent par exemple une hypoactivation du cortex cingulaire postérieur (DI MARTINO et al., 2008).

Le chevauchement des différences neuronales avec des régions impliquées dans le contrôle moteur, telles que le cervelet, les ganglions de la base et le cortex préfrontal, pourrait expliquer les difficultés motrices fréquemment observées chez les sujets avec TSA. En effet, des lésions du cervelet pourraient perturber le contrôle en *feedforward* ou la coordination sensori-motrice (MANTO et al., 2012). De même, les ganglions de la base pourraient être liés à l'apparition de mouvements stéréotypés (GROENEWEGEN, 2003).

Ainsi, les données de neuroimagerie révèlent des caractéristiques neuronales distribuées plutôt que localisées, affectant des régions impliquées dans la cognition sociale, la régulation émotionnelle et le contrôle moteur. Le chevauchement de ces anomalies avec celles observées dans d'autres troubles du neurodéveloppement ou pathologies complexifie leur interprétation (GUO et al., 2024; LUKITO et al., 2020). Parmi les régions altérées, on retrouve de façon récurrente des structures en lien avec la motricité, notamment le cervelet ou les ganglions de la base. Cette implication dans un trouble défini par des critères socio-cognitifs interroge la place des troubles moteurs dans le phénotype autistique. Alors, comment les connaissances issues des modèles cérébraux actuels s'intègrent-elles, ou non, dans les outils de diagnostic existants, et quelles en sont les limites ?

2.3 Diagnostic des TSA : outils, validité, et limites méthodologiques

Malgré la mise en évidence progressive de différences neuronales suggérant l'existence de marqueurs non seulement sociaux mais aussi moteurs chez les personnes présentant un TSA, la recherche et la pratique clinique se sont historiquement centrées sur les dimensions psycho-socio-cognitives du trouble (COOK, 2016). Pour autant, le diagnostic des TSA reste complexe en raison d'un chevauchement symptomatique (voir section 2.1.2) et neuronal (voir section 2.2.1) avec d'autres troubles du neurodéveloppement ou d'autres pathologies.

Actuellement, le diagnostic repose sur une évaluation clinique intégrant l'observation comportementale, l'histoire développementale et les informations parentales, selon un consensus pluridisciplinaire considéré comme le *gold standard* (HAS, 2018, p. 52; FALKMER et al., 2013; HIROTA & KING, 2023; RANDALL et al., 2018; WOOLFENDEN et al., 2012). Un nombre important d'outils standardisés pour assister le diagnostic ont été proposés (HAS, 2018, p. 51; FALKMER et al., 2013; RANDALL et al., 2018). Ainsi, aujourd'hui, les outils standardisés considérés comme la référence et les plus utilisés sont l'*Autism Diagnostic Interview, Revised* (ADI-R) et l'*Autism Diagnostic Observation Schedule, 2e édition* (ADOS-2) (FRIGAUX et al., 2019; HIROTA & KING, 2023).

2.3.1 Outils comportementaux de référence

L'ADOS-2 est un outil standardisé et semi-structuré d'observation directe, basé sur l'évaluation de la communication, l'interaction sociale, le jeu et les comportements répétitifs chez les personnes suspectées de TSA (LORD et al., 2012). Il se compose de 4 modules adaptés à l'âge et au niveau de langage de l'individu (LORD et al., 2012). L'ADI-R, quant à lui, prend la forme d'un entretien semi-structuré mené auprès des parents ou aidants d'enfants et d'adultes, portant sur la trajectoire développementale de l'individu (LORD et al., 1994).

Il convient alors de s'interroger sur la validité de ces outils diagnostiques : le statut de référence qui leur est attribué est-il justifié par leur validité ?

2.3.2 Validité et questionnement du statut de référence

Chez les enfants, l'ADI-R possède une sensibilité de l'ordre de 60 à 70 % et une spécificité d'environ 80 % (dos SANTOS et al., 2024 ; FULCERI et al., 2025 ; LEBERSFELD et al., 2021 ; RANDALL et al., 2018). Cependant, ces résultats cachent une incertitude très élevée, avec des plages de sensibilité s'étendant de 19 à 100 % et une spécificité comprise entre 50 % et 100 % (FULCERI et al., 2025 ; LEBERSFELD et al., 2021). L'ADOS-2 montre dans la même population une sensibilité légèrement plus importante, de l'ordre de 90 %, et une spécificité autour de 70-80 % avec incertitude notable mais plus faible que pour l'ADI-R (sensibilité : 77–100 % ; spécificité : 44–100 %) (FULCERI et al., 2025 ; LEBERSFELD et al., 2021).

En termes de fiabilité inter-juges, des accords élevés sont rapportés pour l'ADI-R, avec des taux compris entre 80 et 90 % (LORD et al., 1994 ; ZANDER et al., 2017). Il en va de même pour l'ADOS-2, bien que la fiabilité dépende fortement de l'expérience de l'évaluateur, avec des taux d'accord variant de 50 à 86 % selon les modules et l'expérience de l'évaluateur (KAMP-BECKER et al., 2018).

Un biais circulaire doit également être pris en compte : les études de validation de ces outils s'appuient généralement sur un diagnostic de référence posé par une équipe pluridisciplinaire, laquelle intègre déjà les résultats de l'ADOS/ADOS-2 et de l'ADI-R dans son évaluation.

Enfin, les performances varient aussi selon les profils cliniques : la spécificité de l'ADI-R peut, par exemple, tomber à 57 % chez les adultes sans déficience intellectuelle (ADAMOU et al., 2021). Ainsi, bien qu'efficaces, les outils standardisés sont sujets à une validité incertaine et hétérogène en fonction des populations. Cette hétérogénéité questionne la dépendance de ces outils à des normes développementales, mais aussi sociales, qu'il convient d'interroger.

2.3.3 Ancrage normatif des outils de diagnostic

Les outils de diagnostic possèdent un biais de genre marqué : les filles sont régulièrement sous-diagnostiquées (GUPTA et al., 2025 ; LAI et al., 2023 ; REA et al., 2023). Ce phénomène s'explique en partie par des facteurs socioculturels et par la construction genrée des outils et des critères diagnostiques. En effet, la plupart des tests ont été élaborés à partir de cohortes majoritairement masculines, et certains comportements typiques des TSA peuvent être socialement tolérés, voire valorisés, chez les filles (LAI et al., 2023). De plus, la difficulté d'application des outils standardisés auprès de populations présentant des particularités sensorielles, telles qu'une déficience visuelle ou auditive (HIROTA & KING, 2023), ou encore la nécessité de traduire ces outils et d'en valider ces traductions constituent des limites supplémentaires.

En outre, les outils actuellement utilisés pour le diagnostic des TSA présentent des biais qui conduisent à une sous-identification récurrente de certaines populations, notamment féminines, et une validité incertaine. Dans cette perspective, une approche fondée sur le contrôle moteur, en complément des outils actuellement utilisés, pourrait contribuer à réduire certains de ces biais. En effet, la motricité et notamment la motricité fine est moins susceptible d'être influencée par les différences de genre, de handicap, ou de contexte culturel que les interactions sociales. De plus, les altérations motrices observées chez les personnes autistes sont corrélées avec les caractéristiques centrales des TSA comme les difficultés sociales ou de communication (HOCKING & CAEYENBERGHS, 2017).

2.4 TSA et contrôle moteur : caractérisation de la motricité fine

Dès les premières étapes du développement, les enfants présentant un TSA montrent majoritairement des déficiences dans les évaluations standardisées du développement moteur, qu'il s'agisse de la motricité globale ou de la motricité fine (HOCKING & CAEYENBERGHS, 2017). Toutefois, tous les enfants avec TSA ne présentent pas nécessairement de déficiences motrices (HOCKING & CAEYENBERGHS, 2017). Ainsi, plutôt que de ne prendre en compte uniquement ces difficultés motrices, il apparaît pertinent d'examiner les particularités de la motricité globale comme fine chez les enfants avec TSA. Dans cette optique, nous faisons ici le choix de nous intéresser à la motricité fine, à travers l'étude des modèles de pointage, de saisie manuelle et d'écriture.

2.4.1 Pointage et saisie manuelle

La littérature met en évidence, chez les enfants présentant un TSA, une tendance à une augmentation du temps de mouvement lors des tâches de pointage et de saisie manuelle (BENCHEKRI, 2024; FORTI et al., 2011; GLAZEBROOK et al., 2006), bien que ce résultat ne soit pas systématiquement observé (PAPADOPOULOS et al., 2012; RINEHART et al., 2006), ainsi qu'une diminution de la fluidité du mouvement (BENCHEKRI, 2024). Alors, cette diminution de la vitesse pourrait être interprétée soit comme la cause d'une réduction de la fluidité du mouvement, soit, au contraire, comme sa conséquence, à l'image de ce qui a été observé chez des adultes atteints du syndrome parkinsonien (BENCHEKRI, 2024). De plus, il a été rapporté une augmentation du temps d'élaboration de la commande motrice (GLAZEBROOK et al., 2006; RINEHART et al., 2006), pouvant refléter un dysfonctionnement des ganglions de la base similaire à celui observé chez les patients parkinsoniens (RINEHART et al., 2006).

Il est important de noter que ces différences sont modulées par des variables de confusion, notamment le quotient intellectuel (QI) ou la complexité de la tâche (MARI et al., 2003). Ainsi, les enfants présentant un TSA associé à un QI plus faible que la moyenne tendent à exécuter les mouvements plus lentement que ceux ayant un QI plus élevé (MARI et al., 2003).

2.4.2 Écriture

Chez les enfants présentant un TSA, on peut retrouver des difficultés marquées dans l'écriture. On retrouve notamment une diminution de la lisibilité globale et une détérioration de la formation des lettres (HANDLE et al., 2022; KUSHKI et al., 2011). Au niveau moteur, l'écriture se caractérise par une vitesse d'exécution ralentie et une fluidité de mouvement plus faible (BENCHEKRI, 2024; HANDLE et al., 2022; KANGARANI-FARAHANI et al., 2024). Il peut être considéré que ces caractéristiques résulteraient notamment d'une altération de la coordination visuomotrice, les enfants présentant un TSA s'appuieraient en effet préférentiellement sur le *feedback* proprioceptif (BENCHEKRI, 2024; KANGARANI-FARAHANI et al., 2024; SHAFER et al., 2021).

Nous avons pu voir que des caractéristiques spécifiques de la motricité fine chez les enfants autistes sont mises en évidence au sein de tâches de pointage ou d'écriture, et ne se limitent pas aux déficits fonctionnels observés par les tests standardisés. Une approche consistant d'abord en une classification, puis en la détermination des profils moteurs, pourrait permettre une caractérisation plus fine de ces différences. Cette démarche contribuerait à la compréhension du phénotype moteur des TSA ainsi que des mécanismes neurofonctionnels sous-jacents. En effet, ces caractéristiques motrices, cohérentes avec les altérations des structures impliquées dans le contrôle moteur (voir section 2.2), apparaissent

comme des manifestations potentiellement informatives du fonctionnement cérébral des TSA. Une description précise de ces profils moteurs pourrait ainsi favoriser l'identification de marqueurs pertinents, utiles tant pour améliorer le diagnostic précoce des TSA que pour approfondir la compréhension de ce trouble, en offrant la possibilité de repérer des profils neurofonctionnels équivalents. Dans cette perspective, la littérature récente mobilise des approches fondées sur l'apprentissage automatique pour, d'une part, caractériser la motricité fine des individus avec un TSA, et, d'autre part, classifier les profils neurotypiques de ceux des enfants présentant un TSA.

2.4.3 Apport des approches par apprentissage automatique

Classification en fonction de variables motrices

Tout d'abord, la littérature montre de manière convergente la faisabilité d'une classification des TSA par des approches d'apprentissage automatique appliquées à des tâches de motricité fine. Les précisions sont généralement comprises entre 70 et 90 % selon la tâche et le modèle utilisés, qu'il s'agisse de tâches d'imitation gestuelle au niveau de la main (LI et al., 2017 ; LIU et al., 2024 ; VABALAS et al., 2020), de saisie manuelle (CAVALLO et al., 2021 ; CRIPPA et al., 2015 ; FREUD et al., 2025 ; MILANO et al., 2023 ; SIMEOLI et al., 2021 ; SU et al., 2024), de dessin (EMANUELE et al., 2021), ou de pointage (ANZULEWICZ et al., 2016 ; DOCTOR et al., 2025 ; LUONGO et al., 2024).

Caractérisation de la motricité fine

Par ailleurs, les modèles issus de ces études mettent en évidence des différences dans les vitesses, accélérations et dans la variabilité des trajectoires et amplitudes, traduisant des mouvements moins fluides chez les enfants avec TSA (DOCTOR et al., 2025 ; LI et al., 2017 ; MILANO et al., 2023 ; SIMEOLI et al., 2021). Il a été proposé que les enfants avec TSA auraient une moindre dépendance au *feedback* sensoriel, en particulier visuel, et des stratégies de contrôle davantage en boucle ouverte (ANZULEWICZ et al., 2016 ; CRIPPA et al., 2015 ; EMANUELE et al., 2021), ce qui est cohérent avec les conclusions des études plus observationnelles (voir Sections 2.4.1, 2.4.2).

Pour autant, les approches par apprentissage statistique demeurent à un stade de preuve de concept (DOCTOR et al., 2025). Bien qu'il soit possible d'extraire de l'information pertinente pour la classification à partir de tâches de motricité fine, les variables de confusion, telles que l'âge ou la présence ou non de déficience intellectuelle, peuvent biaiser l'apprentissage des modèles et ne sont pas toujours prises en compte (CAVALLO et al., 2021). De plus, les échantillons étudiés sont souvent relativement faibles comparés au nombre de *features*, ce qui entraîne un risque de surapprentissage. Enfin et surtout, la validation d'une approche automatique reste limitée par une forte hétérogénéité méthodologique, tant au niveau des tâches que des *features* extraites, ce qui empêche la constitution d'un modèle entraîné sur un grand volume de données et donc pleinement généralisable.

Face à cette hétérogénéité, l'identification des variables motrices les plus caractéristiques permettrait d'orienter la collecte de données pour le développement d'outils diagnostics basés sur la motricité. De plus, dans une perspective de modélisation *utile*, cela permettrait de formuler des hypothèses sur les systèmes neuronaux sous-jacents impliqués chez les sujets TSA. Par exemple, si les variables les plus discriminantes reflètent principalement des processus de planification, cela suggérerait une implication prédominante des ganglions de la base et permettrait de mobiliser les connaissances issues de la maladie de Parkinson pour mieux comprendre les mécanismes autistiques (RINEHART et al., 2006).

3 Problématique, objectifs et hypothèses

3.1 Problématique

La revue de la littérature met en évidence le besoin de mieux comprendre les TSA et de pouvoir les diagnostiquer précocement. Bien que l'on possède des connaissances sur les bases neuronales, la compréhension des TSA et les outils de diagnostic actuels restent largement imparfaits. En ce sens, une caractérisation de la motricité fine des TSA, notamment par des approches computationnelles, pourrait être une stratégie pertinente pour combler ces limites. Toutefois, ces approches ne sont pas cliniquement exploitées. Une limite majeure que l'on peut noter est l'hétérogénéité des variables mesurées et des tâches utilisées. Ainsi, déterminer les marqueurs moteurs les plus caractéristiques des TSA constituerait une avancée pour la compréhension et le diagnostic de ce trouble.

Nous nous proposons d'identifier, parmi un ensemble de tâches de motricité fine, les marqueurs moteurs les plus caractéristiques chez l'enfant avec TSA, dans l'objectif de mieux comprendre les altérations motrices associées et de contribuer, à titre exploratoire, au développement d'outils diagnostiques complémentaires à ceux utilisés aujourd'hui.

3.2 Objectifs

À l'aide d'analyses adaptées à un contexte de forte dimensionnalité, ce travail vise, d'une part, à améliorer la compréhension des TSA en reliant les marqueurs moteurs identifiés aux corrélats neuronaux décrits dans la littérature. D'autre part, il cherche à identifier une tâche ou un ensemble de variables de motricité fine présentant un fort pouvoir discriminant, afin d'évaluer l'existence de différents profils moteurs au sein de la population TSA. Cette approche pourrait constituer une base pour de futures études à plus large échelle, visant le développement d'outils de classification automatique en complément du diagnostic actuel.

3.3 Hypothèses

Sur la base de la littérature et des questionnements précédents, nous faisons l'hypothèse qu'il sera possible de classer les enfants présentant un TSA par rapport aux enfants neurotypiques avec une précision de l'ordre de 70 à 90 % – avec une sensibilité et spécificité équilibrée – à partir de l'ensemble des variables motrices issues des différentes tâches, et ce, sans surapprentissage. Nous supposons par ailleurs qu'un sous-ensemble restreint, correspondant aux variables les plus discriminantes, sera suffisant pour classer les deux groupes avec des performances comparables à celles obtenues avec l'ensemble complet des marqueurs. Enfin, nous faisons l'hypothèse que les variables motrices les plus discriminantes présenteront des liens cohérents avec les corrélats neurophysiologiques décrits dans la littérature, principalement le cervelet et les ganglions de la base, et qu'elles seront donc majoritairement associées à la fluidité et à l'accélération du mouvement.

4 Matériel et méthodes

Les données analysées dans ce mémoire sont issues des travaux de la thèse de BENCHEKRI (2024), dont nous rappelons ici les éléments de protocole nécessaires à la compréhension de la démarche statistique.

4.1 Protocole expérimental

4.1.1 Population

L'étude a inclus des enfants âgés de 6 à 12 ans, répartis en deux groupes : des enfants avec un trouble du spectre de l'autisme (TSA) et des enfants à développement "typique" (TD). Pour les enfants TSA, le diagnostic a été validé cliniquement par les équipes médicales des structures partenaires où ils étaient suivis, et objectivé par un score seuil à l'ADI-R et/ou à l'ADOS.

4.1.2 Dispositif et tâches motrices

Le protocole comprenait des tâches organisées de la façon suivante : motricité fine, motricité globale, puis oculométrie. Parmi l'ensemble des tâches proposées, quatre étaient en lien avec la motricité fine et ont donc donné lieu aux variables analysées dans ce mémoire. Les données motrices ont été recueillies à l'aide d'une tablette graphique et d'un stylet¹, sur quatre sites : Bordeaux, La Rochelle, Limoges, Poitiers.

Anticipation pointage

La tâche d'anticipation pointage (PA) consistait à pointer successivement deux cibles avec le stylet, en partant d'un carré de 0,5 cm de côté. La première cible, d'un diamètre de 2 cm, était présentée horizontalement à 10 cm de la zone de départ, à gauche ou à droite. La seconde cible était placée au-dessus de la première, à 14 cm de celle-ci, et pouvait présenter deux diamètres : 2 cm ou 0,5 cm, correspondant respectivement aux conditions facile et difficile (voir figure 4.1).




FIGURE 4.1 – Configuration expérimentale pour la réalisation de la tâche d'Anticipation Pointage. La première cible pouvait apparaître à droite ou à gauche. La seconde cible est ici représentée en condition difficile (cible petite). N'est pas à l'échelle.

1. Tablettes Yiynova MSP19U ou Huion 19GT-190 en fonction du site de recueil des données (19 pouces échantillonnage 200 Hz, 1024 points de pression, temps de retour 5ms)

Anticipation écriture

La tâche d'anticipation écriture (*ll_ln*) consistait à recopier avec le stylet et par-dessus un modèle, deux digrammes (*ll* et *ln*) présentés en écriture cursive, sans espace entre les deux lettres (voir figure 4.2). On parle d'anticipation car le sujet devait planifier son geste d'écriture en fonction de la lettre suivante (*l* ou *n*) avant d'avoir terminé la première.



FIGURE 4.2 – Représentation des visuels utilisés pour la réalisation de la tâche d'Anticipation Écriture

Isochronie

Pour la tâche d'isochronie (Epow), le participant devait recopier, avec le stylet et par-dessus un modèle, la lettre *e* selon cinq tailles différentes. Pour chaque taille, cinq essais consécutifs étaient réalisés avant de passer à la taille suivante (voir figure 4.3).




FIGURE 4.3 – Représentation des visuels utilisés pour la réalisation de la tâche d'isochronie. Pour chaque taille, 5 essais étaient réalisés. N'est pas à l'échelle.

Pointage simple

La tâche de Pointage Simple (PS) correspondait à une tâche de Fitts (FITTS, 1954). Le participant devait pointer une cible avec le stylet dès son apparition, le plus rapidement possible et sans lever le stylet, en partant d'un carré de 0,5 cm de côté. Quatre niveaux de difficulté ont été définis par l'indice de difficulté ID, calculé selon la formule suivante :

$$ID = \log_2 \left(\frac{2A}{w} \right)$$

où *A* désigne la distance entre le centre de chaque cible et *w* la largeur de la cible. Les paramètres associés à chaque niveau de difficulté sont présentés dans le tableau 4.1.

4.2 Description du jeu de données

Au total, 66 enfants TSA et 62 enfants TD ont été rencontrés. Après traitement des données, le jeu de données final retenu pour les analyses comprend 45 enfants TSA et 49 enfants TD. À partir des

ID	Distance A (cm)	Taille w (cm)
3	8	2
4	16	2
5	8	0,5
6	16	0,5

TABLE 4.1 – Paramètres utilisés lors de la tâche de Fitts

enregistrements issus des quatre tâches, 142 variables motrices ont été extraites, auxquelles s’ajoutent l’âge et le sexe de chaque enfant, soit 144 variables prédictives (*features*) au total. On peut répartir ces variables en trois catégories : des variables cinématiques et temporelles brutes (distances, vitesses, durées...), des variables dérivées (SPARC, curve index...) et des variables spécifiques aux tâches (indice d’isochronie, pente de la loi de Fitts...). Une description complète de l’ensemble des variables est disponible en [Annexe A](#).

Le ratio variables/observations ($D/n = 144/94 \approx 1.5$) est supérieur à 1. L’analyse statistique est donc dans un cas de grande dimension. Ce constat motive le recours à un cadre régularisant pour déterminer les variables les plus caractéristiques.

4.3 Cadre de l’inférence bayésienne

L’inférence bayésienne repose sur le théorème de Bayes, qui exprime la distribution *a posteriori* des paramètres θ du modèle conditionnellement aux données observées y :

$$p(\theta | y) \propto p(y | \theta) p(\theta)$$

où $p(y | \theta)$ désigne la vraisemblance des données et $p(\theta)$ la distribution *a priori* sur les paramètres. Contrairement à l’approche fréquentiste (cadre "classique"), les paramètres ne sont pas estimés ponctuellement mais caractérisés par une distribution de probabilité, qui quantifie explicitement l’incertitude sur leurs valeurs. L’inférence porte ainsi sur $p(\theta | y)$ et non sur la probabilité des données sous l’hypothèse nulle. Il est important de noter que les probabilités sont ici considérées de façon *épistémique* : elles modélisent l’incertitude des paramètres et non leur fréquence.

Les approches fondées sur les tests d’hypothèse nulle et le seuil de significativité $p < 0.05$ font l’objet de critiques méthodologiques majeures (AMRHEIN et al., 2019 ; IOANNIDIS, 2005). Elles encouragent notamment le raisonnement binaire, entraînent une inflation des erreurs de type I et ne permettent pas de quantifier l’incertitude sur les paramètres d’intérêt. Dans le contexte de ce mémoire où $p > n$, on s’attend à une grande incertitude sur les paramètres et à un risque important d’erreurs de type I dans un cadre fréquentiste.

Ainsi, une méthodologie bayésienne lève ces limitations en fournissant une distribution de probabilité complète par paramètre, en s’affranchissant du problème des comparaisons multiples (GELMAN et al., 2009) et en intégrant la régularisation via les distributions *a priori* (voir section 4.6.2).

En pratique, la distribution *a posteriori* n’est pas calculable analytiquement dans le cas général. Elle est approchée par simulation via des méthodes de Monte Carlo par chaînes de Markov (MCMC), qui permettent d’approximer la distribution de $p(\theta | y)$ en obtenant des échantillons de celle-ci. Une limite importante de la méthodologie appliquée est donc le coût computationnel qui est supérieur aux approches fréquentistes classiques, bien que les implémentations actuelles rendent ce coût élevé mais acceptable pour les dimensions considérées ici.

4.4 Cadre interprétatif de la sélection

La sélection de variables est réalisée selon un critère prédictif (voir section 4.7.2) : une variable est considérée comme informative si sa présence dans le modèle améliore la capacité à prédire l'appartenance au groupe TSA ou TD sur de nouvelles observations (PIIRONEN et al., 2025). Nous considérerons que si une variable est prédictive, alors elle reflète une caractéristique motrice différenciant les deux groupes sans que cela constitue une preuve de causalité. Ainsi, si un sous-ensemble de variables prédit aussi bien que le modèle complet, les variables exclues sont soit du bruit, soit redondantes, c'est-à-dire qu'elles partagent une information mutuelle élevée² avec les variables déjà sélectionnées sans pour autant être du bruit. La redondance n'est pas limitée aux relations linéaires d'ordre 1 (corrélations) : des dépendances non linéaires entre variables peuvent également conduire à l'exclusion d'une variable par ailleurs pertinente.

Ces considérations impliquent que la liste des variables sélectionnées constitue un point de départ pour l'exploration clinique et expérimentale et non un ensemble exhaustif ou définitif de marqueurs du TSA.

4.5 Prétraitement des données

Trois sujets présentant des valeurs manquantes ont été exclus de l'analyse. Un sujet supplémentaire a été exclu sur la base d'un critère de valeur aberrante : toute observation présentant un score $|z| > 5$ sur au moins une variable était candidate à l'exclusion. L'exclusion a été confirmée après vérification en unités naturelles et examen du contexte de la tâche. Au total, 90 sujets ont donc été retenus pour l'analyse (46 TD et 44 TSA).

L'ensemble des variables a ensuite été centré et réduit (moyenne et écart-type estimés sur l'échantillon), de façon à les ramener à une échelle commune. Cette normalisation repose sur des estimateurs fréquentistes, ce qui constitue une légère entorse à la cohérence bayésienne stricte mais était néanmoins nécessaire pour l'application de distributions a priori régularisantes comparables entre coefficients (voir section 4.6.2).

4.6 Modèle de référence

4.6.1 Régression logistique bayésienne

Le modèle de référence est une régression logistique bayésienne. La variable à prédire $y_i \in \{0, 1\}$ indique l'appartenance de l'individu i au groupe TSA ($y_i = 1$) ou TD ($y_i = 0$). Le modèle est défini tel que :

2. Au sens de la théorie de l'information, l'information mutuelle entre deux variables aléatoires X et Y est définie par :

$$I(X; Y) = H(X) + H(Y) - H(X, Y)$$

où H désigne l'entropie de Shannon. Elle mesure la quantité d'information partagée entre X et Y , et vaut zéro si et seulement si X et Y sont indépendantes.

$$y_i \sim \text{Bernoulli}(\pi_i), \quad i = 1, \dots, n$$

$$\text{logit}(\pi_i) = \alpha + \sum_{j=1}^D \beta_j x_{ij}, \quad j = 1, \dots, D$$

où $\pi_i = P(y_i = 1 \mid x_i)$ est la probabilité d'appartenir au groupe TSA, α l'ordonnée à l'origine, β_j le coefficient associé à la variable x_{ij} , et D le nombre total de variables. La fonction logit, définie par $\text{logit}(\pi) = \log(\pi/(1 - \pi))$, assure que $\pi_i \in]0, 1[$. Géométriquement, le modèle définit un hyperplan qui sépare les groupes TD et TSA dans l'espace des *features* dont la distance signée détermine la probabilité d'appartenance à chaque groupe.

4.6.2 Spécification des priors

Dans le cadre bayésien, les distributions a priori peuvent jouer un rôle analogue à la régularisation en statistique fréquentiste en contraignant les coefficients vers zéro, d'autant plus quand il y a peu de données. Un *a priori* (prior) gaussien centré correspond à une pénalité ridge (L_2) tandis qu'un prior laplacien correspond à une pénalité lasso (L_1). Ces deux approches présentent cependant des limitations dans le régime $p > n$: le prior gaussien écrase uniformément tous les coefficients sans produire de sparsité (coefficient à 0), tandis que le prior laplacien tend à trop contraindre les effets importants.

Le prior *Regularized Horseshoe* (RHS) (PIIRONEN & VEHTARI, 2017) est proposé pour dépasser ces limites dans un cadre bayésien, pour les problèmes de sélection de variables en grande dimension. Il repose sur une décomposition en deux niveaux de régularisation :

$$\begin{aligned} \beta_j &\sim \mathcal{N}(0, \tau^2 \tilde{\lambda}_j^2) \\ \tilde{\lambda}_j^2 &= \frac{c^2 \lambda_j^2}{c^2 + \tau^2 \lambda_j^2} \\ \lambda_j &\sim \text{C}^+(0, 1), \quad \tau \sim \text{C}^+(0, \tau_0) \\ c^2 &\sim \text{Inv-Gamma}\left(\frac{\nu}{2}, \frac{\nu s^2}{2}\right) \end{aligned}$$

où C^+ désigne la distribution demi-Cauchy. Le paramètre τ joue le rôle de *shrinkage global* : il pousse l'ensemble des coefficients vers zéro. Le paramètre λ_j joue le rôle de *shrinkage local* : il permet aux coefficients présentant un signal suffisant d'échapper à cet écrasement. Le terme c^2 , issu d'une distribution *Inverse-Gamma* de paramètres $(\nu/2, \nu s^2/2)$ avec $\nu = 4$ et $s = 2$ (valeurs recommandées par PIIRONEN et VEHTARI, 2017), régularise les coefficients importants en bornant leur variance *a priori*.

L'hyperparamètre τ_0 , qui calibre le shrinkage global en fonction de la sparsité attendue, est défini par :

$$\tau_0 = \frac{p_0}{D - p_0} \frac{\sigma}{\sqrt{n}}$$

où p_0 est le nombre de variables a priori supposées prédictives, D le nombre total de variables, n la taille d'échantillon, et σ un facteur d'échelle dans le cadre de la régression logistique. Conformément aux recommandations de PIIRONEN et VEHTARI (2017) pour la régression logistique, σ est fixé à 2.

Nous posons $p_0 = 10$, reflétant l’hypothèse que seul un petit nombre de variables parmi les $D = 144$ est suffisant pour discriminer les deux groupes. Ce choix est exploratoire et sa sensibilité est évaluée dans la section 4.9.

L’intercept α reçoit un prior Student-t faiblement informatif, centré en zéro :

$$\alpha \sim \text{Student-t}(\nu = 7, \mu = 0, \sigma = 2.5)$$

4.6.3 Critères de validité du modèle

La performance prédictive du modèle est évaluée par validation croisée *leave-one-out*³ (LOO-CV), approchée par l’estimateur PSIS-LOO (*Pareto Smoothed Importance Sampling Leave-One-Out*) (VEHTARI et al., 2015). Il estime l’*expected log pointwise predictive density* (elpd), définie telle que :

$$\text{elpd}_{\text{loo}} = \sum_{i=1}^n \log p(y_i | y_{-i})$$

où $p(y_i | y_{-i})$ désigne la probabilité assignée par le modèle ajusté sur les $n - 1$ observations restantes à la vraie classe de l’observation i . L’elpd est donc la somme des log-probabilités prédites pour chaque observation mise de côté tour à tour : plus elle est élevée, meilleure est la capacité du modèle à généraliser à de nouvelles données. L’elpd constitue le critère principal de comparaison entre modèles.

La fiabilité de l’approximation PSIS-LOO est contrôlée par les diagnostics $\hat{k}$ de Pareto : pour chaque observation i , un $\hat{k} > 0.7$ signale que l’approximation est peu fiable pour cette observation et que l’estimation de l’elpd doit être interprétée avec précaution (VEHTARI et al., 2015). La précision de classification (*accuracy*) est rapportée comme critère complémentaire pour faciliter l’interprétation clinique des résultats. Elle est définie comme la proportion d’observations correctement classées, la classe prédite étant celle de probabilité maximale selon le modèle (PIIRONEN et al., 2025).

4.6.4 Diagnostics MCMC

Il est nécessaire de vérifier la convergence des chaînes de Markov avant toute inférence, sans quoi les résultats risquent de ne pas être valides. Quatre chaînes de chacune 4000 itérations ont été simulées, dont 2000 de préchauffage (*warmup*), soit 8000 échantillons post-warmup au total. La convergence est évaluée par le critère $\hat{R}$ de Gelman-Rubin. Une valeur $\hat{R} < 1.01$ et une taille d’échantillon effective > 400 pour l’ensemble des paramètres sont retenues comme seuil de convergence (VEHTARI et al., 2019). Ces diagnostics sont complétés par un examen visuel des traceplots, des graphiques d’autocorrélation et des distributions marginales *a posteriori* (histogrammes et densités).

4.6.5 Vérifications prédictives (*Predictive Checks*)

Enfin, la validité du modèle a été évaluée par des vérifications prédictives (*Predictive Checks*). Un *Prior Predictive Check* a d’abord permis de s’assurer que les distributions *a priori* ne contraignaient pas le modèle vers des prédictions extrêmes avant l’observation des données. Après ajustement, un *Posterior Predictive Check* a été réalisé en comparant la distribution des données observées aux données simulées par le modèle. Le *Posterior Predictive Check* montre que le modèle reproduit la proportion des classes (TSA/TD) sans pour autant présenter une certitude extrême et évite ainsi le surapprentissage. Les graphiques sont présentés en Annexe B.

3. La validation croisée LOO correspond à, à chaque itération d’apprentissage/validation, réaliser l’apprentissage sur $n - 1$ observations et la validation sur l’unique observation restante. Il y a donc n itérations.

4.7 Sélection par projection prédictive

4.7.1 Principe de `cv_varsel`

La sélection par projection prédictive (PIIRONEN et al., 2018) est une méthode de sélection de variables en fonction d'un modèle de référence, ici le modèle logistique bayésien complet ajusté sur l'ensemble des variables. Ce modèle constitue un plafond de performance prédictive : l'objectif est d'identifier le sous-modèle le plus parcimonieux dont la performance prédictive n'est pas inférieure à celle du modèle de référence (voir section 4.7.2 pour le critère de sélection).

Le modèle de référence est d'abord ajusté sur l'ensemble des données et sa distribution *a posteriori* est obtenue par MCMC. Une recherche forward est ensuite conduite : les variables sont ajoutées une à une au sous-modèle, en sélectionnant à chaque étape la variable qui minimise la divergence de Kullback-Leibler⁴ entre les prédictions du sous-modèle projeté et celles du modèle de référence. La projection consiste à trouver, pour chaque taille de sous-modèle, les paramètres qui reproduisent au mieux le comportement prédictif du modèle de référence. Une fois le sous-modèle sélectionné, une inférence finale est conduite sur ce sous-modèle restreint.

La performance prédictive de chaque sous-modèle est évaluée par `cv_varsel` avec `validate_search = TRUE` (PIIRONEN et al., 2025). Une LOO-CV est réalisée dans laquelle, à chaque fold, la recherche forward est réappliquée sur les $n - 1$ observations d'entraînement. La performance à chaque étape (chaque *fold* de LOO-CV pour chaque taille de sous-modèle k testée) est définie par l'elpd approximé par PSIS-LOO. La performance finale du sous-modèle sélectionné est évaluée sur l'observation exclue. La fréquence à laquelle une variable est incluse dans le sous-modèle de taille k à travers les folds permet de constituer une mesure de stabilité de la sélection.

4.7.2 Critère de sélection

Le critère principal de sélection est l'elpd estimé par PSIS-LOO (voir section 4.6.3). Pour chaque taille de sous-modèle k , l'écart à la performance du modèle de référence est quantifié par la différence $\Delta\text{elpd}_k = \text{elpd}_k - \text{elpd}_{ref}$ négative ou nulle par construction. La taille du sous-modèle retenu est déterminée principalement par la règle des $1\widehat{SE}$ (erreur standard) (PIIRONEN et al., 2018) : le sous-modèle le plus parcimonieux tel que $|\Delta\text{elpd}_k| \leq \widehat{SE}(\Delta\text{elpd}_k)$, c'est-à-dire dont l'écart au modèle de référence reste inférieur à son erreur standard estimée. Ce critère est confirmé visuellement par le critère du coude sur la courbe Δelpd_k et par la stabilité de sélection des variables. La précision est également rapportée mais la sélection de modèle est décidée par l'application des critères sur l'elpd.

4.8 Screening par comparaison de modèles et sélection sur la tâche PA

L'application de la sélection par projection prédictive sur le modèle global (144 variables) se heurte à une incertitude élevée sur l'estimation de l'elpd liée au ratio D/n important. En l'absence de coude

4. La divergence de Kullback-Leibler, notée D_{KL} , est souvent décrite comme une mesure de la distance entre deux distributions de probabilité. Formellement, avec P et Q des densités de probabilité :

$$D_{KL}(P||Q) = \int p(x) \log \frac{p(x)}{q(x)} dx$$

net dans la courbe Δelpd_k , il n'est pas possible d'identifier un sous-ensemble de variables de manière fiable à partir du modèle complet (voir section 5.1).

Pour contourner cette limite, le modèle global est décomposé en quatre sous-modèles de référence, un par tâche motrice (PA, ll_ln, Epow, PS). Chaque sous-modèle est ajusté indépendamment avec le même prior RHS et la même procédure MCMC que le modèle global, à l'exception de $p_0 = 5$, ce qui reflète le moindre nombre de variables (τ_0 recalculé en fonction, voir section 4.6.2). La performance prédictive de chaque sous-modèle est estimée par PSIS-LOO et les $\hat{k}$ de Pareto sont rapportés pour chaque modèle. La comparaison des elpd entre sous-modèles et avec le modèle global est conduite par `loo_compare` (VEHTARI et al., 2025).

La tâche PA présente un elpd dont l'écart au modèle global reste inférieur à $1\widehat{SE}$ (voir section 5.3.1), ce qui satisfait le critère de sélection défini en section 4.7.2. Elle est donc retenue comme tâche candidate pour la sélection par projection prédictive, son sous-modèle constituant le nouveau modèle de référence ($D_{\text{PA}} = 24$).

4.9 Analyse de sensibilité

La sensibilité des résultats au choix de p_0 a été évaluée en réajustant le modèle de référence complet ($D = 144$) avec trois valeurs : $p_0 \in \{5, 10, 20\}$, et le modèle de référence PA ($D = 24$) avec $p_0 \in \{3, 5, 10\}$. Pour chaque valeur, τ_0 est recalculé en conséquence (voir section 4.6.2) et la procédure `cv_varsel` est réappliquée. La stabilité des variables sélectionnées, de la taille du sous-modèle retenu et des coefficients des variables est examinée pour chacun des scénarios.

4.10 Environnement logiciel

Les analyses ont été conduites sous R version 4.5.3 (R CORE TEAM, 2026). Le modèle bayésien a été ajusté par l'algorithme de Monte Carlo hamiltonien implémenté dans `rstanarm` (version 2.32.1) (GOODRICH et al., 2025). La sélection par projection prédictive a été conduite avec le package `projpred` (version 2.10.0.9000) (PIIRONEN et al., 2025). La validation croisée LOO et les diagnostics $\hat{k}$ de Pareto ont été calculés avec le package `loo` (version 2.9.0.9000) (VEHTARI et al., 2025). La reproductibilité des résultats est assurée par une graine aléatoire (123). La robustesse du modèle de référence a été confirmée en vérifiant la stabilité des résultats avec une graine alternative (1234). L'ensemble des données et du code nécessaire à l'application de la méthodologie et de la compilation du mémoire est disponible au lien suivant : <https://github.com/rmartinie/memoire-tsa-motricite-fine-bayesien>.

5 Résultats

5.1 Sélection sur le modèle global : limites de l'approche

5.1.1 Courbe elpd et sélection des variables

La procédure `cv_varsel` a été appliquée sur le jeu de données complet, avec un nombre maximum de variables fixé à $k = 15$. Ce plafond a été validé en répétant la procédure avec $k = 25$, qui ne produit pas d'amélioration supplémentaire ni de l'elpd ni de l'*accuracy*.

La courbe elpd (figure 5.1) présente une première difficulté d'interprétation. En effet, selon le critère strict de l'erreur standard, le modèle à une seule variable est statistiquement équivalent au modèle complet, en raison d'une incertitude élevée sur les différences d'elpd. L'examen visuel de la courbe et les taux de sélection par *fold* suggèrent néanmoins de retenir quatre variables, sélectionnées avec une stabilité respective de 0.99, 0.91, 0.97 et 0.93 (voir [Annexe C](#) pour le détail par variable).




FIGURE 5.1 – Courbes de l'elpd et de l'*accuracy* issues du modèle de référence global, en fonction du nombre de variables incluses dans le sous-modèle, obtenues par projection prédictive avec validation croisée. Chaque point représente la différence d'elpd/d'*accuracy* entre le sous-modèle et le modèle de référence. Les barres d'erreur indiquent l'incertitude à ± 1 erreur standard. Une différence proche de zéro indique des performances prédictives équivalentes au modèle de référence global.

Le sous-modèle à quatre variables retenu est `L2_large`, `Sparc_small`, `Sparc2` et `pT2Pv6`. `L2_large` correspond à la distance parcourue de la première à la seconde cible lors de la tâche PA en condition

"facile" (cible large). `Sparc_small` et `Sparc2` sont des mesures de SPARC¹ (*Spectral Arc Length*, mesure de fluidité) mesurée lors de la tâche PA et Epow, respectivement. Enfin, `pT2Pv6` correspond au temps pour atteindre le pic de vitesse (*time to peak*) mesuré lors de la tâche PS avec ID = 6.

Les estimations *a posteriori* sont présentées dans la table 5.1 pour les valeurs quantitatives et la figure 5.2 pour les distributions qualitatives des courbes de densité. Si la taille d'effet reste toujours très incertaine, la probabilité de direction est très forte pour chacune des 4 variables sélectionnées ce qui indique une faible incertitude quant au signe des effets.

Les performances prédictives du sous-modèle sont comparables à celles du modèle de référence (sous-modèle vs référence; elpd : -54.61 vs -57.52 , *accuracy* : 0.678 vs 0.656). La matrice de confusion montre une classification modérée, avec 13 faux négatifs (classifié TD au lieu de TSA) et 12 faux positifs (classifié TSA au lieu de TD) sur 90 observations. L'*accuracy* globale restant inférieure au seuil de 0.70 , la capacité prédictive du modèle de référence est elle-même limitée, ce qui invite à la prudence dans l'interprétation des variables sélectionnées. Par ailleurs, le modèle ne montre pas de signe de surapprentissage.




FIGURE 5.2 – Distributions *a posteriori* des coefficients de régression du sous-modèle à quatre variables à partir du modèle de référence global. Pour chaque paramètre, la barre verticale bleue indique la médiane *a posteriori* et la zone bleue représente l'intervalle de crédibilité à 95 % (IC_{95%}). Conditionnellement au modèle et aux données, la valeur du paramètre a 95 % de chance de se situer dans cet intervalle.

1. Le SPARC (*Spectral ARC length*) est défini comme la longueur de l'arc spectral de la vitesse du mouvement :
$$\text{SPARC} = - \int_0^{\omega_c} \sqrt{\left(\frac{1}{\omega_c^2} + \frac{d\hat{V}(\omega)}{d\omega} \right)^2} d\omega$$
 où $\hat{V}(\omega)$ est la transformée de Fourier de la vitesse et ω_c la fréquence de coupure. Le SPARC est négatif. Une valeur plus proche de zéro indique un mouvement plus fluide (BALASUBRAMANIAN et al., 2015).

	Médiane	IC _{95%}	$P(\beta_j < 0)$	$P(\beta_j > 0)$
Intercept	0.035	$[-0.468; 0.541]$	0.443	0.558
L2_large	-0.738	$[-1.442; -0.018]$	0.978	0.023
Sparc_small	-0.400	$[-1.137; 0.020]$	0.970	0.030
Sparc2	-0.392	$[-1.201; 0.059]$	0.955	0.045
pT2Pv6	0.216	$[-0.095; 0.898]$	0.130	0.870

TABLE 5.1 – Estimations *a posteriori* des coefficients du sous-modèle à quatre variables à partir du modèle de référence global. La médiane et l’intervalle de crédibilité à 95 % (IC_{95%}) résument la distribution *a posteriori* de chaque coefficient ; $P(\beta_j < 0)$ et $P(\beta_j > 0)$ indiquent la probabilité *a posteriori* que le coefficient soit négatif ou positif, respectivement (probabilité de direction).

5.1.2 Diagnostics MCMC et approximation PSIS-LOO

Les diagnostics MCMC à travers les *traceplots*, les fonctions d’autocorrélation, les histogrammes et les distributions marginales (figure 5.3) ne révèlent pas de problème majeur de convergence. Néanmoins, les *traceplots* montrent des pics ponctuels vers des valeurs extrêmes. Ce comportement peut être attendu avec un prior RHS en situation d’incertitude, ses queues lourdes autorisant l’exploration de grandes valeurs de coefficients. L’ensemble des paramètres affiche un $\hat{R}$ inférieur à 1.01 et une taille effective d’échantillon > 400 .




FIGURE 5.3 – Exemple de diagnostics MCMC illustrés pour le paramètre `L2_large`, sélectionné à partir du modèle global. De gauche à droite et de haut en bas : (1) *traceplot* des chaînes, un bon mélange est souhaité et se traduit par des chaînes entrelacées, similaires à un bruit blanc ; (2) fonction d’autocorrélation, une décroissance rapide vers zéro est souhaitée, ce qui indique une faible dépendance entre échantillons successifs ; (3) histogramme de la distribution *a posteriori*, il doit contenir assez d’informations pour approximer la densité ; (4) courbe de densité estimée *a posteriori*, l’axe x de l’histogramme et de la courbe de densité est exprimé en taille d’effet standardisée.

Concernant l’approximation PSIS-LOO, 9 observations présentent un $\hat{k}$ de Pareto supérieur à 0.7 (environ 10 % des observations), seuil au-delà duquel l’estimation PSIS est considérée peu fiable pour

l’observation concernée (VEHTARI et al., 2015). Ce résultat invite à interpréter les valeurs d’elpd avec prudence.

5.1.3 Sensibilité au prior (p_0)

Afin d’évaluer l’influence du prior sur les résultats, deux valeurs alternatives du paramètre p_0 ont été testées et comparées à la valeur de référence.

Les trois configurations conduisent à la sélection des mêmes quatre variables, dans le même ordre, avec des stabilités par *fold* comparables. Les estimations *a posteriori* des coefficients sont stables. Exprimés en fraction de la largeur de l’intervalle de crédibilité à 95 % du modèle de référence, les écarts normalisés δ_{norm} restent inférieurs à 10% pour l’ensemble des paramètres et des deux valeurs alternatives testées (tableau 5.2). Les signes et ordres de grandeur des effets sont identiques dans toutes les configurations.

	$\hat{\beta}_{\text{ref}}$	$\hat{\beta}_{p_0=5}$	$\delta_{\text{norm}}(\%)$	$\hat{\beta}_{p_0=20}$	$\delta_{\text{norm}}(\%)$
Intercept	0.035	0.016	1.9	0.041	0.6
L2_large	-0.738	-0.732	0.4	-0.754	1.1
Sparc_small	-0.400	-0.343	4.9	-0.493	8.0
Sparc2	-0.392	-0.272	9.5	-0.469	6.1
pT2Pv6	0.216	0.143	7.3	0.325	10.9

TABLE 5.2 – Analyse de sensibilité des estimations *a posteriori* au choix du paramètre p_0 du prior RHS. $\hat{\beta}_{\text{ref}}$ désigne la médiane *a posteriori* du modèle de référence ($p_0 = 10$) ; δ_{norm} est l’écart normalisé en fonction de l’intervalle de crédibilité, tel que $\delta_{\text{norm}} = |\hat{\beta}_{p_0} - \hat{\beta}_{\text{ref}}| / (\text{largeur IC}_{95\%}^{\text{ref}}) \times 100$

Sur le plan prédictif, les performances sont stables. Les valeurs d’elpd et d’*accuracy* du modèle de référence et du sous-modèle restent du même ordre quelle que soit la valeur de p_0 . On note toutefois qu’avec $p_0 = 20$, l’*accuracy* du sous-modèle (0.689) est supérieure à celle du modèle de référence (0.667), tandis que les valeurs d’elpd demeurent proches. À l’inverse, avec $p_0 = 5$, les deux métriques convergent et les estimations des coefficients sont légèrement plus faibles. Cela indique une régularisation plus forte. La configuration $p_0 = 10$ semble donc être un compromis satisfaisant.

5.2 Screening par tâche motrice

La comparaison des modèles par tâche motrice via LOO-CV (voir figure 5.4) indique que le modèle restreint à la tâche PA est statistiquement équivalent au modèle complet ($\Delta\text{elpd} = -2.21$, $\widehat{SE} = 3.21$) selon le critère de l’erreur standard sur la différence d’elpd, tout en reposant sur un espace de variables nettement plus faible. En effet, le modèle PA présente un p_{loo} (nombre de paramètres effectifs) plus faible que le modèle complet (8.08 vs 23.84), ce qui indique un modèle plus parcimonieux.

Les modèles fondés sur les tâches Epow, ll_ln et PS affichent des performances inférieures, avec des différences d’elpd qui excèdent leur erreur standard respective (voir figure 5.4). Ces résultats sont cohérents avec ceux de la section précédente, où les deux premières variables sélectionnées (L2_large, Sparc_small) sur le modèle complet appartenaient déjà à la tâche PA. La projection prédictive est donc conduite dans un second temps en restreignant l’espace des variables à cette seule tâche.




FIGURE 5.4 – Comparaison des modèles par tâche selon l’elpd estimé par LOO-CV. Chaque point représente la différence d’elpd entre le modèle considéré et le meilleur modèle (PA, fixé à 0) ; les barres d’erreur indiquent ± 1 erreur standard sur cette différence. Une différence dont l’intervalle d’erreur standard chevauche zéro indique des performances prédictives statistiquement équivalentes au modèle issu de la tâche PA. Le modèle global (Full) est donc statistiquement équivalent à celui de la tâche PA.

5.3 Sélection sur la tâche PA

5.3.1 Courbe elpd et sélection des variables

La projection prédictive appliquée aux variables de la tâche PA conduit à la sélection de deux variables, `L2_large` et `Sparc_small`, retenues avec une stabilité de 0.99 chacune sur l’ensemble des *folds* (voir [Annexe D](#) pour le détail par variable). Le critère de l’erreur standard, la stabilité de sélection et le coude de la courbe elpd (figure 5.5) convergent vers $k_{\text{opt}} = 2$. Il est important de noter que ces deux variables correspondent aux deux premières retenues lors de la sélection sur le modèle global (section 5.1).

Les performances prédictives du sous-modèle sont comparables à celles du modèle de référence PA (sous-modèle vs référence ; elpd : -52.82 vs -55.28 , *accuracy* : 0.700 vs 0.700). La matrice de confusion indique 15 faux négatifs (classifié TD au lieu de TSA) et 11 faux positifs (classifié TSA au lieu de TD) sur 90 observations. Ces performances sont légèrement supérieures à celles obtenues sur le modèle global (section 5.1), ce qui suggère que la restriction de l’espace des variables à la tâche PA réduit le bruit introduit par des variables peu informatives. On notera que l’elpd du sous-modèle est légèrement supérieur à celui du modèle de référence (figure 5.5), ce qui peut refléter la régularisation induite par la réduction du modèle.

Les estimations des coefficients *a posteriori*, conditionnellement au modèle et aux données, sont présentées dans le tableau 5.3 et la figure 5.6. Les deux coefficients sont négatifs, avec des médianes respectivement de -0.883 et -0.502 , et une incertitude réduite sur le signe des effets malgré une

incertitude importante sur leur taille. Ces estimations sont proches de celles obtenues lors de la sélection sur le modèle complet, avec des écarts relatifs sur les médianes de 16 % pour L2_large et 20 % pour Sparc_small.




FIGURE 5.5 – Courbes de l’elpd et de l’accuracy issues du modèle de référence PA, en fonction du nombre de variables incluses dans le sous-modèle, obtenues par projection prédictive avec validation croisée. Chaque point représente la différence d’elpd/d’accuracy entre le sous-modèle et le modèle de référence. Les barres d’erreur indiquent l’incertitude à ± 1 erreur standard. Une différence proche de zéro indique des performances prédictives équivalentes au modèle de référence.




FIGURE 5.6 – Distributions *a posteriori* des coefficients de régression du sous-modèle à deux variables à partir du modèle de référence PA. Pour chaque paramètre, la barre verticale bleue indique la médiane *a posteriori* et la zone bleue représente l’intervalle de crédibilité à 95 % ($IC_{95\%}$). Conditionnellement au modèle et aux données, la valeur du paramètre a 95 % de chance de se situer dans cet intervalle.

	Médiane	IC _{95%}	$P(\beta_j < 0)$	$P(\beta_j > 0)$
Intercept	-0.011	$[-0.463; 0.463]$	0.52	0.48
L2_large	-0.883	$[-1.524; -0.076]$	0.99	0.01
Sparc_small	-0.502	$[-1.169; -0.028]$	0.97	0.03

TABLE 5.3 – Estimations *a posteriori* des coefficients du sous-modèle à deux variables à partir du modèle de référence PA. La médiane et l'intervalle de crédibilité à 95 % (IC_{95%}) résument la distribution *a posteriori* de chaque coefficient ; $P(\beta_j < 0)$ et $P(\beta_j > 0)$ indiquent la probabilité *a posteriori* que le coefficient soit négatif ou positif, respectivement (probabilité de direction).

5.3.2 Diagnostics MCMC et approximation PSIS-LOO

Les diagnostics MCMC (figure 5.7) ne révèlent pas de problème de convergence et l'ensemble des paramètres affiche un $\hat{R} < 1.01$ ainsi qu'une taille effective d'échantillon > 400 . L'approximation PSIS-LOO est fiable pour l'ensemble des observations. Aucun $\hat{k}$ de Pareto ne dépasse le seuil de 0.7, ce qui contraste avec les résultats obtenus sur le modèle global et renforce la confiance dans les estimations d'elpd utilisées pour la sélection avec le modèle de référence PA.




FIGURE 5.7 – Exemple de diagnostics MCMC illustrés pour le paramètre L2_large, sélectionné à partir du modèle PA. De gauche à droite et de haut en bas : (1) *traceplot* des chaînes, un bon mélange est souhaité et se traduit par des chaînes entrelacées, similaires à un bruit blanc ; (2) fonction d'auto-corrélation, une décroissance rapide vers zéro est souhaitée, ce qui indique une faible dépendance entre échantillons successifs ; (3) histogramme de la distribution *a posteriori*, il doit contenir assez d'informations pour approximer la densité ; (4) courbe de densité estimée *a posteriori*, l'axe x de l'histogramme et de la courbe de densité est exprimé en taille d'effet standardisée.

5.3.3 Sensibilité au prior (p_0)

Deux valeurs alternatives du paramètre p_0 ont été testées et comparées à la valeur de référence ($p_0 = 5$). Les trois configurations conduisent à la sélection des mêmes deux variables, dans le même ordre, avec des stabilités par *fold* identiques (0.99 et 0.99 dans toutes les configurations). Les estimations *a*

posteriori sont stables : les écarts normalisés δ_{norm} sont inférieurs à 4 % pour l'ensemble des paramètres (tableau 5.4).

Sur le plan prédictif, les performances restent globalement stables. Avec $p_0 = 10$, on observe néanmoins que l'*accuracy* du modèle de référence augmente (0.711) alors que celle du sous-modèle ne suit pas (0.700), tandis que les valeurs d'elpd évoluent peu. Cela suggère un léger surapprentissage du modèle de référence.

	$\hat{\beta}_{\text{ref}}$	$\hat{\beta}_{p_0=3}$	$\delta_{\text{norm}}(\%)$	$\hat{\beta}_{p_0=10}$	$\delta_{\text{norm}}(\%)$
Intercept	-0.011	-0.033	2.4	0.008	2.0
L2_large	-0.883	-0.898	1.0	-0.939	3.9
Sparc_small	-0.502	-0.483	1.7	-0.508	0.5

TABLE 5.4 – Analyse de sensibilité des estimations *a posteriori* au choix du paramètre p_0 du prior RHS du modèle PA. $\hat{\beta}_{\text{ref}}$ désigne la médiane *a posteriori* du modèle de référence ($p_0 = 5$) ; δ_{norm} est l'écart normalisé en fonction de l'intervalle de crédibilité, tel que $\delta_{\text{norm}} = |\hat{\beta}_{p_0} - \hat{\beta}_{\text{ref}}| / (\text{largeur IC}_{95\%}^{\text{ref}}) \times 100$

5.3.4 Représentation dans l'espace des variables sélectionnées

La figure 5.8 représente les observations dans l'espace des deux variables sélectionnées, `L2_large` et `Sparc_small`. Les deux groupes forment des nuages distincts mais se chevauchent partiellement. Ce chevauchement est cohérent avec les performances prédictives observées (*accuracy* de 0.700).




FIGURE 5.8 – Représentation des observations dans l'espace des deux variables sélectionnées par projection prédictive sur la tâche PA (`L2_large` et `Sparc_small`). Les unités des axes sont en taille d'effet standardisée.

En conclusion, l'ensemble de ces analyses semble donc converger. Le modèle global produit une sélection stable malgré une incertitude élevée sur les différences d'elpd. Le screening par tâche motrice montre que le modèle restreint à la tâche PA est équivalent au modèle complet tout en reposant sur un espace de variables plus faible. La projection prédictive conduite sur ce sous-espace aboutit à un sous-modèle à deux variables, `L2_large` et `Sparc_small`, dont la sélection est très stable (0.99 sur l'ensemble des *folds*) et cohérente avec les deux premières variables retenues sur le modèle global. Ces résultats sont peu sensibles au choix du prior p_0 . De plus, les deux coefficients sont négatifs : des valeurs plus élevées de `L2_large` et de `Sparc_small` sont associées à une probabilité réduite d'appartenir au groupe TSA, bien que l'incertitude sur la taille de ces effets demeure importante.

6 Discussion

L’objectif de ce mémoire était d’identifier les marqueurs de motricité fine les plus caractéristiques des TSA, parmi un nombre important de variables candidates, via une sélection par projection prédictive. Cette démarche a permis de montrer que le groupe TSA est principalement caractérisé par une réduction de l’amplitude et de la fluidité du mouvement dans la tâche PA. Bien que la sélection par projection prédictive ait déjà quelque fois été appliquées (BRATULIC et al., 2022 ; SULLIVAN et al., 2025 ; WIRTHGEN et al., 2023), c’est à notre connaissance la première fois que cette approche ait été appliquée dans le domaine des STAPS.

6.1 Convergence des résultats, PA comme tâche la plus discriminante

La cohérence entre les trois niveaux d’analyse constitue une forme de validation interne de la démarche par décomposition. Le modèle global, bien qu’il produise une sélection stable aux *folds* et au prior, présentait une incertitude élevée sur les différences d’elpd. Le critère strict basé sur l’erreur standard n’étant pas satisfait, il ne pouvait suffire seul à déterminer k_{opt} . Le screening par tâche a permis de montrer que la tâche PA est la seule équivalente au modèle complet sur la capacité prédictive. Ce résultat a motivé la sélection finale sur PA. Or les deux variables retenues par cette sélection, `L2_Large` et `Sparc_small`, correspondent aux deux premières variables identifiées par le modèle global, et leur proportion de sélection en validation croisée avoisine 0.99 dans les deux analyses. Cette convergence n’était pas garantie, d’autant plus que l’analyse à partir de la tâche PA était elle aussi stable au prior. Cela renforce donc la confiance dans les analyses.

Sur le plan prédictif, l’*accuracy* de 0.700 atteint la borne inférieure de l’objectif fixé à 70–90 %. Enfin, la non-sélection de l’âge et du sexe était un résultat attendu. En effet, le jeu de données étant équilibré par construction sur ces deux variables, leur absence d’effet constitue plutôt un témoin négatif, contrairement à ce qu’on observerait dans la population générale TSA où, par exemple, le ratio de sexe est d’environ 4 garçons pour une fille (ZEIDAN et al., 2022). L’analyse effectuée sur cet échantillon semble donc se prémunir de tout biais lié au sexe.

Les variables issues des tâches Epow, ll_in et PS n’ont pas été retenues, ce qui suggère que ces tâches mobilisent des processus moins sensibles aux altérations motrices caractéristiques des TSA dans cet échantillon, ou qu’elles capturent des dimensions redondantes avec celles déjà indexées par la tâche PA. Ainsi, une explication serait que la composante anticipatoire constitue une différence discriminante. Pour autant, les variables sélectionnées, `L2_Large` et `Sparc_small`, sont des paramètres du mouvement d’atteinte vers la seconde cible, sans lien direct apparent avec la phase d’anticipation de la tâche. La tâche PA semble donc discriminante non pas grâce à sa composante anticipatoire, mais via les caractéristiques cinématiques du mouvement lui-même. La question de savoir pourquoi la tâche PS est moins discriminante reste ouverte. S’agit-il de l’absence d’enchaînement d’actions motrices ou d’une autre propriété de la tâche PA ?

6.2 Interprétation des variables sélectionnées

Les deux variables retenues à l'issue de la sélection sur la tâche PA, **L2_large** et **Sparc_small**, présentent toutes deux des coefficients négatifs : une valeur plus élevée de chacune est associée à une probabilité moindre d'appartenir au groupe TSA. En d'autres termes, c'est la diminution de la distance parcourue et de la fluidité du mouvement qui caractérise les enfants TSA dans cet échantillon.

L2_large correspond à la longueur du tracé parcouru lors du deuxième mouvement de pointage, du premier au deuxième point d'arrivée, en condition cible large. **Sparc_small** correspond à l'indice SPARC calculé sur ce même segment de mouvement, mais en condition cible petite. Ces deux variables indexent donc des dimensions distinctes du contrôle moteur. L'une capture la dimension spatiale, l'autre la dimension temporelle (spectrale) du profil de vitesse. La sélection par projection prédictive confirme leur complémentarité : chacune apporte une contribution prédictive non redondante avec l'autre.

Conformément aux hypothèses formulées, **Sparc_small** s'inscrit dans le cadre d'un déficit de fluidité sous contrainte de précision (médiane $\beta = -0.502$). **L2_large**, en revanche, constitue un résultat plus inattendu. La diminution de la longueur de trajectoire en condition facile (médiane $\beta = -0.883$) oriente l'interprétation vers une hypokinésie du mouvement plutôt que vers un déficit de guidage terminal. Ces deux pistes sont développées dans les sous-sections suivantes.

6.2.1 Hypokinésie du mouvement et planification en *feedforward*

La réduction de distance indexée par **L2_large** ne s'accompagne pas d'une modification de la courbure de trajectoire : les valeurs de l'indice de courbure (*curve index*) sur ce tracé sont comparables entre les deux groupes (TSA : 0.17 ± 0.06 vs TD : 0.16 ± 0.07). Cela exclut une trajectoire plus rectiligne au sens strict. Si la distance est plus courte mais que la courbure est similaire, alors les enfants TSA produisent des trajectoires d'amplitude réduite, ce qui est cohérent avec une hypokinésie déjà observée dans la littérature (ZHANG et al., 2025).

L'absence de sélection de **L2_small** est donc elle-même informative. La condition cible petite est susceptible de masquer les différences d'amplitude de mouvement. Ce résultat est cohérent avec un déficit du contrôle en *feedforward* (voir section 2.2.2) : si la différence provenait d'un déficit de correction par *feedback*, on s'attendrait à ce que ce soit précisément la condition exigeant la plus grande précision qui révèle le plus de différences entre groupes. L'observation inverse semble donc être cohérente avec une altération de la planification motrice initiale.

De plus, on sait que les ganglions de la base interviennent dans la planification mouvement (DESMURGET et al., 2004). Aussi, dans la maladie de Parkinson, la physiopathologie repose sur un dysfonctionnement de ces structures et l'hypokinésie du geste de pointage est souvent retrouvée dans la littérature (MAZZONI et al., 2012), ce qui oblige les patients à produire des ajustements par *feedback* successifs pour atteindre la cible. Or, des anomalies des ganglions de la base sont documentées dans les TSA (MCALONAN et al., 2009). L'hypokinésie observée ici pourrait donc refléter une atteinte partielle des mécanismes de planification dépendants des ganglions de la base, sans pour autant atteindre le tableau clinique complet décrit dans les pathologies avérées de ces structures.

6.2.2 Déficit de fluidité sous contrainte de précision et rôle du cervelet

La non-sélection de **Sparc_large** par la projection prédictive est ici également informative. Elle ne signifie pas que la fluidité est forcément identique entre groupes en condition large, mais que c'est la

condition exigeant la plus grande précision qui concentre l’information discriminante. Un déficit moteur brut, affectant uniformément la production du mouvement, devrait se manifester indépendamment de la contrainte de précision. À l’inverse, un déficit des modèles internes prédictifs ne deviendrait pleinement visible que lorsque la tâche impose une demande de précision importante.

En condition *small*, les enfants TSA semblent contraints de recourir davantage à la correction par *feedbacks* sensoriels pour atteindre la cible, ce qui se traduirait par des ajustements successifs et donc des discontinuités dans le profil de vitesse et un SPARC plus bas. De façon analogue, on retrouve chez les sujets TSA des anomalies du cervelet et des ganglions de la base (GUO et al., 2024; MCALONAN et al., 2009) et leurs conséquences comportementales attendues sont une perturbation du contrôle en *feedforward* (MANTO et al., 2012) et une moindre fluidité comme retrouvé chez les patients parkinsoniens (DOUNSKAIA et al., 2009).

Ainsi, les résultats relatifs à *L2_large* et à *Sparc_small* convergent donc vers une interprétation similaire. L’hypokinésie du geste de pointage et le déficit de fluidité sous contrainte de précision peuvent pointer tous deux vers une moindre efficacité du contrôle en *feedforward*. De plus, le réseau sous-cortical (notamment cervelet et ganglions de la base) est documenté comme altéré chez les sujets TSA, de manière moins marquée que chez les patients parkinsoniens, chez qui on retrouve des troubles moteurs similaires mais plus sévères. En conclusion, ces deux dimensions semblent complémentaires, non redondantes et parcimonieuses pour caractériser les sujets TSA.

6.2.3 Variables secondaires (*Sparc* et *Time to Peak*)

Les deux variables supplémentaires issues du modèle global présentent aussi des proportions de sélection élevées : *Sparc2* (0.97) et *pT2Pv6* (0.93), sans être retenues lors de la sélection conduite sur la tâche PA. Elles sont en effet issues de tâches distinctes, respectivement Epow (tâche d’isochronie) et PS (tâche de pointage simple), et leur statut est celui de pistes secondaires : leur stabilité en sélection justifie qu’elles soient mentionnées, mais l’incertitude sur les différences d’elpd du modèle global ne permet pas de leur accorder le même poids qu’à *L2_large* et *Sparc_small*.

Sparc2 correspond à l’indice SPARC calculé sur la tâche Epow. Sa sélection répétée est cohérente avec *Sparc_small* : la fluidité du mouvement se retrouve discriminante dans une tâche différente, ce qui suggère que le déficit de lissage *feedforward* n’est pas spécifique à la tâche PA. Néanmoins, la sélection par projection prédictive n’étant pas censée sélectionner des variables redondantes, on peut se demander quelle information nouvelle apporterait la fluidité lors de la tâche Epow par rapport à celle rapportée par *Sparc_small* dans la tâche PA.

Enfin, *pT2Pv6* correspond au temps au pic de vitesse mesuré sur la tâche PS à l’indice de difficulté le plus élevé (ID = 6). Ainsi, un temps au pic précoce reflète une impulsion initiale brève, tandis qu’un pic tardif traduit une accélération plus progressive. Dans cet échantillon, l’effet de *pT2Pv6* traduit un *time to peak* plus tard chez les enfants TSA, ce qui est cohérent avec l’interprétation d’hypokinésie évoquée plus tôt. De plus, la sélection de *pT2Pv6* à l’indice de difficulté le plus élevé est par ailleurs cohérente avec l’idée que les contraintes de précision amplifieraient les déficits de planification.

6.3 Performance prédictive et hétérogénéité du spectre

L’*accuracy* du modèle réduit final était de 0.700, ce qui est modéré mais cohérent avec la nature continue du spectre autistique. En effet, certains enfants TSA présentent des altérations motrices

marquées, d'autres non (HOCKING & CAEYENBERGHS, 2017). Néanmoins, les cas extrêmes sont bien classifiés. La superposition dans l'espace des *features* sélectionnées correspond aux profils intermédiaires (voir figure 5.8). Cela souligne que les marqueurs de motricité fine ne sauraient suffire seuls à un diagnostic, mais pourraient être complémentaires à d'autres outils.

De plus, une analyse en composantes principales (ACP) à titre exploratoire a été conduite sur les quatre variables sélectionnées, restreinte au groupe TSA. L'ACP confirme l'absence de sous-groupes discrets (voir Annexe E). Les deux premières composantes n'expliquent que 57.4 % de la variance totale et la distribution des individus dans l'espace ne révèle pas de structure en clusters mais plutôt un étalement continu. Ce résultat suggère qu'il n'existe pas de profils moteurs distincts au sein du groupe TSA. La variabilité semble former un spectre dont l'une des extrémités se confond progressivement avec la distribution du groupe TD.

Les erreurs de classification ne constituent pas pour autant un échec prédictif. Avec seulement deux variables de motricité fine, le modèle atteint une *accuracy* comparable ou légèrement inférieure à celles rapportées dans certaines études utilisant davantage de *features* et des approches non linéaires (voir section 2.4.3). Un modèle non linéaire aurait probablement pu améliorer la capacité prédictive du modèle, mais au prix de la parcimonie et de l'interprétabilité, qui constituaient les objectifs premiers du mémoire. Ainsi, une perspective intéressante consisterait à développer un modèle non linéaire intégrant les variables sélectionnées, combinées à d'autres types de mesures – comme la motricité globale – afin d'atteindre des performances potentiellement plus élevées. De plus, il serait intéressant d'identifier des variables non seulement sensibles aux TSA, mais aussi spécifiques. En effet, on peut s'attendre à ce que d'autres troubles du neurodéveloppement conduisent à des altérations motrices similaires aux TSA.

6.4 Limites

Certaines limites doivent être signalées. La principale limite est la taille d'échantillon ($n = 90$), qui est faible comparée au nombre de variables, ce qui diminue la précision des estimations des coefficients. La probabilité de direction est forte pour les deux variables retenues, mais la taille d'effet des coefficients reste très incertaine. Les résultats sont donc à considérer comme exploratoires et appellent une confirmation sur des échantillons plus larges. De plus, l'estimation de la performance prédictive du modèle est à interpréter avec prudence. En effet, la fiabilité de l'approximation PSIS-LOO est variable selon le modèle considéré. Dans le modèle global, environ 10 % des observations présentent des valeurs $\hat{k} > 0.7$. Néanmoins, le modèle issu de la tâche PA n'est pas concerné par cette limite.

La généralisabilité des résultats est également à nuancer. L'échantillon est clinique et équilibré artificiellement sur le sexe et l'âge, si bien que les performances prédictives obtenues ne se transposent pas directement à la population TSA. De même, l'absence de validation externe sur un échantillon indépendant ne permet pas de conclure à la robustesse des variables sélectionnées au-delà du jeu de données concerné. La double validation croisée LOO atténue cette limite sans pour autant l'éliminer. `L2_large` et `Sparc_small` sont donc des variables candidates pour de futures études, non des biomarqueurs validés.

Enfin, l'espace de variables est contraint par le protocole expérimental. D'autres tâches de motricité fine, impliquant par exemple la coordination bimanuelle ou des séquences plus complexes, auraient pu capturer des variables discriminantes non explorées ici. Cette limite est toutefois relative. Le protocole couvre plusieurs tâches et un nombre important de variables, il aurait été compliqué d'augmenter le nombre de celles-ci sans augmenter la taille de l'échantillon.

7 Conclusion

Ce mémoire visait à identifier, parmi un ensemble large de variables de motricité fine, les marqueurs les plus caractéristiques des enfants avec TSA, à l'aide d'une sélection par projection prédictive. Les trois hypothèses formulées reçoivent un soutien empirique convergent.

Le modèle réduit atteint une *accuracy* de 0.700, ce qui est comparable à ce qui peut être retrouvé dans la littérature sur la base de la motricité, mais avec seulement 2 variables prédictives et une approche linéaire. La décomposition par tâche a permis d'identifier la tâche PA comme la plus discriminante, et la sélection finale a retenu comme variables **L2_large**, qui peut être interprété comme un indice d'hypométrie du geste de pointage, et **Sparc_small**, indice de fluidité sous contrainte de précision. Ces deux variables sont cohérentes avec les corrélats neurophysiologiques décrits dans la littérature, notamment les anomalies du cervelet et des ganglions de la base. On peut alors interpréter ces résultats comme étant potentiellement liés à une moindre efficacité du contrôle en *feedforward*, ce qui serait la différence la plus caractéristique du TSA d'un point de vue moteur. Enfin, l'absence de profils moteurs discrets au sein du groupe TSA suggère que la variabilité intragroupe forme un spectre continu, dont l'une des extrémités se confond avec la distribution du groupe neurotypique, ce qui soutient en partie les limites de toute approche de classification fondée sur la motricité seule.

Ces résultats sont exploratoires et appellent plusieurs perspectives. Une validation externe sur un échantillon indépendant et plus large est nécessaire pour confirmer la robustesse des variables identifiées. Sur le plan méthodologique, l'utilisation de *priors* informatifs fondés sur les estimations obtenues ici permettrait, dans de futures études, de réduire l'incertitude actuellement élevée sur les tailles d'effet. Enfin, l'intégration de **L2_large** et **Sparc_small** dans un modèle multimodal constituerait une piste pour le développement d'outils complémentaires au diagnostic clinique actuel.

Bibliographie

- ADAMOU, M., JONES, S. L., & WETHERHILL, S. (2021). Predicting diagnostic outcome in adult autism spectrum disorder using the autism diagnostic observation schedule, second edition. *BMC Psychiatry*, 21, 24. <https://doi.org/10.1186/s12888-020-03028-7>
- AL SAGHEER, T., HAIDA, O., BALBOUS, A., FRANCHETEAU, M., MATAS, E., FERNAGUT, P.-O., & JABER, M. (2018). Motor Impairments Correlate with Social Deficits and Restricted Neuronal Loss in an Environmental Model of Autism. *Int. J. Neuropsychopharmacol.*, 21(9), 871-882. <https://doi.org/10.1093/ijnp/pyy043>
- AMRHEIN, V., GREENLAND, S., & MCSHANE, B. (2019). Scientists rise up against statistical significance. *Nature*, 567, 305-307. <https://doi.org/10.1038/d41586-019-00857-9>
- ANZULEWICZ, A., SOBOTA, K., & DELAFIELD-BUTT, J. T. (2016). Toward the Autism Motor Signature: Gesture patterns during smart tablet gameplay identify children with autism. *Sci. Rep.*, 6:31107. <https://doi.org/10.1038/srep31107>
- APA. (2022). *Diagnostic and Statistical Manual of Mental Disorders, Fifth Edition, Text Revision (DSM-5-TR)*. American Psychiatric Publishing.
- BALASUBRAMANIAN, S., MELENDEZ-CALDERON, A., ROBY-BRAMI, A., & BURDET, E. (2015). On the analysis of movement smoothness. *J. NeuroEng. Rehabil.*, 12:112. <https://doi.org/10.1186/s12984-015-0090-9>
- BENCHEKRI, A. (2024). *Mieux comprendre les déficits moteurs associés au trouble du spectre de l'autisme : approches biomécanique et cognitive* [Thèse de Doctorat, Spécialité : Sciences et techniques des activités physiques et sportives]. Université de Poitiers.
- BIELENINIK, Ł., POSSERUD, M.-B., GERETSEGG, M., THOMPSON, G., ELEFANT, C., & GOLD, C. (2017). Tracing the temporal stability of autism spectrum diagnosis and severity as measured by the Autism Diagnostic Observation Schedule: A systematic review and meta-analysis. *PLoS One*, 12(9), e0183160. <https://doi.org/10.1371/journal.pone.0183160>
- BRATULIC, S., LIMETA, A., DABESTANI, S., BIRGISSON, H., ENBLAD, G., STÅLBERG, K., HESSELAGER, G., HÄGGMAN, M., HÖGLUND, M., SIMONSON, O. E., STÅLBERG, P., LINDMAN, H., BÅNG-RUDENSTAM, A., EKSTRAND, M., KUMAR, G., CAVARRETTA, I., ALFANO, M., PELLEGRINO, F., MANDEL-CLAUSEN, T., ... GATTO, F. (2022). Noninvasive detection of any-stage cancer using free glycosaminoglycans. *Proc. Natl. Acad. Sci. U.S.A.*, 119(50), e2115328119. <https://doi.org/10.1073/pnas.2115328119>
- BRUGHA, T. S., MCMANUS, S., BANKART, J., SCOTT, F., PURDON, S., SMITH, J., BEBBINGTON, P., JENKINS, R., & MELTZER, H. (2011). Epidemiology of Autism Spectrum Disorders in Adults in the Community in England. *Archives of General Psychiatry*, 68(5), 459-465. <https://doi.org/10.1001/archgenpsychiatry.2011.38>
- CAVALLO, A., ROMEO, L., ANSUINI, C., BATTAGLIA, F., NOBILI, L., PONTIL, M., PANZERI, S., & BECCHIO, C. (2021). Identifying the signature of prospective motor control in children with autism. *Scientific Reports*, 11, 3165. <https://doi.org/10.1038/s41598-021-82374-2>
- COOK, J. (2016). From movement kinematics to social cognition: the case of autism [Publisher: Royal Society]. *Philosophical Transactions of the Royal Society B: Biological Sciences*, 371(1693), 20150372. <https://doi.org/10.1098/rstb.2015.0372>
- CRIPPA, A., SALVATORE, C., PEREGO, P., FORTI, S., NOBILE, M., MOLteni, M., & CASTIGLIONI, I. (2015). Use of Machine Learning to Identify Children with Autism and Their Motor Abnormalities. *Journal of Autism and Developmental Disorders*, 45(7), 2146-2156. <https://doi.org/10.1007/s10803-015-2379-8>
- DESMURGET, M., GRAFTON, S. T., VINDRAS, P., GRÉA, H., & TURNER, R. S. (2004). The basal ganglia network mediates the planning of movement amplitude. *Eur. J. Neurosci.*, 19(10), 2871-2880. <https://doi.org/10.1111/j.0953-816X.2004.03395.x>

- DI MARTINO, A., ROSS, K., UDDIN, L. Q., SKLAR, A. B., CASTELLANOS, F. X., & MILHAM, M. P. (2008). Functional Brain Correlates of Social and Non-Social Processes in Autism Spectrum Disorders: an ALE Meta-Analysis. *Biol. Psychiatry*, 65(1), 63. <https://doi.org/10.1016/j.biopsych.2008.09.022>
- DOCTOR, K. P., MCKEEVER, C., WU, D., PHADNIS, A., PLAWECKI, M. H., NURNBERGER, J. I., Jr., & JOSÉ, J. V. (2025). Deep learning diagnosis plus kinematic severity assessments of neurodivergent disorders. *Sci. Rep.*, 15(1), 20269. <https://doi.org/10.1038/s41598-025-04294-9>
- dos SANTOS, C. L., BARRETO, I. I., FLORIANO, I., TRISTÃO, L. S., SILVINATO, A., & BERNARDO, W. M. (2024). Screening and diagnostic tools for autism spectrum disorder: Systematic review and meta-analysis. *Clinics*, 79, 100323. <https://doi.org/10.1016/j.clinsp.2023.100323>
- DOUNSKAIA, N., FRADET, L., LEE, G., LEIS, B. C., & ADLER, C. H. (2009). Submovements during pointing movements in Parkinson's disease. *Exp. Brain Res.*, 193(4), 529-544. <https://doi.org/10.1007/s00221-008-1656-6>
- ELSABBAGH, M., DIVAN, G., KOH, Y.-J., KIM, Y. S., KAUCHALI, S., MARCÍN, C., MONTIEL-NAVA, C., PATEL, V., PAULA, C. S., WANG, C., YASAMY, M. T., & FOMBONNE, E. (2012). Global Prevalence of Autism and Other Pervasive Developmental Disorders. *Autism Research*, 5(3), 160. <https://doi.org/10.1002/aur.239>
- EMANUELE, M., NAZZARO, G., MARINI, M., VERONESI, C., BONI, S., POLLETTA, G., D'AUSILIO, A., & FADIGA, L. (2021). Motor synergies: Evidence for a novel motor signature in autism spectrum disorder. *Cognition*, 213:104652. <https://doi.org/10.1016/j.cognition.2021.104652>
- ESTES, A., ZWAIGENBAUM, L., GU, H., JOHN, T. S., PATERSON, S., ELISON, J. T., HAZLETT, H., BOTTERON, K., DAGER, S. R., SCHULTZ, R. T., KOSTOPOULOS, P., EVANS, A., DAWSON, G., ELIASON, J., ALVAREZ, S., PIVEN, J., & NETWORK, I. (2015). Behavioral, cognitive, and adaptive development in infants with autism spectrum disorder in the first 2 years of life. *Journal of Neurodevelopmental Disorders*, 7(1), 24. <https://doi.org/10.1186/s11689-015-9117-6>
- FALKMER, T., ANDERSON, K., FALKMER, M., & HORLIN, C. (2013). Diagnostic procedures in autism spectrum disorders: a systematic literature review. *European Child & Adolescent Psychiatry*, 22(6), 329-340. <https://doi.org/10.1007/s00787-013-0375-0>
- FITTS, P. M. (1954). The information capacity of the human motor system in controlling the amplitude of movement. *Journal of Experimental Psychology*, 47(6), 381-391. <https://doi.org/10.1037/h0055392>
- FORTI, S., VALLI, A., PEREGO, P., NOBILE, M., CRIPPA, A., & MOLTENI, M. (2011). Motor planning and control in autism. A kinematic analysis of preschool children. *Research in Autism Spectrum Disorders*, 5(2), 834-842. <https://doi.org/10.1016/j.rasd.2010.09.013>
- FREUD, E., AHMAD, Z., SHELEF, E., & HADAD, B. S. (2025). Effective Autism Classification Through Grasping Kinematics. *Autism Research*, 18(6), 1170-1181. <https://doi.org/10.1002/aur.70049>
- FRIGAUX, A., EVRARD, R., & LIGHEZZOLO-ALNOT, J. (2019). L'ADI-R et l'ADOS face au diagnostic différentiel des troubles du spectre autistique : intérêts, limites et ouvertures. *L'Encéphale*, 45(5), 441-448. <https://doi.org/10.1016/j.enceph.2019.07.002>
- FULCERI, F., CARUSO, A., MICAI, M., GILA, L., TANCREDI, R., FATTA, L. M., GALATI, G., D'AMICO, R., SCHÜNEMANN, H. J., BALDUZZI, S., CINQUINI, M., & SCATTONI, M. L. (2025). Autism diagnosis in children and adolescents: A systematic review and meta-analysis of test accuracy. *Neurosci. Biobehav. Rev.*, 173, 106164. <https://doi.org/10.1016/j.neubiorev.2025.106164>
- GELMAN, A., HILL, J., & YAJIMA, M. (2009). Why we (usually) don't have to worry about multiple comparisons. *arXiv*. <https://doi.org/10.48550/arXiv.0907.2478>
- GLAZEBROOK, C. M., ELLIOTT, D., & LYONS, J. (2006). A Kinematic Analysis of How Young Adults with and Without Autism Plan and Control Goal-Directed Movements. *Motor Control*, 10(3), 244-264. <https://doi.org/10.1123/mcj.10.3.244>
- GOODRICH, B., GABRY, J., ALI, I., & BRILLEMANN, S. (2025). rstanarm: Bayesian applied regression modeling via Stan. [R package version 2.32.2]. <https://mc-stan.org/rstanarm/>
- GROENEWEGER, H. J. (2003). The Basal Ganglia and Motor Control. *Neural Plast.*, 10(1-2), 107. <https://doi.org/10.1155/NP.2003.107>

- GUO, Z., TANG, X., XIAO, S., YAN, H., SUN, S., YANG, Z., HUANG, L., CHEN, Z., & WANG, Y. (2024). Systematic review and meta-analysis: multimodal functional and anatomical neural alterations in autism spectrum disorder. *Molecular Autism*, 15, 16. <https://doi.org/10.1186/s13229-024-00593-6>
- GUPTA, N., SRINIVASAN, S., & GUPTA, M. (2025). Rethinking psychometric testing in autism: overcoming the challenges of comorbidity and diagnostic overshadowing. *CNS Spectr.*, 30(1), e19. <https://doi.org/10.1017/S1092852925000021>
- HANDLE, H. C., FELDIN, M., & PILACINSKI, A. (2022). Handwriting in Autism Spectrum Disorder: A Literature Review. *NeuroSci*, 3(4), 558. <https://doi.org/10.3390/neurosci3040040>
- HAS. (2018, février). *Trouble du spectre de l'autisme : Signes d'alerte, repérage, diagnostic et évaluation chez l'enfant et l'adolescent* (rapp. tech.) (https://www.has-sante.fr/upload/docs/application/pdf/2018-02/trouble_du_spectre_de_lautisme_de_lenfant_et_ladolescent_-_argumentaire.pdf). Haute Autorité de Santé (HAS).
- HIROTA, T., & KING, B. H. (2023). Autism Spectrum Disorder: A Review. *JAMA*, 329(2), 157-168. <https://doi.org/10.1001/jama.2022.23661>
- HOCKING, D. R., & CAEYENBERGHS, K. (2017). What is the Nature of Motor Impairments in Autism, Are They Diagnostically Useful, and What Are the Implications for Intervention? [Publisher: Springer Science and Business Media LLC]. *Current Developmental Disorders Reports*, 4(2), 19-27. <https://doi.org/10.1007/s40474-017-0109-y>
- HOLLOCKS, M. J., LERH, J. W., MAGIATI, I., MEISER-STEDMAN, R., & BRUGHA, T. S. (2019). Anxiety and depression in adults with autism spectrum disorder: a systematic review and meta-analysis. *Psychological Medicine*, 49(4), 559-572. <https://doi.org/10.1017/S0033291718002283>
- HU, T., ZHAO, X., WU, M., LI, Z., LUO, L., YANG, C., & YANG, F. (2022). Prevalence of depression in older adults: A systematic review and meta-analysis. *Psychiatry Res.*, 311:114511. <https://doi.org/10.1016/j.psychres.2022.114511>
- IOANNIDIS, J. P. A. (2005). Why Most Published Research Findings Are False. *PLoS Med.*, 2(8), e124. <https://doi.org/10.1371/journal.pmed.0020124>
- KAMP-BECKER, I., ALBERTOWSKI, K., BECKER, J., GHAREMAN, M., LANGMANN, A., MINGEBACH, T., POUSTKA, L., WEBER, L., SCHMIDT, H., SMIDT, J., STEHR, T., ROESSNER, V., KUCHARCZYK, K., WOLFF, N., & STROTH, S. (2018). Diagnostic accuracy of the ADOS and ADOS-2 in clinical practice. *Eur. Child Adolesc. Psychiatry*, 27(9), 1193-1207. <https://doi.org/10.1007/s00787-018-1143-y>
- KANGARANI-FARAHANI, M., MALIK, M. A., & ZWICKER, J. G. (2024). Motor Impairments in Children with Autism Spectrum Disorder: A Systematic Review and Meta-analysis. *Journal of Autism and Developmental Disorders*, 54(5), 1977-1997. <https://doi.org/10.1007/s10803-023-05948-1>
- KESSLER, R. C., PETUKHOVA, M., SAMPSON, N. A., ZASLAVSKY, A. M., & WITTCHEN, H.-U. (2012). Twelve-month and lifetime prevalence and lifetime morbid risk of anxiety and mood disorders in the United States. *International Journal of Methods in Psychiatric Research*, 21(3), 169. <https://doi.org/10.1002/mpr.1359>
- KLEINHANS, N. M., REITER, M. A., NEUHAUS, E., PAULEY, G., MARTIN, N., DAGER, S., & ESTES, A. (2015). Subregional differences in intrinsic amygdala hyper and hypo connectivity in autism spectrum disorder. *Autism research : official journal of the International Society for Autism Research*, 9(7), 760. <https://doi.org/10.1002/aur.1589>
- KUSHKI, A., CHAU, T., & ANAGNOSTOU, E. (2011). Handwriting Difficulties in Children with Autism Spectrum Disorders: A Scoping Review. *J. Autism Dev. Disord.*, 41(12), 1706-1716. <https://doi.org/10.1007/s10803-011-1206-0>
- LAI, M.-C., AMESTOY, A., BISHOP, S., BROWN, H. M., ONAIWU, M. G., HALLADAY, A., HARROP, C., HOTEZ, E., HUERTA, M., KELLY, A., MILLER, D., NORDAHL, C. W., RATTO, A. B., SAULNIER, C., SIPER, P. M., SOHL, K., ZWAIGENBAUM, L., & GOLDMAN, S. (2023). Improving autism identification and support for individuals assigned female at birth: clinical suggestions and research priorities. *Lancet. Child Adolesc. Health*, 7(12), 897-908. [https://doi.org/10.1016/S2352-4642\(23\)00221-3](https://doi.org/10.1016/S2352-4642(23)00221-3)


- LEBERSFELD, J. B., SWANSON, M., CLESI, C. D., & O'KELLEY, S. E. (2021). Systematic Review and Meta-Analysis of the Clinical Utility of the ADOS-2 and the ADI-R in Diagnosing Autism Spectrum Disorders in Children. *J. Autism Dev. Disord.*, 51(11), 4101-4114. <https://doi.org/10.1007/s10803-020-04839-z>
- LI, B., SHARMA, A., MENG, J., PURUSHWALKAM, S., & GOWEN, E. (2017). Applying machine learning to identify autistic adults using imitation: An exploratory study. *PLoS One*, 12(8), e0182652. <https://doi.org/10.1371/journal.pone.0182652>
- LIU, F., QIU, K., WANG, H., DONG, Y., & YU, D. (2024). Decreased wrist rotation imitation abilities in children with autism spectrum disorder. *Front. Psychiatry*, 15:1349879. <https://doi.org/10.3389/fpsy.2024.1349879>
- LORD, C., ELSABBAGH, M., BAIRD, G., & VEENSTRA-VANDERWEELE, J. (2018). Autism spectrum disorder. *Lancet (London, England)*, 392(10146), 508-520. [https://doi.org/10.1016/S0140-6736\(18\)31129-2](https://doi.org/10.1016/S0140-6736(18)31129-2)
- LORD, C., RUTTER, M., DI LAVORE, P. C., RISI, S., GOTHAM, K., & BISHOP, S. (2012). *Autism Diagnostic Observation Schedule, Second Edition (ADOS-2) Manual (Part I): Modules 1-4*. Western Psychological Services.
- LORD, C., RUTTER, M., & LE COUTEUR, A. (1994). Autism Diagnostic Interview-Revised: A revised version of a diagnostic interview for caregivers of individuals with possible pervasive developmental disorders. *J. Autism Dev. Disord.*, 24(5), 659-685. <https://doi.org/10.1007/BF02172145>
- LUKITO, S., NORMAN, L., CARLISI, C., RADUA, J., HART, H., SIMONOFF, E., & RUBIA, K. (2020). Comparative Meta-analyses of Brain Structural and Functional Abnormalities during Cognitive Control in Attention-Deficit/Hyperactivity Disorder and Autism Spectrum Disorder. *Psychol. Med.*, 50(6), 894. <https://doi.org/10.1017/S0033291720000574>
- LUONGO, M., SIMEOLI, R., MAROCCO, D., MILANO, N., & PONTICORVO, M. (2024). Enhancing early autism diagnosis through machine learning: Exploring raw motion data for classification. *PLoS One*, 19(4), e0302238. <https://doi.org/10.1371/journal.pone.0302238>
- MANTO, M., BOWER, J. M., CONFORTO, A. B., DELGADO-GARCÍA, J. M., da GUARDA, S. N. F., GERWIG, M., HABAS, C., HAGURA, N., IVRY, R. B., MARIËN, P., MOLINARI, M., NAITO, E., NOWAK, D. A., TAIB, N. O. B., PELISSON, D., TESCHE, C. D., TILIKETE, C., & TIMMANN, D. (2012). Consensus Paper: Roles of the Cerebellum in Motor Control—The Diversity of Ideas on Cerebellar Involvement in Movement. *Cerebellum (London, England)*, 11(2), 457. <https://doi.org/10.1007/s12311-011-0331-9>
- MARI, M., CASTIELLO, U., MARKS, D., MARRAFFA, C., & PRIOR, M. (2003). The reach-to-grasp movement in children with autism spectrum disorder. *Philos. Trans. R. Soc. London, Ser. B*, 358(1430), 393-403. <https://doi.org/10.1098/rstb.2002.1205>
- MAZZONI, P., SHABBOTT, B., & CORTÉS, J. C. (2012). Motor Control Abnormalities in Parkinson's Disease. *Cold Spring Harb. Perspect. Med.*, 2(6), a009282. <https://doi.org/10.1101/cshperspect.a009282>
- MCALONAN, G. M., CHEUNG, C., CHEUNG, V., WONG, N., SUCKLING, J., & CHUA, S. E. (2009). Differential effects on white-matter systems in high-functioning autism and Asperger's syndrome. *Psychol. Med.*, 39(11), 1885-1893. <https://doi.org/10.1017/S0033291709005728>
- MICAI, M., FATTA, L. M., GILA, L., CARUSO, A., SALVITTI, T., FULCERI, F., CIARAMELLA, A., D'AMICO, R., DEL GIOVANE, C., BERTELLI, M., ROMANO, G., SCHÜNEMANN, H. J., & SCATTONI, M. L. (2023). Prevalence of co-occurring conditions in children and adults with autism spectrum disorder: A systematic review and meta-analysis. *Neurosci. Biobehav. Rev.*, 155:105436. <https://doi.org/10.1016/j.neubiorev.2023.105436>
- MILANO, N., SIMEOLI, R., REGA, A., & MAROCCO, D. (2023). A deep learning latent variable model to identify children with autism through motor abnormalities. *Front. Psychol.*, 14:1194760. <https://doi.org/10.3389/fpsyg.2023.1194760>
- OMS. (2018). Classification internationale des maladies, 11e révision (CIM-11) : chapitre 6A02 – Troubles du spectre de l'autisme. <https://icd.who.int/fr/>
- PAPADOPOULOS, N., MCGINLEY, J., TONGE, B. J., BRADSHAW, J. L., SAUNDERS, K., & RINEHART, N. J. (2012). An investigation of upper limb motor function in high functioning autism and As-

- perger's disorder using a repetitive Fitts' aiming task. *Research in Autism Spectrum Disorders*, 6(1), 286-292. <https://doi.org/10.1016/j.rasd.2011.05.010>
- PATRIQUIN, M. A., DERAMUS, T., LIBERO, L. E., LAIRD, A., & KANA, R. K. (2016). Neuroanatomical and neurofunctional markers of social cognition in autism spectrum disorder. *Hum. Brain Mapp.*, 37(11), 3957. <https://doi.org/10.1002/hbm.23288>
- PIIRONEN, J., PAASINIEMI, M., CATALINA, A., WEBER, F., MARTIN, O., & VEHTARI, A. (2025). projpred: Projection Predictive Feature Selection [R package version 2.10.0]. <https://mc-stan.org/projpred/>
- PIIRONEN, J., PAASINIEMI, M., & VEHTARI, A. (2018). Projective Inference in High-dimensional Problems: Prediction and Feature Selection. *arXiv*. <https://doi.org/10.1214/20-EJS1711>
- PIIRONEN, J., & VEHTARI, A. (2017). Sparsity information and regularization in the horseshoe and other shrinkage priors. *arXiv*. <https://doi.org/10.1214/17-EJS1337SI>
- POPIT, S., SEROD, K., LOCATELLI, I., & STUHEC, M. (2024). Prevalence of attention-deficit hyperactivity disorder (ADHD): systematic review and meta-analysis. *Eur. Psychiatry*, 67(1), e68. <https://doi.org/10.1192/j.eurpsy.2024.1786>
- R CORE TEAM. (2026). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. Vienna, Austria. <https://www.R-project.org/>
- RANDALL, M., EGBERTS, K. J., SAMTANI, A., SCHOLTEN, R. J., HOOFT, L., LIVINGSTONE, N., STERLING-LEVIS, K., WOOLFENDEN, S., & WILLIAMS, K. (2018). Diagnostic tests for autism spectrum disorder (ASD) in preschool children. *Cochrane Database of Systematic Reviews*, 2018(7), CD009044. <https://doi.org/10.1002/14651858.CD009044.pub2>
- REA, H. M., ØIEN, R. A., SHIC, F., WEBB, S. J., & RATTO, A. B. (2023). Sex Differences on the ADOS-2. *J. Autism Dev. Disord.*, 53(7), 2878-2890. <https://doi.org/10.1007/s10803-022-05566-3>
- RINEHART, N. J., BELLGROVE, M. A., TONGE, B. J., BRERETON, A. V., HOWELLS-RANKIN, D., & BRADSHAW, J. L. (2006). An Examination of Movement Kinematics in Young People with High-functioning Autism and Asperger's Disorder: Further Evidence for a Motor Planning Deficit. *J. Autism Dev. Disord.*, 36(6), 757-767. <https://doi.org/10.1007/s10803-006-0118-x>
- SATO, W., & UONO, S. (2019). The atypical social brain network in autism: advances in structural and functional MRI studies. *Curr. Opin. Neurol.*, 32(4), 617-621. <https://doi.org/10.1097/WCO.0000000000000713>
- SHAFFER, R. L., WANG, Z., BARTOLOTTI, J., & MOSCONI, M. W. (2021). Visual and somatosensory feedback mechanisms of precision manual motor control in autism spectrum disorder. *Journal of Neurodevelopmental Disorders*, 13, 32. <https://doi.org/10.1186/s11689-021-09381-2>
- SIMEOLI, R., MILANO, N., REGA, A., & MAROCCO, D. (2021). Using Technology to Identify Children With Autism Through Motor Abnormalities. *Front. Psychol.*, 12:635696. <https://doi.org/10.3389/fpsyg.2021.635696>
- SONG, P., ZHA, M., YANG, Q., ZHANG, Y., LI, X., & RUDAN, I. (2021). The prevalence of adult attention-deficit hyperactivity disorder: A global systematic review and meta-analysis. *Journal of Global Health*, 11, 04009. <https://doi.org/10.7189/jogh.11.04009>
- SU, W.-C., MUTERSBAUGH, J., HUANG, W.-L., BHAT, A., & GANDJBAKHCHÉ, A. (2024). Using deep learning to classify developmental differences in reaching and placing movements in children with and without autism spectrum disorder. *Sci. Rep.*, 14(1), 30283. <https://doi.org/10.1038/s41598-024-81652-z>
- SULLIVAN, B., BARKER, E., MACGREGOR, L., GORMAN, L., WILLIAMS, P., BHAMBER, R., THOMAS, M., GURNEY, S., HYAMS, C., WHITEWAY, A., COOPER, J. A., MCWILLIAMS, C., TURNER, K., ANDREW W. DOWSEY, bibinitperiod, & MAHABLESHWAR ALBUR, bibinitperiod. (2025). Comparing conventional and Bayesian workflows for clinical outcome prediction modelling with an exemplar cohort study of severe COVID-19 infection incorporating clinical biomarker test results. *BMC Med. Inf. Decis. Making*, 25(1), 123. <https://doi.org/10.1186/s12911-025-02955-3>

- TANNER, A., & DOUNAVI, K. (2021). The Emergence of Autism Symptoms Prior to 18 Months of Age: A Systematic Literature Review. *J. Autism Dev. Disord.*, 51(3), 973-993. <https://doi.org/10.1007/s10803-020-04618-w>
- VABALAS, A., GOWEN, E., POLIAKOFF, E., & CASSON, A. J. (2020). Applying Machine Learning to Kinematic and Eye Movement Features of a Movement Imitation Task to Predict Autism Diagnosis. *Scientific Reports*, 10, 8346. <https://doi.org/10.1038/s41598-020-65384-4>
- van ROOIJ, D., ANAGNOSTOU, E., ARANGO, C., AUZIAS, G., BEHRMANN, M., BUSATTO, G. F., CALDERONI, S., DALY, E., DERUELLE, C., DI MARTINO, A., DINSTEIN, I., DURAN, F. L. S., DURSTON, S., ECKER, C., FAIR, D., FEDOR, J., FITZGERALD, J., FREITAG, C. M., GALLAGHER, L., ... BUITELAAR, J. K. (2017). Cortical and Subcortical Brain Morphometry Differences Between Patients With Autism Spectrum Disorder and Healthy Individuals Across the Lifespan: Results From the ENIGMA ASD Working Group. *Am. J. Psychiatry*, 175(4), 359. <https://doi.org/10.1176/appi.ajp.2017.17010100>
- VEHTARI, A., GABRY, J., MAGNUSSON, M., YAO, Y., BÜRKNER, P.-C., PAANANEN, T., & GELMAN, A. (2025). loo: Efficient leave-one-out cross-validation and WAIC for Bayesian models [R package version 2.9.0]. <https://mc-stan.org/loo/>
- VEHTARI, A., GELMAN, A., & GABRY, J. (2015). Practical Bayesian model evaluation using leave-one-out cross-validation and WAIC. *arXiv*. <https://doi.org/10.1007/s11222-016-9696-4>
- VEHTARI, A., GELMAN, A., SIMPSON, D., CARPENTER, B., & BÜRKNER, P.-C. (2019). Rank-normalization, folding, and localization: An improved $\hat{R}$ for assessing convergence of MCMC. *arXiv*. <https://doi.org/10.1214/20-BA1221>
- WAIZBARD-BARTOV, E., & MILLER, M. (2022). Does the Severity of Autism Symptoms Change Over Time? A Review of the Evidence, Impacts, and Gaps in Current Knowledge. *Clin. Psychol. Rev.*, 99, 102230. <https://doi.org/10.1016/j.cpr.2022.102230>
- WEBB, S. J., & JONES, E. J. H. (2009). Early Identification of Autism: Early Characteristics, Onset of Symptoms, and Diagnostic Stability. *Infants and young children*, 22(2), 100. <https://doi.org/10.1097/IYC.0b013e3181a02f7f>
- WIRTHGEN, E., WEBER, F., KUBICKOVA-WEBER, L., SCHILLER, B., SCHILLER, S., RADKE, M., & DÄBRITZ, J. (2023). Identifying predictors of clinical outcomes using the projection-predictive feature selection—a proof of concept on the example of Crohn’s disease. *Front. Pediatr.*, 11, 1170563. <https://doi.org/10.3389/fped.2023.1170563>
- WOOLFENDEN, S., SARKOZY, V., RIDLEY, G., & WILLIAMS, K. (2012). A systematic review of the diagnostic stability of Autism Spectrum Disorder. *Research in Autism Spectrum Disorders*, 6(1), 345-354. <https://doi.org/10.1016/j.rasd.2011.06.008>
- ZANDER, E., WILLFORS, C., BERGGREN, S., COCO, C., HOLM, A., JIFÄLT, I., KOSIERADZKI, R., LINDER, J., NORDIN, V., OLAFSDOTTIR, K., & BÖLTE, S. (2017). The Interrater Reliability of the Autism Diagnostic Interview-Revised (ADI-R) in Clinical Settings. *Psychopathology*, 50(3), 219-227. <https://doi.org/10.1159/000474949>
- ZEIDAN, J., FOMBONNE, E., SCORAH, J., IBRAHIM, A., DURKIN, M. S., SAXENA, S., YUSUF, A., SHIH, A., & ELSABBAGH, M. (2022). Global prevalence of autism: A systematic review update. *Autism Research*, 15(5), 778-790. <https://doi.org/10.1002/aur.2696>
- ZHANG, T., WANG, J., CAO, Z., MA, Y., & LV, Z. (2025). Early muscle hypotonia as a potential marker for autism spectrum disorder: a systematic review. *Front. Psychiatry*, 16, 1598182. <https://doi.org/10.3389/fpsy.2025.1598182>
- ZWAIGENBAUM, L., BAUMAN, M. L., STONE, W. L., YIRMIYA, N., ESTES, A., HANSEN, R. L., MCPARTLAND, J. C., NATOWICZ, M. R., CHOUERI, R., FEIN, D., KASARI, C., PIERCE, K., BUIE, T., CARTER, A., DAVIS, P. A., GRANPEESHEH, D., MAILLOUX, Z., NEWSCHAFER, C., ROBINS, D., ... WETHERBY, A. (2015). Early Identification of Autism Spectrum Disorder: Recommendations for Practice and Research. *Pediatrics*, 136(Supplement_1), S10-S40. <https://doi.org/10.1542/peds.2014-3667C>


Annexe A. Description de l'ensemble des variables

Annexe B. *Prior et Posterior Predictive Checks*




Les histogrammes comparent la distribution des données réelles (y , en bleu clair) aux données simulées par le modèle (y_{rep} , en bleu foncé, $\pm$ écart-type). À gauche, le *prior predictive check*, c'est-à-dire la distribution des données simulées par le modèle avant d'avoir intégré les données. À droite, le *posterior predictive check*, soit la distribution après que le modèle se soit ajusté aux données. La convergence des deux distributions sur le graphique de droite montre la capacité du modèle à capturer la structure des données TSA/TD, avec une incertitude résiduelle qui témoigne d'une absence de sur-apprentissage.

Annexe C. Stabilité de sélection des variables par *fold* à partir du modèle de référence global




Représente la fréquence de sélection des variables (en ordonnée) en fonction de la taille du sous-modèle (en abscisse) lors de la sélection par projection prédictive à partir du modèle de référence global. Chaque case indique le pourcentage de sélection d'une variable donnée entre les *folds* de la validation croisée pour une taille de modèle k jusqu'à $k = 15$.

Annexe D. Stabilité de sélection des variables par *fold* à partir du modèle de référence PA



Représente la fréquence de sélection des variables (en ordonnée) en fonction de la taille du sous-modèle (en abscisse) lors de la sélection par projection prédictive à partir du modèle de référence PA. Chaque case indique le pourcentage de sélection d'une variable donnée entre les *folds* de la validation croisée pour une taille de modèle k jusqu'à $k = 15$.

Annexe E. Représentation des deux composantes principales issues de l'ACP réalisée sur les 4 variables sélectionnées pour les sujets TSA



Présente la projection des individus du groupe TSA sur les deux premières composantes principales issues d'une ACP réalisée sur les quatre variables les plus discriminantes identifiées par la projection prédictive à partir du modèle de référence global. La répartition des points montre une absence de clusters distincts. Les variables de motricité fine sélectionnées semblent donc varier de façon continue, plutôt que de définir des sous-types de profils moteurs.

Identification des marqueurs de motricité fine les plus caractéristiques des TSA chez l'enfant : Approche bayésienne par projection prédictive

Présenté par : Romain MARTINIE

Sous la direction de : Laetitia FRADET (Université de Bretagne-Sud) & Germain FAITY (ENS 2SEP)

RÉSUMÉ

Objectif : Identifier les marqueurs de motricité fine les plus caractéristiques des TSA chez l'enfant pour améliorer la compréhension du phénotype moteur et explorer des pistes diagnostiques complémentaires.

Méthode : Des marqueurs de motricité fine de 90 enfants (46 TD, 44 TSA) ont été analysés via une approche bayésienne par projection prédictive. Un modèle de référence intégrant 144 variables issues de quatre tâches motrices a été décomposé pour identifier la tâche la plus discriminante. Une sélection de variables a ensuite été opérée sur le sous-modèle retenu.

Résultats : La tâche de Pointage Anticipation (PA) a été sélectionnée comme la plus informative. Deux variables suffisantes pour reproduire la capacité prédictive du modèle ont été identifiées : une codant l'amplitude du mouvement et une la fluidité, avec une précision similaire à ce qui est rapporté dans la littérature (0.700).

Discussion : Les coefficients négatifs associés aux variables sélectionnées traduisent une hypokinésie et un déficit de fluidité chez les enfants TSA, ce qui semble être causé par des altérations des mécanismes de planification en *feedforward* potentiellement liés au cervelet et aux ganglions de la base.

Conclusion : Bien qu'exploratoires en raison du contexte de haute dimensionnalité, ces résultats pointent vers une réduction de l'amplitude du mouvement et de la fluidité lors de tâches de pointage comme les marqueurs de motricité fine les plus caractéristiques des TSA au sein de cet échantillon.

Mots-clefs : TSA, motricité fine, inférence bayésienne, projection prédictive, contrôle proactif.

ABSTRACT

Objectives : To identify the most characteristic fine motor markers of ASD in children to improve the understanding of the motor phenotype and explore complementary ways of diagnostic.

Method : Fine motor markers from 90 children (46 TD, 44 ASD) were analyzed using a Bayesian projective prediction approach. A reference model incorporating 144 variables from four motor tasks was decomposed to identify the most discriminant task. Variable selection was then performed on the selected sub-model.

Results : The Pointing task with Anticipation (PA) was selected as the most informative. Two variables sufficient to replicate the model's predictive power were identified : one encoding movement amplitude and one encoding smoothness, achieving an accuracy similar to that reported in the literature (0.700).

Discussion : The negative coefficients associated with the selected variables reflect hypokinesia and a lack of smoothness in children with ASD, potentially caused by alterations in feedforward planning mechanisms linked to the cerebellum and basal ganglia.

Conclusion : Although exploratory due to the high-dimensional context, these results point to reduced movement amplitude and smoothness during pointing tasks as the most characteristic fine motor markers of ASD within this sample.

Keywords : ASD, fine motor skills, Bayesian inference, projective prediction, feedforward control.

romain.martinie@ens-rennes.fr